

立 德 管 理 學 院

資源環境學系碩士班

碩士論文

主成分分析及類神經網路應用於  
工業區污水處理廠之水質預測

Application of Principal Components Analysis and Artificial  
Neural Networks on Quality Prediction  
of Effluent in Wastewater Treatment Plant

研 究 生：林修平

指導教授：吳春生

中華民國九十五年一月

立德管理學院碩士學位論文  
指導教授推薦書

『資源與環境管理研究所 林修平 君所提之論文—主  
成分分析及類神經網路應用於工業區污水處理廠之水  
質預測，係由本人指導撰寫，同意提付審查』

指導教授：吳春生（簽章）

中華民國 95 年 元 月 15 日

立德管理學院碩士學位論文  
學位考試委員審定書

『資源與環境管理研究所 林修平 君所提之論文—主  
成分分析及類神經網路應用於工業區污水處理廠之  
水質預測，經本委員會審查符合碩士資格標準』

學位考試委員會

召集人：黃汝賢 (簽章)

委員：李祥泉      吳春生  
黃汝賢      \_\_\_\_\_

所長：林淑真 (簽章)

中華民國 95 年 元 月 16 日

## 誌謝

完成研究所的學業及論文，首先要感謝指導教授吳春生老師，在研究方向及論文寫作上耐心的給予學生指導，以及黃汝賢老師不間斷地鼓勵及協助，終使學生論文得以完成。論文口試期間，承蒙李源泉老師撥空細閱並惠賜卓見，特致謝意。

感謝同窗好友建良、盛銘的一路相挺，謹記於心。

最後，默默支持的家人，您們的陪伴才是我走下去最大的原動力，父親、母親、小妹，謝謝你們。

林修平 謹誌

中華民國九十五年一月

**立德管理學院**  
**資源環境學系碩士班**

**碩士論文**

**主成分分析及類神經網路應用於  
工業區污水處理廠之水質預測**

**Application of Principal Components Analysis and  
Artificial Neural Networks on Quality Prediction  
of Effluent in Wastewater Treatment Plant**

**研 究 生：林修平**      Student: Shiu-Ping Lin

**指導教授：吳春生**      Advisor: Chun-Sheng Wu

A Thesis Submitted to Department of Resource and  
Environment Management on Graduate Studies of Leader  
University in partial fulfillment of the Requirements for the  
degree of Master

January 2006

Tainan, Taiwan, Republic of China

## 摘要

由於工業區廠區內各工廠類型不同及其產量之變化，使得工業區聯合污水處理廠進流水質水量變動劇烈，增加操作管理工作之不確定性。若能由聯合污水處理廠之進流及各處理單元之操作條件，及時準確預測放流水質，進而及時因應、調整污水處理廠之操作條件，將有助於污水廠之操作與管理。過去有關污水廠放流水質之預測常僅利用類神經網路模擬，鮮少與工程實務同時進行考量。由於其涉及放流水質動態變化之輸入參數眾多，且參數彼此間存在著某種程度之相關性，為能同時兼顧數值分析與工程實務的觀點與合理性，本研究乃採用主成份分析針對案例污水處理場廠最複雜的活性污泥系統各項操作及監測參數以因子分析中最被廣泛使用的主成份分析法進行輸入變數的篩選。由於各因素中皆包含所有的輸入參數，以此方式可以避免直接進行參數挑選時可能出現的以統計方式所挑選出的重要參數與實際狀況中之重要參數不符的爭議，並能有效的將眾多輸入參數進行縮減而又能保存原有資料結構所提供的主要資訊，以利其後倒傳遞類神經網路的進行。

本研究以南部某工業區聯合污水處理廠民國 89 年 8 月至 91 年 9 月之每日監測及操作參數，首先進行主成份分析進行參數的合成；接著以各處理單元水力停留時間決定可能影響階次；續而使用倒傳遞類神經網路經交叉比對後進行工業區污水處理廠活性污泥系統及最終放流水質濃度之預測，較傳統網路輸入方式所得預測效果為佳。最後經由進一步的效能改善測試後，以預測項目之過去歷史值以及主成份分析合成之新參數，即可針對放流水 COD 及 SS 濃度進行預測，經驗證預測效果得知其測試相關係數分別為 0.774 及 0.706。

關鍵詞：倒傳遞類神經網路、主成份分析、污水處理廠。

## Abstract

The variety of factories and their products in the industrial park has contributed to the dramatic change of influent water quality and influent flow rate of wastewater treatment plant in the industrial park as well as increase the uncertainty of operations management. On the basis of the influent of wastewater treatment plant and the operating conditions of each processing element, the effluent water quality can be calculated accurately and punctually. By this way, operating conditions of wastewater treatment plant can be adjusted or modified in time which is very beneficial to the operations management of wastewater treatment plant. Previous studies in relation with the calculation of effluent water quality of wastewater treatment plant have only applied neural networks and simulation. However, little concern has been paid to the engineering practices. There are multiple and interrelated input parameters pertaining to characteristics of effluent water quality. To consider both perspectives of numerical analysis and engineering practice and the rationality, the present study aims to apply principal component analysis which is widely used to complete the screening of input parameters in the case of the most complicated activated sludge system of wastewater treatment plant. Due to the reason that each component contains all input parameters, such method can present from selecting the main parameters inconsistent with that of real practice, lessen the unnecessary input parameters efficiently and preserve the basic information from original data structure so as to promote the process of back-propagation neural networks.

Data were collected and based on the monitoring parameter and operating parameter from wastewater treatment plant of industrial park located in southern Taiwan from August, 2000 to September, 2002. First, principal component analysis was used to gain the new parameters. Then, the hydraulic retention time of each processing element is used to determine the influence order. Through back-propagation neural networks, the calculation of final effluent water quality of activated sludge system of wastewater treatment plant of industrial part is proved to be more effective than the calculation from conventional neural networks. Finally, after improved tests, the historical value of calculation items and the new parameters derived from principal component analysis can be employed to calculate COD of effluent water quality and the concentration of SS. After calculation, the results show that the test correlation coefficients are 0.774 and 0.706 respectively.

Key words : Back-Propagation Neural Network , Principal Component Analysis , Wastewater Treatment Plant

# 目錄

中文摘要.....	I
英文摘要.....	II
符號說明.....	
第一章 前言.....	1
1-1 研究動機.....	1
1-2 研究目的.....	1
第二章 文獻回顧.....	3
2-1 污水處理廠動態操作之相關研究.....	3
2-2 類神經網路效能評比之相關研究.....	5
2-3 主成分分析界定因子之相關研究.....	5
2-4 主成分分析與類神經網路結合之相關研究.....	6
2-5 污水處理網路輸入變數之相關研究.....	6
第三章 理論背景.....	9
3-1 類神經網路原理.....	9
3-1-1 類神經網路的優缺點.....	9
3-1-2 類神經網路種類.....	10
3-2 倒傳遞類神經網路.....	12
3-2-1 轉換函數.....	13
3-2-2 倒傳遞類神經網路常見問題.....	13
3-3 類神經網路訓練流程.....	14
3-4 因子分析.....	18
3-4-1 適合度檢定.....	20
3-4-2 因子選取.....	21
3-4-3 因子旋轉.....	21



第四章 研究方法.....	22
4-1 輸入向量變數.....	22
4-2 輸入時間區間.....	22
4-3 隱藏層層數及隱藏層神經元.....	22
4-4 資料的前處理.....	23
4-5 正規化處理.....	23
4-6 學習速率 學習法則及訓練次數.....	24
4-7 訓練及測試範例.....	24
4-8 網路效能評估.....	25
第五章 結果與討論.....	26
5-1 活性污泥系統參數之分析.....	26
5-2 活性污泥系統放流水質預測.....	30
5-3 整體污水處理廠放流水質預測.....	39
5-4 網路效能比較及改善測試.....	44
5-4-1 活性污泥系統放流水質預測效能改善測試.....	48
5-4-2 整體污水處理廠放流水質預測效能改善測試.....	56
第六章 結論與建議.....	65
6-1 結論.....	65
6-2 後續研究建議.....	66
參考文獻.....	67

## 圖目錄

圖 3-1 倒傳遞類神經網路架構.....	14
圖 4-1 過度學習現象.....	24
圖 5-1 案例工業區污水處理廠流程圖.....	28
圖 5-2 活性污泥系統放流水 COD 濃度網路訓練散佈圖.....	32
圖 5-3 活性污泥系統放流水COD濃度網路預測散佈圖.....	32
圖 5-4 活性污泥系統放流水 COD 濃度網路訓練圖.....	33
圖 5-5 活性污泥系統放流水 COD 濃度網路預測圖.....	34
圖 5-6 二級處理放流水 COD 濃度網路訓練散佈圖.....	37
圖 5-7 二級處理放流水 COD 濃度網路預測散佈圖.....	37
圖 5-8 二級處理放流水 COD 濃度網路訓練圖.....	38
圖 5-9 二級處理放流水 COD 濃度網路預測圖.....	39
圖 5-10 污水處理廠放流水 COD 濃度網路訓練散佈圖.....	42
圖 5-11 污水處理廠放流水 COD 濃度網路預測散佈圖.....	42
圖 5-12 污水處理廠放流水 COD 濃度網路訓練圖.....	43
圖 5-13 污水處理廠放流水 COD 濃度網路預測圖.....	44
圖 5-14 污水處理廠放流水 COD 濃度含自身項網路訓練散佈圖.....	49
圖 5-15 污水處理廠放流水 COD 濃度含自身項網路訓練圖.....	50
圖 5-16 污水處理廠放流水 COD 濃度含自身項網路預測散佈圖.....	51
圖 5-17 污水處理廠放流水 COD 濃度含自身項網路預測圖.....	51
圖 5-18 活性污泥系統放流水 SS 濃度含自身項網路訓練散佈圖.....	53
圖 5-19 活性污泥系統放流水 SS 濃度含自身項網路訓練圖.....	54
圖 5-20 活性污泥系統放流水 SS 濃度含自身項網路預測散佈圖.....	55
圖 5-21 活性污泥系統放流水 SS 濃度含自身項網路預測.....	55
圖 5-22 污水處理場放流水 COD 濃度含自身項網路訓練散佈圖.....	58
圖 5-23 污水處理場放流水 COD 濃度含自身項網路預測散佈圖.....	58

圖 5-24 水處理場放流水 COD 濃度含自身項網路訓練圖.....	59
圖 5-25 水處理場放流水 COD 濃度含自身項網路預測圖.....	60
圖 5-26 污水處理場放流水 SS 濃度含自身項網路訓練散佈圖.....	62
圖 5-27 污水處理場放流水 SS 濃度含自身項網路預測散佈圖.....	62
圖 5-28 污水處理場放流水 SS 濃度含自身項網路訓練圖.....	63
圖 5-29 污水處理場放流水 SS 濃度含自身項網路預測圖.....	64

## 表目錄

表 3-1 各式類神經網路模式彙整比較表.....	11
表 5-1 KMO 檢定表.....	26
表 5-2 案例污水處理廠各項監測操作參數統計表.....	27
表 5-3 各因子特徵值及變異量表.....	29
表 5-4 最大正交旋轉所得之因子負荷量表.....	29
表 5-5 活性污泥系統放流水 COD 濃度預測隱藏層神經元數測試果.....	31
表 5-6 二級處理 9 個輸入項放流水 COD 濃度預測隱藏層神經元數測試結果.....	35
表 5-7 二級處理 11 個輸入項放流水 COD 濃度預測隱藏層神經元數測試結果.....	36
表 5-8 整廠 9 個輸入項放流水 COD 濃度預測隱藏層神經元數測試結果.....	40
表 5-9 整廠 11 個輸入項放流水 COD 濃度預測隱藏層神經元數測試結果.....	41
表 5-10 含自身項活性污泥系統放流水 COD 濃度預測隱藏層神經元數測試結果.....	48
表 5-11 含自身項活性污泥系統放流水 SS 濃度預測隱藏層神經元數測試結果.....	52
表 5-12 含自身項污水處理場放流水 COD 濃度預測隱藏層神經元數測試結果.....	57
表 5-13 含自身項污水處理場放流水 SS 濃度預測隱藏層神經元數測試結果.....	61

## 符號說明

英文字母：	
$A$	：因子負荷矩陣（-）
$C$	：常數（-）
$E$	：能量函數（-）
$F$	：轉換函數（-）
$G$	：樣本的測值（-）
$\bar{G}$	：變數的平均值（-）
$H$	：隱藏層神經元的輸出值（-）
$KMO$	：抽樣正確量（-）
$L$	：主成分分析基本資料矩陣（-）
$MSE$	：均方誤差（-）
$O$	：主成份分析原始變量重新組合彼此互相獨立的新變量矩陣（-）
$R$	：相關矩陣（-）
$S$	：變數的標準差（-）
$T$	：輸出層輸出單元之目標輸出值（-）
$U$	：特徵向量矩陣（-）
$V^+$	：正規化之最大值網路輸出（-）
$V^-$	：正規化之最小值網路輸出（-）
$W$	：輸入神經元與隱藏神經元或隱藏神經元與輸出神經元間之連結權重值（-）
$X$	：應用訓練範例的輸入層神經元的輸入值（-）
$Y$	：輸出層神經元的推論輸出值（-）
$Z$	：標準化後的標準化矩陣（-）

$a$	: 因子負荷 ( - )
$h$	: 變數間之偏相關係數 ( - )
$k$	: 預測值與實際值之差值 ( - )
$m$	: 因子分析後所選取的因子個數 ( 個 )
$n$	: 資料筆數 ( 筆 )
$q$	: 因子分析前所選取的因子個數 ( 個 )
$r$	: 相關係數 ( - )
希臘字母 :	
$\Delta W$	: 權重值變化量 ( - )
$\Delta W(n)$	: 權重值 $W$ 第 $n$ 次的修正量 ( - )
$\Delta W(n-1)$	: 權重值 $W$ 第 $n-1$ 次的修正量 ( - )
$\Delta \theta$	: 隱藏層神經元或輸出層神經元之閾限值修正量 ( - )
$\Delta \theta(n)$	: 閾限值 $\theta$ 第 $n$ 次的修正量 ( - )
$\Delta \theta(n-1)$	: 閾限值 $\theta$ 第 $n-1$ 次的修正量 ( - )
$\alpha$	: 慣性因子 ( - )
$\delta$	: 隱藏層神經元或輸出層神經元的誤差量 ( - )
$\varepsilon$	: $m$ 個主因子不能解釋的部分 ( - )
$\eta$	: 學習速率 ( - )
$\mu$	: 平均值 ( - )
$\theta$	: 隱藏層神經元或輸出層神經元之閾限值 ( - )
$\lambda$	: 特徵值 ( - )
$\sigma$	: 標準差 ( - )
下標 :	
$b$	: $KMO$ 檢定中之變數 ( - )
$c$	: $KMO$ 檢定中之變數 ( - )
$d$	: 目標值 ( - )

$e$	: 第 $e$ 個輸入神經元 ( - )
$f$	: 第 $f$ 個輸出神經元 ( - )
$g$	: 第 $g$ 個隱藏神經元 ( - )
$i$	: 第 $i$ 個隱藏神經元 ( - )
$j$	: 第 $j$ 個輸入神經元 ( - )
$l$	: 第 $l$ 個輸出神經元 ( - )
$t$	: $t$ 時之時間 ( - )
$v$	: 主成份分析中第 $v$ 個變數 ( - )
$w$	: 主成份分析中第 $w$ 個樣本的測值 ( - )
$x$	: 網路輸出值 ( - )

# 第一章 前言

## 1-1 研究動機

工業廢水的排放所造成的污染是為台灣河川污染的主因之一，而國內之工業區並不如國外之工業區依照同性質工業區作分類，故國內之工業區聯合污水處理廠易受廠區內之工廠產品特性、製程原料以及其產銷淡旺季之影響，使得操作控制困難，造成放流水質的變化。近年來更由於經濟及工業的急速成長，使得工業廢水問題日益嚴重，造成水體環境急速惡化及水資源的破壞。

一般工業區聯合污水處理廠之規劃設計及營運管理，在保護承受水體與符合法規之放流標準前提下，必須充份考量進流負荷的變動、污染物質的去除效率、系統中單元與程序的配置與彈性、操作難易度、與對環境衝擊之程度等因素。面對日趨嚴格的污水排放標準，污水處理廠若能事先掌握處理水質之狀況，將有助於提高污水廠之處理效率。

然而污水處理系統中充滿許多不明確的變數，整個處理系統呈現高度複雜的關係，因此不易以傳統的推理模式進行預測。類神經網路(artificial neural network,ANN)是模仿生物神經元運作的計算系統，具有學習與識別能力、高度的非線性模擬能力及容忍能力，已被廣泛的應用於各學術領域上，如 Yi *et al.*, (1996)；Spellman *et al.*, (1999)；Jorquera *et al.*, (1998)；Prybutok *et al.*, (2000)，包括在污水處理放流水質動態變化之預測上，也有良好的成效，如 Hack *et al.*, (1996)；Tomida *et al.*, (1999)；Belanche *et al.*, (1999)。

## 1-2 研究目的

類神經網路用於污水處理廠之放流水質預測雖有良好的表現，但由於輸入變數之篩選與相關時間區間只能由試誤法及歷來文獻判定，如施東河等，(1997)；陳清暉等，(1999)；Wan *et al.*, (2000)；何佳祥等，(2002)，使得類神經網路於實際的運算工作量上顯得龐大及複雜。換言之，完善的資料前處理程序將可有效減少類神經網路之演算量，並提升效率。又由於各個污水處理廠之處理程序、進流條件及操作



條件皆有差異，某一污水廠之較重要參數，對於另一污水廠而言卻不見得適用。因此本研究期能建立一套較為完善參數前處理之篩選程序，包括使用主成份分析先進行較為複雜的活性污泥系統各參數的精簡，再利用類神經網路依據各槽體不同的水力停留時間比較影響階次進行網路的訓練及驗證。

本研究擬針對南部某聯合工業區污水處理廠之放流水 COD 及放流水 SS 濃度，以類神經網路加以預測，研究項目包括：

- 一、以主成分分析將案例污水處理廠活性污泥系統主要參數分析出的因素以線性迴歸的方式組合成全新的輸入變數，並依據各處理單元水力停留時間進行最相近時間階次的網路實作比較。
- 二、比照其他相關文獻進行網路結構的精簡以及網路預測效能的改善，針對該污水處理廠之放流水 COD 濃度及 SS 濃度進行類神經網路的訓練及驗證。

## 第二章 文獻回顧

本章茲就污水處理廠動態操作、水質監測與預測之國內外相關文獻，包括統計檢定、類神經網路等相關研究進行回顧整理。

### 2-1 污水處理廠動態操作之相關研究

由於電腦普及及性能與運算速度不斷提昇，開始出現許多對於實廠或模廠之動態操作之相關研究。

Lech *et al.*, (1977) 以模廠之活性污泥處理系統推求活性污泥處理程序於自動控制時所使用之轉換函數模式之參數。Berthouex *et al.*, (1978) 針對活性污泥處理程序隨時間連續觀測產生有順序之時間數列型態之資料建立ARIMA模式，預測放流水BOD濃度。推求放流水BOD濃度、進流水BOD濃度及進流水流量三者間之動態關係。藉由此模式可經由進流水BOD濃度及進流水流量預測放流水BOD濃度。Stenstrom *et al.*, (1979) 分別以數學模式及模廠模擬的方式證明控制比攝氧率可以有效的控制放流水水質的變化。Debelak *et al.*, (1981) 以時間數列ARIMA模式，以實廠之連續資料進行分析，進行污水處理廠進流水COD濃度及放流水COD濃度之模式化，並發展污水處理程序之轉移函數。其研究結果顯示單獨使用自身進行預測是不夠的，建議預測模式應包含更多的變數，如流量、進流負荷、溫度...等等，來提高模式之預測能力。Hack *et al.*, (1996) 使用多層認知類神經網路 (multilayer preceptron neural network) 以污水處理廠實廠進行預測，其中輸入參數使用相關性分析，選取與預測項目相關性高之參數作為輸入參數，以分析後所選取之參數作為輸入參數，於各項測試範例中其相關係數R值皆可達到0.8以上。施東河等，(1997) 使用類神經網路以活性污泥模廠進行放流水SS濃度之預測，所使用之輸入變數包含進流量、MLSS濃度、迴流污泥濃度、溶氧量、迴流污泥量、進流水COD濃度、放流水SS濃度等，其採用之類神經網路類型為倒傳遞類神經網路，經過網路敏感度分析後得到各輸入變數較重要之時間區間以及較重要之輸入變數。經網路最適化後得到輸入變數為進流量、MLSS濃度、迴流污泥濃度、迴流污泥量、進流水COD濃度、放流水SS濃度等，內含10個輸入神經

元，2個隱藏層神經元，以及1個輸出神經元；訓練範例195筆，測試範例40筆，學習速率為0.4；網路執行測試結果之RMS( root mean square )為0.133。Tomida *et al.*, ( 1999 ) 使用模糊類神經網路和多重迴歸分析模式模擬、預測活性污泥處理模型場之放流水COD濃度，以曝氣槽進流水COD濃度，操作運轉時間，曝氣槽停留時間HRT及放流水溫度等四項作為輸入項，結果顯示模糊類神經網路之預測結果優於多重迴歸分析模式之預測結果。Belanche *et al.*, ( 1999 ) 使用類神經網路以模廠進行放流水COD濃度之預測，所使用之輸入變數包含進流流量、迴流流量、廢棄污泥量曝氣槽曝氣量、進流水COD濃度、進流水BOD濃度、進流水TSS濃度、放流水COD濃度及放流水BOD濃度等，其採用之類神經網路之類型為時間延遲類神經網路，內含13個輸入神經元，8個隱藏層神經元，以及1個輸出神經元。其研究結果顯示，實際值與預測值呈現良好之一致性。Wan *et al.*, ( 2000 ) 使用類神經網路結合遺傳演算法（類分子神經系統）經過網路自主學習後，再經由網路敏感度分析得知污水處理廠影響放流水質SS濃度之重要參數為進流量、MLSS濃度、進流水pH及迴流污泥量。Choi *et al.*, ( 2001 ) 使用主成份分析作為倒傳遞類神經網路輸入變數之篩選方式，以活性污泥系統進行TKN濃度之預測，比未篩選參數的類神經網路得到更佳的结果。何佳祥等，( 2002 ) 使用類神經網路之倒傳遞類神經網路及灰色系統理論以實廠之上流式厭氧污泥床分別進行放流水COD濃度之預測，將實廠之資料分為淡、旺兩季。以Pearson分析得知與放流水COD濃度相關性較高之參數為輸入變數，以試誤法透過網路之學習與識別，決定相關時間區間為4階。研究結果顯示，類神經網路旺季時最佳學習與測試筆數比例為8：1，測試相關係數R值達0.989；淡季時最佳學習與測試筆數比例為5：1，測試相關係數R值達0.9以上。灰預測旺季時最佳測試資料筆數為22筆，測試相關係數R值達0.901；淡季時最佳測試資料筆數為18筆，測試相關係數R值達0.913。洪明松，( 2004 ) 針對鋼鐵廠之廢水處理廠進行放流水質COD濃度之預測，使用因子分析進行網路輸入參數之篩選，預測結果對整體放流水COD濃度的模擬吻合性相當高。

## 2-2 類神經網路效能評比之相關研究

由於類神經網路之應用研究與日俱增，比較類神經網路與其他模式在工程上的研究也隨之增加。

Yi *et al.*, (1996) 於美國德州達拉斯一處工業區，分別應用迴歸模式、ARIMA、以及類神經網路三種模式進行都市地區臭氧濃度日最大值之預測。Spellman *et al.*, (1999) 比較倒傳遞類神經網路與逐步迴歸法進行1993~1996年間英國五個測站之臭氧濃度預測之結果。Jorquera *et al.*, (1998) 比較類神經網路模式、模糊模式及時間序列模式進行臭氧最大濃度預測之結果。Tomida *et al.*, 1999 分別使用模糊類神經網路和多重迴歸分析模式於一個模擬活性污泥處理模型場進行放流COD濃度之預測。Prybutok *et al.*, (2000) 比較倒傳遞類神經網路、ARIMA 及逐步迴歸法預測臭氧日最高值之結果。黃宗仁，2000 比較類神經網路與時間序列法及複迴歸分析法預測台中都會區臭氧趨勢。以上研究結果皆顯示類神經網路在非線性的模擬能力不遜於其他模式，故本研究擬採用類神經網路進行預測。

## 2-3 主成分分析界定因子之相關研究

在多變量統計分析中，主成分分析法最常被用於減少維度的方法，同時也常用於分析界定組成因子的研究中。黃建源，(2000) 以多變量統計法分析民國82至87年日月潭水庫水質監測資料，分析日月潭水庫水質變異之主成份因子與研判污染源，主成分分析結果顯示日月潭水庫水質變異之主成份因子，分別是總磷、總氮與硝酸鹽氮組成的「營養鹽供給因子」；透明度與濁度組成的「混濁因子」及葉綠素與化學需氧量組成的「有機物供給因子」。王俊凱，(2000) 研究探討高雄、台北都會區氣膠特性與污染來源，以主成分分析推估結果顯示台北地區以二次光化反應污染、農廢燃燒為主要的污染來源。蔡明昊，(2002) 研究探討德基水庫不同位址底泥、土壤與水質之關係，以水質資料作主成分分析，以分析各項影響水質因子的權重。主成分分析結果則顯示，影響水質重要因子為總固體、懸浮固體與總磷，並且判斷出污染較嚴重的是梨山排水溝與水庫源頭，結果與底泥分析結果所判斷受到人為污染的結果相同。鄭百乘，(2003) 研究界定焚化廠與周界空氣、土壤、植物中戴奧辛含量的關係，使

用主成分分析、階層群集分析與ISCST3大氣擴散模式結果顯示，焚化廠並非當地戴奧辛主要排放源，人類活動的綜合影響應為此區域戴奧辛之主要來源。林碧霜，(2003)研究探討人文經濟活動對漁港水質環境的影響程度，最後從主成分分析中發現家庭人口等所產生的廢水量是影響港區 $\text{NH}_4 - \text{N}$ 含量的最大因素。

## 2-4 主成分分析與類神經網路結合之相關研究

李維斌，(2000)針對銀行業進行品值管理，使用因子分析將問卷資料分類成數個因素，再藉由倒傳遞類神經網路學習來建立網路模式，以提供銀行業者作為全面品值管理成效評定之參考依據。郭益銘等，(2000)針對雲林沿海地區地下水質變化採用因子分析將雲林沿海地區地下水質資料分成海水鹽化因子及砷污染因子等兩項，具78%之代表性。再使用倒傳遞類神經網路針對此2因子分別建立類神經網路預測模式。陳瑞龍，(2001)針對醫院進行服務品值管理，使用因子分析將問卷資料分類成數個因素，再藉由倒傳遞類神經網路學習來建立網路模式，以提供醫院作為全面品值管理成效評定之參考依據。賴怡瑾等，(2002)針對壽險業業務人員服務績效評估，使用因子分析將問卷資料分類成數個因素，再藉由倒傳遞類神經網路學習來建立網路模式，以提供壽險業作為業務人員服務績效評估之參考依據。

## 2-5 污水處理網路輸入變數之相關研究

架構類神經網路第一個步驟為輸入變數之篩選。施東河等，(1997)以蔡勇斌，(1993)提出之活性污泥模廠資料使用相關性分析作為倒傳遞類神經網路輸入變數之篩選方式，選取與預測項目相關性高之參數作為輸入變數（進流量、MLSS濃度、迴流污泥濃度、溶氧量、迴流污泥量、進流水COD濃度、放流水SS濃度），進行放流水SS濃度之預測。陳清暉，(1999)以蔡勇斌，(1993)提出之操作監測項目作為污水處理廠之重要操作、監測項目，並以實廠資料進行相關性分析作為倒傳遞類神經網路輸入變數之篩選方式，進行放流水SS濃度之預測，比較多種不同之輸入變數之組合。Choi *et al.*，(2001)使用主成份分析作為倒傳遞類神經網路輸入變數之篩選方式，以活性污泥系統進行TKN濃度之預測，根據主成份分析將活性污泥系統之眾多參數分

為成數個因素 ( Components ), 以特徵值大於1的因素中的因子負荷量將之線性組合出新的參數, 再以新合成之參數進行倒傳遞類神經網路, 並與直接以參數群作為輸入的類神經網路比較, 結果顯示能以較少的輸入項目得到更佳的结果。陳柏蒼等, ( 2002 ) 針對未設測站之河川流量進行推估, 使用因子分析將地文因子資料進行篩選後再與其他流量資料進行倒傳遞類神經網路的流量推估模式。何佳祥等, ( 2002 ) 使用相關性分析作為倒傳遞類神經網路輸入變數之篩選方式, 以實廠之上流式厭氧污泥床進行放流水COD濃度之預測, 選取與預測項目相關性高之參數作為輸入變數。簡家宏, ( 2004 ) 使用相關性分析作為倒傳遞類神經網路輸入變數之篩選方式, 以空氣品質監測資料進行PM<sub>10</sub>濃度之預測, 選取空氣品質之間所得相關性高之參數作為輸入變數。洪明松, ( 2004 ) 針對鋼鐵廠之廢水處理廠進行放流水質COD濃度之預測, 使用主成分分析進行網路輸入參數之篩選, 以各因素中之因子負荷量最大的因子做為類神經網路之輸入項目, 其預測結果對整體放流水COD濃度的模擬吻合性相當高。

劉興明, ( 2004 ) 指出在類神經網路決定輸入變數時, 通常是利用相關性分析, 或憑藉著操作者的經驗而定, 並沒有一定的建模規則可適。由於各個污水處理廠之處理進流水質及其設計或處理方式可能皆有差異, 其操作、監測之項目及其特性也會隨之不同, 似乎不宜以歷來文獻中所提出之操作監測項目概括各不同型態之污水處理廠, 又以相關性分析作為污水處理廠放流水直預測類神經網路輸入變數之篩選方式, 其結果無法完全呈現監測、操作參數所提供的主要資訊, 所篩選之變數實際上重要與否也備受爭議。

由於類神經網路具有自我學習的特性, 因此輸入項目適合與否關係著網路的預測能力。羅華強, ( 2001 ) 指出, 在某些狀況下, 輸入向量的維度很大, 但是向量的組成是高度相關的, 在這種狀況中, 降低輸入向量的維度是有用的。因此, 本研究使用主成分分析進行污水處理廠中最重要也最複雜的活性污泥系統部份參數資料的縮減。

因子分析是一種用來篩選多變數的統計方法, 能以較少的維數來表示原先的資料結構, 而又能保存原有資料結構所提供的主要資訊, 故本研究針對案例污水處理場廠最複雜的活性污泥系統各項操作及監測參數以因子分析中最被廣泛使用的主成份分析法進行輸入變數的篩選, 根據主成份分析將所有輸入參數分為成數個因素

( Components ), 以特徵值大於1的因素中的因子負荷量將之線性組合出新的參數, 再以新合成之參數進行倒傳遞類神經網路污水處理廠放流水質之預測。由於各因素中皆包含所有的輸入參數, 以此方式可以避免直接進行參數挑選時可能出現的以統計方式所挑選出的重要參數與實際狀況中之重要參數不符的爭議, 並能有效的將眾多輸入參數進行縮減而又能保存原有資料結構所提供的主要資訊, 以利其後倒傳遞類神經網路的進行。

## 第三章 理論背景

### 3-1 類神經網路原理

類神經網路(artificial neural network)，又稱為人工神經網路，是一種計算系統，包括軟體與硬體，使用大量簡單的相連人工神經元來模仿生物神經網路的能力。人工神經元是生物神經元的簡單模擬，它從外界輸入或者其它人工神經元取得資訊，並加以簡單的運算，並輸出其結果到外界環境或者其它人工神經元。

#### 3-1-1 類神經網路的優缺點

類神經網路之優缺點分述如下：

##### 一、優點：

##### (1) 具有容錯能力

在類神經網路中的一組輸入與輸出的關係，並不是直接由網路中某一個連結所單獨負責的，而是由眾多連結交互影響而成，每一個連結只會映射出輸入與輸出模式的一個微特徵 ( micro feature ) 且每一個連結只是輕微地影響輸入及其對應之輸出結果。當網路中所有的微特徵組合在一起時，才能夠呈現出完整的輸入與輸出結果。因此，當某一連結所輸入需處理的訊號其有雜訊或處理的數據不完整時，此一輸入對網路所造成的影響並不大。

##### (2) 具有適應性學習能力

每種類型的類神經網路都有其特定的學習演算法則，經由演算法則可調整連結與連結之間的連接權重值，並透過不斷地調整權重值直到得到相似的輸入與輸出模式，這種能力稱之為適應性學習能力。

##### (3) 高速的計算能力

由於電腦運算速度的大幅提升，類神經網路的計算速度也跟著增強，所以高速的計算能力也是類神經網路的優點之一。



## 二、缺點：

### (1) 網路最適化之工作費時

(2) 一般而言在網路內之隱藏層需一層至二層，各層之神經元數可設為任意數目，並且另需設定學習速率參數等動作，因此為求最適化之參數設定費時甚鉅。

### (3) 過度學習現象

因網路內具有大量可調參數，可能因為網路參數之設定不當而發生「過度學習」現象。所謂過度學習是指在訓練的過程中誤差已經被推算至非常小的值，但是在驗證新的數據時，所產生的誤差卻變得很大，即是網路已經學習了訓練範例，但是針對測試範例並沒有良好的模擬能力。

### (4) 非唯一解

因為類神經網路是一種非線性模式，各加權值及閾限值並非唯一解，故難以證明所得解為最佳解。

### (5) 模型複雜，無法套用公式

因類神經網路是以含權值的網路來建構模式，故難以套用公式直接解題。

## 3-1-2 類神經網路種類

目前的類神經網路模式很多（如表3-1），一般而言分為監督式、無監督式、聯想式及最適化應用網路等四類。監督式又分為感知機（perceptron）、倒傳遞網路（back-propagation network）、機率神經網路（probabilistic neural network）、學習向量量化網路（learning vector quantization）及反傳遞網路（counter-propagation network）。無監督式又可分為自組織映射圖網路（self-organizing map network）、自適應共振理論網路（adaptive resonance theory network）。聯想式又可分為霍普菲爾網路（Hopfield neural network）、雙向聯想記憶網路（bi-directional associative memory network）。最適化應用網路又可分為霍普菲爾-坦克網路（Hopfield-Tank neural network）及退火神經網路（annealed neural network）。

表3-1 各式類神經網路模式彙整比較表（葉怡成，1999）

分類	模式	主要研發者	研發年代	主要應用	主要特點
監督式	感知機	F. Rosenblatt	1957	打字字母識別	無法解決互斥 exclusive or (XOR) 問題 模式最簡單 發展最早
	倒傳遞網路	P. Werbos D. Parker D. Rumelhart	1974~1985	樣本識別 分類問題 函數合成 適應控制 雜訊過濾 資料壓縮 專家系統	可解決互斥 exclusive or (XOR) 問題 應用最普及 成功案例多 學習精度高 學習速率慢 回想速度快 理論簡明
	機率神經網路	D.F. Specht	1988	樣本識別 分類問題	學習速率快 回想速度快 理論簡明
	學習向量量化網路	T. Kohonen	1988	樣本識別 分類問題	學習速率快 回想速度快 理論簡明
	反傳遞網路	R. Hecht-Nielsen	1986	樣本識別 分類問題 函數合成 資料壓縮	結合監督與無監督學習 理論簡明 學習速率快 學習精度較低
	自組織映射圖	T. Kohonen	1980	聚類問題 拓撲映射	具有鄰近區域觀念 學習速率快
無監督式	自適應共振理論	G.A. Carpenter S. Grossberg	1976~1986	樣本識別 聚類問題	網路具穩定性 網路具可塑性 學習速率快 回想速度慢 模式非常複雜 具警戒值觀念
	霍普菲爾網路	J. Hopfield	1982	自聯想記憶問題 雜訊過濾	學習速率快 回想速度慢 理論簡明
聯想式	雙向聯想記憶網路	B. Kosko	1985	異聯想記憶問題 雜訊過濾	學習速率快 回想速度慢 理論簡明
	霍普菲爾-坦克網路	J. Hopfield D. Tank	1985	組合最適化問題	易陷局部最小值
最適化	退火神經網路	D.E. Ven Den Bout T.K. Miller	1988	組合最適化問題	較不易陷局部最小值

綜合各種類神經網路特點的比較（表3-1），本研究擬採最適合於預測模式的監督式類神經網路。又在五種監督式類神經網路中，感知機之功能不足而不考慮採用，而機率神經網路僅可進行機率分類問題，亦與本研究之需求不符。學習向量量化網路僅能處理分類問題也與本研究所需不符，故不予採用。就解決問題的精確性而言，倒

傳遞類神經網路優於反傳遞類神經網路，倒傳遞類神經網路雖有學習速率較慢之缺點，但其學習精確度較高，且目前應用範圍最廣，成功案例亦較多，故本研究擬採用倒傳遞類神經網路進行放流水質之預測。

### 3-2 倒傳遞類神經網路

倒傳遞網路是目前各類神經網路模式中被應用得最廣而且最成功的模式。此模式在1974年Werbos的博士論文中被提出，直到1985年Parker再次提出時才漸漸的被廣泛應用。倒傳遞類神經網路是將Widrow-Hoff 學習規則廣義化到多層具非線性可微分轉移函數網路中而創造出來的，倒傳遞網路具有權重值與閾限值，隱藏層可為雙彎曲轉移函數（sigmoid function）或為正切雙彎曲轉移函數（hyperbolic tangent function）。利用已知的輸入向量與其所相對應的輸出向量來訓練此一網路，加上足夠之隱藏層神經元數，則可使網路能逼近任意不連續點的任何函數。

倒傳遞類神經網路演算過程分為學習過程(learning process)及回想過程(recalling process)。其中學習過程包含兩個階段：順向傳遞(forward pass)與逆向傳遞(backward pass)。順向傳遞是從輸入層開始，傳至隱藏層而後至輸出層，一層一層向前傳遞並由非線性轉換函數計算各層處理單元的輸出值，直至網路的最後一層。逆向傳遞則是由輸出層向後傳遞，這一階段在於計算誤差及更新連接權重，其方法是將前層的誤差值向後傳遞(error back-propagation)，並以此為依據修改連接權重，計算該層的誤差，再將其往後傳遞，直到輸入層。此學習過程通常以一次一個訓練範例的方式進行，直到學習完所有的訓練範例，且達到網路收斂為止。至於回想過程則是網路依學習過程中所學習到之連接權重，以輸入向量輸入，推估輸出向量的過程，也稱為預測過程(forecasting process)。倒傳遞神經網路的基本原理則是利用最陡坡降法(gradient steepest descent method)的觀念，將誤差函數予以最小化，同時倒傳遞網路因增加了隱藏層的學習，使得網路可表現輸入處理資料間的交互影響。

### 3-2-1 轉換函數 ( transfer function )

轉換函數其功能在於限制人工神經元的輸出值在某一範圍之內，轉換函數約有以下三種基本型態（羅華強，2001）：

#### 1、雙彎曲轉移函數 ( sigmoid function )

其值域在〔0，1〕之間，其數學式如下

$$\frac{1}{1 + e^{-X}} \quad (3-1)$$

#### 2、正切雙彎曲轉移函數 ( hyperbolic tangent function )

其值域在〔-1，1〕之間，其數學式如下

$$\frac{e^X - e^{-X}}{e^X + e^{-X}} \quad (3-2)$$

#### 3、線性轉移函數 ( linear transfer function )

$$\begin{aligned} 1, X \geq 0 \\ 0, X < 0 \end{aligned} \quad (3-3)$$

### 3-2-2 倒傳遞類神經網路常見問題

倒傳遞網路雖有學習精度高、回想速度快、應用範圍廣等優點，但其應用時所可能遭遇之問題也不少，以下僅針對一般應用時常見之問題及其解決方式分述如下：

#### 一、局部最小值(local minimum)之存在

當訓練過程中均方誤差值停滯於一較預期值大之數值，且呈現上下微幅振盪時，則可能發生最小值問題。由於非線性誤差較線性誤差複雜許多，於多層網路中，可能含有許多局部最小值於誤差曲面中。當在誤差曲面上執行最陡坡降法時，網路所得之最小誤差可能會陷入這些局部最小值內而無法跳出，導致收斂不完善。此現象可藉由重新選擇初始亂數連結權重值，重新訓練網路以確保能獲得最佳解，或加入一隨機動量值修正網路，藉其跳出局部最小值。

## 二、學習速率設定不適當

標準最陡坡降法之學習速率在整個訓練過程中是維持固定不變的。若學習速率設定過大，網路訓練過程可能會不穩定地上下振盪；若學習速率設定過小，則網路可能需花費長時間進行收斂，甚至無法收斂。此時可考慮採用改進式的最陡坡降法，即學習速率於訓練過程中會隨著需要而自動調整，盡可能的大卻又可保持穩定之學習效果，如此即可縮短網路訓練之收斂時間。

## 三、網路無法收斂

導致網路無法收斂之主要原因可能為訓練範例之輸入向量與目標輸出向量間的關聯性不足所致。遇此問題時，應重新考慮倒傳遞類神經網路對於此問題是否適用，並瞭解訓練範例之輸入變數在問題中是否有足夠之代表性、是否有增刪輸入變數的必要。

### 3-3 類神經網路訓練流程

類神經網路中的倒傳遞演算法主要是用一個訓練範例輸入向量  $X$  與目標輸出向量  $T$ ，藉以修正網路權重值  $W$ ，而達到學習的目的。以下用一層隱藏層的類神經網路為例說明類神經網路訓練流程（葉怡成，1999；黃宗仁，2000）：




圖3-1 倒傳遞類神經網路架構

應用訓練範例的輸入神經元的輸入值  $X$ ，計算隱藏層神經元的輸出值  $H$ ，可由以下方程式表示：

$$H_g = F(net_g) = F\left(\sum W_{eg} X_e - \theta_g\right) \quad (3-4)$$

其中  $H_g$  = 隱藏層第  $g$  個神經元輸出值

$F$  = 轉換函數

$W_{eg}$  = 第  $e$  個輸入神經元與第  $g$  個隱藏神經元間之連結權重值

$X_e$  = 第  $e$  個輸入神經元之輸入變數

$\theta_g$  = 第  $g$  個隱藏神經元之閾限值

應用隱藏層神經元的輸出值  $H$ ，計算輸出層神經元的推論輸出值  $Y$ ，可由以下方程式表示：

$$Y_f = F(net_f) = F\left(\sum W_{gf} H_g - \theta_f\right) \quad (3-5)$$

其中  $Y_f$  = 輸出層第  $f$  個神經元之推論輸出值

$F$  = 轉換函數

$W_{gf}$  = 第  $g$  個隱藏神經元與第  $f$  個輸出神經元間之連結權重值

$H_g$  = 隱藏層第  $g$  個神經元輸出值

$\theta_f$  = 第  $f$  個輸出神經元之閾限值

一般以下列能量函數(energy function，或稱誤差函數)表示其學習品質，透過倒傳遞類神經網路之學習過程，能夠降低網路輸出單元之目標輸出值與推論輸出值之差距，可由以下方程式表示：

$$E = \frac{1}{2} \sum (T_f - Y_f)^2 \quad (3-6)$$

其中  $T_f$  = 第  $f$  個輸出神經元之目標輸出值

$Y_f$  = 第  $f$  個輸出神經元之推論輸出值

網路的學習過程即在調整權重值使能量函數往最大梯度方向下降的過程，即每當輸入一訓練範例，網路即小幅調權重值的大小，可由以下方程式表示：

$$\Delta W = -\eta \times \frac{\partial E}{\partial W} \quad (3-7)$$

其中  $\eta$  代表學習速率，意義為修正步幅之大小；較大之  $\eta$  值學習步幅較快，不過容易造成過度學習(overlearning)的情形發生，而較小之  $\eta$  值學習步幅雖然較慢，但可避免過度學習的情形產生。

$W$  會隨著存在不同位置而有不同定義，以下分別敘述隱藏層與輸出層間之連結權重值及輸入層與隱藏層間之連結權重值。

輸入層與隱藏層間之連結權重值：

當  $W_{eg}$  處於輸入層第  $e$  個神經元與隱藏層第  $g$  個神經元間，則可利用微積分學之連鎖律(chain rule)得到下列數值：

誤差量  $\delta$  可由以下方程式表示：

$$\delta_g = \left( \sum_f \delta_f W_{gf} \right) \cdot F'(net_g) \quad (3-8)$$

其中  $\delta_g$  = 第  $g$  個隱藏神經元的誤差量

連結權重值之修正量  $\Delta W$  可由以下方程式表示：

$$\Delta W_{eg} = -\eta \frac{\partial E}{\partial W_{eg}} = \eta \left( \sum_f \delta_f W_{gf} \right) \cdot F'(net_g) \cdot X_e = \eta \cdot \delta_g \cdot X_e \quad (3-9)$$

隱藏神經元之閾限值修正量  $\Delta \theta$  可由以下方程式表示：

$$\Delta \theta_g = -\eta \frac{\partial E}{\partial \theta_g} = -\eta \cdot \delta_g \quad (3-10)$$

隱藏層與輸出層間之連結權重值

當  $W_{gf}$  處於隱藏層第  $g$  個神經元與輸出層第  $f$  個神經元之間，則可利用微積分學之連鎖律(chain rule)得到下列數值：

誤差量  $\delta$  可由以下方程式表示：

$$\delta_f = (T_f - Y_f) \cdot F'(net_f) \quad (3-11)$$

其中  $\delta_f$  = 第  $f$  個輸出神經元的誤差量

連結權重值之修正量  $\Delta W$  可由以下方程式表示：

$$\Delta W_{gf} = -\eta \frac{\partial E}{\partial W_{gf}} = \eta (T_f - Y_f) \cdot F'(net_f) \cdot H_g \quad (3-12)$$

輸出神經元之閾限值修正量  $\Delta \theta$  可由以下方程式表示：

$$\Delta \theta_f = -\eta \frac{\partial E}{\partial \theta_f} = -\eta \cdot \delta_f \quad (3-13)$$

由於計算過程中易落入區域極小值而產生收斂緩慢的缺點，在實際的運用過程通常會加上一個動量修正係數，即加上某比例的上次加權值之修正量以改善收斂過程中的振盪現象，這種學習法則稱為「通用差距法則」(general delta rule)。其加入動量修正係數後上述之權重值修正式為：

$$\Delta W_{gf}(n) = \eta \delta_f H_g + \alpha \Delta W_{gf}(n-1) \quad (3-14)$$

$$\Delta \theta_f(n) = -\eta \delta_f + \alpha \Delta \theta_f(n-1) \quad (3-15)$$

$$\Delta W_{eg}(n) = \eta \delta_g X_e + \alpha \Delta W_{eg}(n-1) \quad (3-16)$$

$$\Delta \theta_g(n) = -\eta \delta_g + \alpha \Delta \theta_g(n-1) \quad (3-17)$$

其中  $\alpha$  = 所加入之慣性因子，用於控制慣性項的比例

$\Delta W_{gf}(n)$  = 權重值  $W_{gf}$  第  $n$  次的修正量

$\Delta W_{gf}(n-1)$  = 權重值  $W_{gf}$  第  $n-1$  次的修正量

$\Delta W_{eg}(n)$  = 權重值  $W_{eg}$  第  $n$  次的修正量

$\Delta W_{eg}(n-1)$  = 權重值  $W_{eg}$  第  $n-1$  次的修正量

$\Delta \theta_f(n)$  = 閾限值  $\theta_f$  第  $n$  次的修正量

$\Delta \theta_f(n-1)$  = 閾限值  $\theta_f$  第  $n-1$  次的修正量

$\Delta \theta_g(n)$  = 閾限值  $\theta_g$  第  $n$  次的修正量

$\Delta \theta_g(n-1)$  = 閾限值  $\theta_g$  第  $n-1$  次的修正量



### 3-4 因子分析

因子分析(factor analysis)是20世紀初期在心理學領域所發展出來的多變量統計技術，最初應用於有關人類行為之研究，再逐漸擴及於社會學、氣象學、政治學、藥學、環境科學、地理學及管理學的領域。因子分析是一種用來篩選多變數的統計方法，其主要目的在以較少的維數(number of dimensions)來表示原先的資料結構，而又能保存原有資料結構所提供的主要資訊。因子分析計有主成份分析法(principal components analysis)、主因子分析法(principal factor analysis)、最大概似法(maximum likelihood method)、因子分析法(alpha factor analysis)、映像因子分析法(image factor analysis)、未加權最小平方法(unweighted least squares)與一般化最小平方法(generalized least squares)等，一般以主成份分析法最被廣泛使用，其運算原理與方法如下所述（黃建源，2000；陳順宇，2001）：

假設資料個數為 $n$ ，原始變量個數為 $q$ ，則基本資料矩陣為：

$$L = \begin{bmatrix} l_{11} & l_{12} & \cdots & l_{1n} \\ l_{21} & l_{22} & \cdots & l_{2n} \\ \cdots & & & \\ l_{q1} & l_{q2} & \cdots & l_{qn} \end{bmatrix}_{q \times n} \quad (3-18)$$

因變數單位不盡相同，為方便計算須先將原始變數標準化，即

$$Z_{vw} = \frac{G_{vw} - \overline{G_v}}{S_v} \quad (v=1, 2, \dots, q; w=1, 2, \dots, n) \quad (3-19)$$

$G_{vw}$ ：為第  $v$  個變數，第  $w$  個樣本的測值

$\overline{G_v}$ ：為第  $v$  個變數的平均值

$S_v$ ：為第  $v$  個變數的標準差

經過標準化後， $Z_{vw}$  的平均值為0，標準差為1，這樣相關矩陣和協方差矩陣會完全一樣。而相關矩陣為：

$$R = \begin{bmatrix} 1 & r_{12} & \cdots & r_{1q} \\ r_{21} & 1 & \cdots & r_{2q} \\ \vdots & \vdots & \ddots & \vdots \\ r_{q1} & r_{q2} & \cdots & 1 \end{bmatrix}_{q \times q} \quad (3-20)$$

其中

$$r_{vw} = \frac{\sum_{k=1}^n (X_{vk} - \bar{X}_v)(X_{wk} - \bar{X}_w)}{\sqrt{\sum_{k=1}^n (X_{vk} - \bar{X}_v)^2 \cdot \sum_{k=1}^n (X_{wk} - \bar{X}_w)^2}} \quad (3-21)$$

由特徵方程式解特徵向量，如下式：

$$|R - \lambda_q| = 0 \quad (3-22)$$

解出之特徵值為  $\lambda_1, \lambda_2, \dots, \lambda_q$ ，且  $\lambda_1 > \lambda_2 > \dots > \lambda_q \geq 0$ 。標準特徵向量為  $U_v$  ( $v=1,2,3,\dots,q$ )，若標準特徵向量等於特徵向量，則特徵向量矩陣為：

$$U = \begin{bmatrix} u_{11} & u_{12} & \cdots & u_{1q} \\ u_{21} & u_{22} & \cdots & u_{2q} \\ \cdots & \cdots & \cdots & \cdots \\ u_{q1} & u_{q2} & \cdots & u_{qq} \end{bmatrix}_{q \times q} \quad (3-23)$$

由主成份分析的原理可知

$$O = U^T Z \quad (3-24)$$

式中  $O$  是一組由原始變量  $L_1, L_2, L_3, L_4, \dots, L_p$  所重新組合彼此互相獨立的新變量矩陣，也就是新選出的主要因子。 $Z$  為經標準化後的標準化矩陣。

將兩邊同乘以  $U$ ，則可改寫為：

$$Z = UO = U_{(1)}U_{(2)} \begin{pmatrix} O_{(1)} \\ O_{(2)} \end{pmatrix} = U_{(1)}O_{(1)} + U_{(2)}O_{(2)} \quad (3-25)$$

在因子分析中，通常只選其中  $m$  個 ( $m < q$ ) 主因子，則  $U_{(1)}O_{(1)}$  代表  $m$  個主因子所能解釋的部分， $U_{(2)}O_{(2)}$  則為殘餘部分，也就是不能解釋的部分。

$$\text{令 } \varepsilon = U_{(2)}O_{(2)} = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \cdots \\ \varepsilon_p \end{pmatrix} \quad (3-26)$$

上式稱為因子模型， $U_{(1)}$  為因子負荷矩陣， $O_{(1)}$  為主要因子， $\varepsilon$  為較難解釋之部分。

式中  $U_{(1)}O_{(1)}$  佔大部分的比例，表示選取的因子可取代原始資料矩陣  $L$  而忽略  $\varepsilon$ ，

亦即選取的因子負荷矩陣具有代表性。

此時因子模型可以寫為（忽略不能解釋的部分）：

$$\begin{cases} L_1 = u_{11}O_1 + u_{12}O_2 + \cdots + u_{1m}O_m \\ L_2 = u_{21}O_1 + u_{22}O_2 + \cdots + u_{2m}O_m \\ \vdots \\ L_q = u_{q1}O_1 + u_{q2}O_2 + \cdots + u_{qm}O_m \end{cases} \quad (3-27)$$

特徵向量  $u_v$  以單位向量表示，進行標準化處理後，即

$$a_{vw} = u_{vw} \sqrt{\lambda_v} \quad (3-28)$$

所以，因子負荷矩陣為：

$$A = (a_{vw}) = \begin{bmatrix} u_{11}\sqrt{\lambda_1} & u_{12}\sqrt{\lambda_2} & \cdots & u_{1q}\sqrt{\lambda_q} \\ u_{21}\sqrt{\lambda_1} & u_{22}\sqrt{\lambda_2} & \cdots & u_{2q}\sqrt{\lambda_q} \\ \cdots & \cdots & \cdots & \cdots \\ u_{q1}\sqrt{\lambda_1} & u_{q2}\sqrt{\lambda_2} & \cdots & u_{qq}\sqrt{\lambda_q} \end{bmatrix} \quad (3-29)$$

因此，因子模型可以改寫為

$$\begin{cases} L_1 = a_{11}O_1 + a_{12}O_2 + \cdots + a_{1m}O_m + a_1\varepsilon_1 \\ L_2 = a_{21}O_1 + a_{22}O_2 + \cdots + a_{2m}O_m + a_2\varepsilon_2 \\ \vdots \\ L_q = a_{q1}O_1 + a_{q2}O_2 + \cdots + a_{qm}O_m + a_q\varepsilon_q \end{cases} \quad (3-30)$$

式中  $O_1, O_2, \dots, O_m$  為共同因子； $a_{vw}$  為因子負荷，即第  $v$  個變量在第  $w$  個主因子上的因子負荷。

### 3-4-1 適合度檢定

對於分析的資料是否適用於因子分析，可用Kaiser-Meyer-Oklin 的抽樣正確量（簡寫為KMO）由偏相關係數來檢定，其定義為：

$$KMO = \frac{\sum \sum_{h \neq c} r_{hc}^2}{\sum \sum_{h \neq c} r_{hc}^2 + \sum \sum_{h \neq c} a_{hc}^2} \quad (3-31)$$

其中  $r_{hc}$  為變數  $h$  與  $c$  之簡單相關係數， $a_{hc}$  為此兩變數之偏相關係數(partial

correlation coefficients)。若所有  $a_{hc}^2$  之和遠小於所有  $r_{hc}^2$  和時，則 KMO 值接近 1，表示這些變數有共同因子存在，可使用因子分析，KMO 值低於 0.5 時，較不宜進行因素分析，其值越大越好，0.8 以上可視為極佳（吳明隆，1999）。

### 3-4-2 因子選取

為達資料精簡之目的，可用較少之主成份因子替代原始龐大的資料結構。因此須選取適當的主成份個數，但目前尚無一定之選取標準。因子選取個數的多寡可由下列方式判定之（黃俊英，1995）：

- (1) 若前  $m$  個最大特徵值之因子變異量總和達全部變異量總和之 80% 以上，即可忽略其他特徵值所造成之影響。
- (2) 以標準化後資料矩陣進行分析，保留特徵值大於 1 以上之主成份因子，特徵值小於 1 則予以刪除。
- (3) 將求得之特徵值由大至小繪製成彎弓型陡坡圖，其曲線底部近似一直線，依尾端趨勢連接此直線，則切線上方之前面較大特徵值即為選用值。
- (4) 若第  $j$  個主成份特徵值之解釋能力低於 5%，其對整體貢獻應視為不顯著，則可予刪除。

### 3-4-3 因子旋轉（factor rotation）

一般求出之因子負荷，因為無法顯著的解釋原變量與因子間的關係，故須對因子負荷進行旋轉，使其平方值向 0 與 1 極化，以利於解釋原變量與因子之關係。本研究採用因子旋轉方式為正交轉軸之最大變異法 (varimax rotation)，其目的在使轉軸後每一個共同因子本身之內的因子負荷量大小相差盡量達最大。利用最大變異法轉軸後所得之因子結構較為簡單，而且容易解釋。

## 第四章 研究方法

本研究採用倒傳遞類神經網路模式，利用污水處理廠每日申報的各項監測、操作參數作為網路訓練輸入變數，針對該污水處理廠隔日放流水 COD 濃度及放流水 SS 濃度作預測。此工業區為綜合工業區，區內主要廠商計有 23 種類別，共 500 餘家。案例污水處理廠為二級生物處理廠+三級化學混凝，每日污水處理量約為 6000CMD。研究中所蒐集之資料為民國 89 年 8 月至 91 年 9 月之每日監測及操作資料。本研究使用之類神經網路軟體為 MATLAB 6.1 版（The Mathworks Inc.）內含之類神經網路工具箱及 SPSS 10.0 版（SPSS Inc.）。研究方法包括輸入向量變數及時間區間、隱藏層層數及隱藏層神經元、資料的前處理、正規化處理及學習法則等，分述如下：

### 4-1 輸入向量變數

建立類神經網路第一個步驟是選擇網路輸入變數，輸入變數的選擇對網路的效能有直接的影響。利用套裝軟體 SPSS 使用因子分析來進行輸入項目的初步篩選。

### 4-2 輸入時間區間

由於污水處理廠的污水處理程序為一連續處理系統，之前之操作狀況會影響之後的處理效果，系統會呈現明顯的時間延遲。依照各單元的水利停留時間以類神經網路比較可能適合的時間區間。

### 4-3 隱藏層層數及隱藏層神經元

通常隱藏層之數目為一到二層時有最好的收斂性，太多層或太少層其收斂結果均較差，因為一層或兩層隱藏層已足以反映問題的輸入單元間的交互作用，更多的隱藏層反而使網路過度複雜，造成更多局部最小值（葉怡成，1999）。在實務運用上，一般性的問題，只要以一層隱藏層搭配足夠的神經元數，就可解決複雜的函數映射問題，除非訓練的範例多，或非線性相關性強，才需以二層的隱藏層來處理（Hornik *et al.*, 1989）。以上說明了一層隱藏層的網路已經可以近似任何連續函數，所以，本研

究將採用一層隱藏層進行運算。

隱藏層神經元數多寡對網路品質影響甚大，隱藏層神經元數目越多，收斂速度越慢，對誤差的降低並無太大的助益；隱藏層神經元數目太少，無法充分反映出輸入-輸出間的交互關係。由於類神經網路為一非線性化過程，且網路參數間會互相影響，故無法找出一絕對之最佳網路參數。一般而言，隱藏層的神經元數選取原則可根據輸入層和輸出層的神經元數作為參考依據（葉怡成，1999）：

#### 1、簡單問題

$$\text{隱藏層神經元數} = (\text{輸入層神經元數} + \text{輸出層神經元數}) \div 2$$

#### 2、一般問題

$$\text{隱藏層神經元數} = (\text{輸入層神經元數} + \text{輸出層神經元數})$$

#### 3、困難問題

$$\text{隱藏層神經元數} = (\text{輸入層神經元數} + \text{輸出層神經元數}) \times 2$$

為了能得到最佳的數值，所以本研究隱藏層神經元數由 1 遞增至 2 倍輸入層神經元數 + 輸出層神經元數，遞增量為 1。

### 4-4 資料的前處理

類神經網路分析之資料必須需為連續且等間距，而污水處理廠監測資料可能會因為一些不可抗拒因素如停電、儀器故障或休假等等因素造成資料的不完整，因此必須填補遺失的數據。在此為了要節省時間及避免資料之消耗，故本研究採用線性內插的方式來填補遺漏。

### 4-5 正規化處理（scaling）

在進行類神經網路的建構之前，所使用的資料需先予以正規化。因為若處理單元所接受的變數之值域變化太大，將可能造成較小值域之變數的重要性會被忽略，而導致整個網路學習由較大值域變數所掌控，進而影響網路學習結果，為了避免這樣的情形，因此需先將變數值域統一。本研究之轉換函數採用正切雙彎曲轉移函數，其值域為 1 和 -1 之間。

#### 4-6 學習速率、學習法則及訓練次數

學習速率的大小就如同行走的步伐大小一般，學習速率過小則網路收斂所需時間過長，並且有可能陷入局部最小值而無法跳出，學習速率過大雖網路收斂之速度越快，但可能因過大而造成無法收斂之問題。為了能得到最佳的數值，所以本研究使用可變學習速率演算法中較精確的 Levenberg-Marguardt 演算法。

本研究使用取提早停止(early stop)學習原則加以預防過度適配(over fitting)的現象，如圖4-1所示。一般而言訓練次數越多，網路收斂之結果越好，惟尚需考慮訓練時間及訓練結果是否會有過度適配(over fitting)的現象。所謂過度適配係指當網路訓練過度時，網路之預測結果將會被強制去符合某一規則作預測，使得預測之結果並非實際之狀況。提早停止(early stop)學習原則即是於過度適配發生前即停止訓練動作，其原則係將部分數據作為驗證組，與訓練組數據同時輸入網路訓練，此時訓練過程將會有兩條收斂曲線，提早停止原則會自動選取兩收斂曲線最接近之時停止網路訓練。




圖4-1 過度學習現象（葉怡成，1999）

#### 4-7 訓練及測試範例

研究中所蒐集之資料為民國 89 年 8 月至 91 年 9 月之每日監測及操作資料，取

89 年 8 月至 91 年 5 月之實測數據為訓練範例，91 年 6 月至 91 年 9 月之實測數據為測試範例。

#### 4-8 網路效能評估

本研究採用之網路效能之評估機制為均方誤差 ( mean square error )，相關係數 ( correlation coefficient )。均方誤差是用來探討函數型問題之網路誤差程度，當 MSE 越趨近於零，則表示模式結果越趨近於真值，均方誤差之公式如式 4-2 所示。相關係數主要是用來表示網路的預測趨勢，可表示輸入值與輸出值之間之趨近程度，當  $r$  值越趨近於 1，則表示其貼近程度越高，相關係數之公式如式 4-3 所示。

$$MSE = \frac{1}{n} \sum_{i=1}^n k_i^2 \quad (4-1)$$

式中

MSE：均方誤差

$n$ ：預測值之個數

$k_i$ ：第  $i$  項之預測值與實際值之差值

$$r = \frac{(\sum T_l Y_l) - n \cdot \mu_d \cdot \mu_x}{(n-1) \cdot \sigma_d \cdot \sigma_x} \quad (4-2)$$

式中

$r$ ：相關係數

$T_l$ ：目標值

$Y_l$ ：網路輸出值

$n$ ：範例數

$\mu_d$ ：目標值平均值

$\mu_x$ ：網路輸出平均值

$\sigma_d$ ：目標值標準差

$\sigma_x$ ：網路輸出值標準差



## 第五章 結果與討論

本研究以倒傳遞類神經網路，針對一工業區污水聯合處理廠之放流水水質濃度進行預測，案例污水處理廠各項監測、操作參數統計如表 5-2 所示。本章茲就類神經網路模式輸入向量變數之篩選、相關時間區間階次之判定、訓練及預測結果加以彙整比較與討論分析。

類神經網路進行的首要步驟是網路輸入變數的選擇，在網路進行篩選時，為了避免篩選工作過於繁複，本研究於篩選前先行決定網路參數的設定，待最適輸入變數選擇決定後，同時進行細部參數的最適化。

### 5-1 活性污泥系統參數之分析

根據圖5-1案例工業區污水處理廠的處理流程，活性污泥系統包含曝氣槽及二沉池兩部份，污水由初沉池放流後進入活性污泥系統後進入三沉池。故活性污泥系統包含的參數有初沉池放流量（曝氣槽進流量）、初沉池放流COD濃度（曝氣槽進流COD濃度）、初沉池放流SS濃度（曝氣槽進流SS濃度）、曝氣槽COD體積負荷、食微比、曝氣槽HRT、MLSS、SVI、DO、SRT、曝氣槽pH值等11項。以此11項參數進行主成分分析，其分析結果如下。

表 5-1 KMO 檢定表

Kaiser-Meyer-Olkin Bartlett 球形檢定	取樣適切性量數	<b>0.697</b>
	近似卡方分配	7950.641
	自由度	55
	顯著性	0.000

由KMO檢定其KMO值，KMO 值低於 0.5 時，表示較不宜進行因素分析（吳明隆，1999）。本研究中之KMO值為 0.697（表5-1），表示數據適合進行因素分析。

表5-2 案例污水處理廠各項監測操作參數統計表

單元	項目	單位	最小值	最大值	平均值	標準差
	廢水進流量	CMD	2067	9967	5245.96	1100.48
	除油池 HRT	hr	0.8	4.1	1.68	0.39
	調勻池 HRT	hr	4.9	23.7	9.78	2.26
初沉池	進流量	CMD	2510	8779	5030.56	958.65
	HRT	hr	2.4	8.5	4.42	0.94
活性 污泥 系統	食微比	-	0.27	1.85	0.88	0.29
	體積負荷	COD/m <sup>3</sup> -D	0.14	1.09	0.48	0.17
	DO	mg/L	0.07	7.10	0.59	0.96
	MLSS	mg/L	1020	5020	2467.48	501.52
	SVI	-	81	415	216.81	61.77
	HRT	hr	5.7	20.1	10.42	2.23
二沉池	HRT	hr	5.9	20.9	10.67	2.29
三沉池	HRT	hr	3.1	9.6	4.81	1.08
SS	進流 SS	mg/L	28	745	151.58	90.95
	調勻槽放流 SS	mg/L	38	760	237.18	123.75
	初沉池放流 SS	mg/L	19	176	77.49	28.78
	二沉池放流 SS	mg/L	3	133	13.56	9.65
	放流 SS	mg/L	2	29	8.05	3.01
COD	進流 COD	mg/L	44	2952	382.46	199.77
	調勻槽放流 COD	mg/L	83	1029	404.46	180.12
	初沉池放流 COD	mg/L	52	397	204.93	66.25
	二沉池放流 COD	mg/L	8	205	70.50	19.38
	放流 COD	mg/L	5	100	64.26	14.97
pH	進流 pH	-	7.2	8.2	7.72	0.16
	調勻槽放流 pH	-	7.0	7.9	7.47	0.14
	初沉池放流 pH	-	6.5	8.7	7.45	0.14
	二沉池放流 pH	-	5.2	7.7	6.77	0.29
	放流 pH	-	6.8	8.3	6.89	0.27
藥品量	PAC	kg	0	496	24.72	104.50
	Polymer	kg	0	48	0.12	2.42
	NaOH	kg	0	360	9.86	47.33
污泥量	初沉池污泥量	Kg/D	0	287	58.05	23.86
	污泥回流量	Kg/D	0	2512	1346.28	171.70
	廢棄污泥量	Kg/D	0	867	56.58	44.76




圖 5-1 案例工業區污水處理廠流程圖

表5-3 各因子特徵值及變異量表

因素	初始特徵值			平方和負荷量萃取			轉軸平方和負荷量		
	總和	變異數%	累積%	總和	變異數%	累積%	總和	變異數%	累積%
1	3.943	35.847	35.847	3.943	35.847	35.847	2.959	26.898	26.898
2	2.232	20.290	56.137	2.232	20.290	56.137	2.136	19.420	46.318
3	1.184	10.767	66.904	1.184	10.767	66.904	1.286	11.687	58.005
4	1.038	9.435	76.339	1.038	9.435	76.339	1.020	9.270	67.276
5	0.847	7.702	84.040						
6	0.777	7.067	91.108						
7	0.611	5.558	96.666						
8	0.235	2.139	98.805						
9	0.083	0.758	99.563						
10	0.037	0.334	99.896						
11	0.011	0.104	100.000						

依據主成份分析的原則選取特徵值大於1之因素，分別為因素1至因素4，其總變異量為76.339%（表5-3）。

表5-4 最大正交旋轉所得之因子負荷量表

	因素			
	1	2	3	4
曝氣槽進流 COD 濃度	0.906	0.173	0.287	0.131
曝氣槽 COD 體積負荷	0.886	-0.311	0.242	0.079
食微比	0.852	-0.243	-0.305	0.048
曝氣槽進流 SS 濃度	0.691	-0.025	0.320	0.127
曝氣槽 HRT	-0.118	0.975	-0.010	0.010
曝氣槽進流量	0.069	-0.971	-0.031	-0.079
MLSS	0.198	0.009	0.960	0.087
SVI	0.153	0.068	0.081	0.979
DO	-0.222	0.045	-0.094	0.059
SRT	-0.079	0.120	-0.107	-0.017
曝氣槽 pH	-0.113	0.188	-0.010	0.049

表 5-4 中以特徵值 1 為分野，取出特徵值大於 1 的因素 1 到 4 等 4 個因素。因素 1 中主要的因子為曝氣槽進流 COD 濃度、曝氣槽 COD 體積負荷、食微比、曝氣槽進流 SS 濃度等，皆為水質因子，因此將因素 1 定義為水質因素。因素 2 中主要的因子為曝氣槽 HRT、曝氣槽進流量等，皆為流量因子，因此將因素 2 定義為水量因素。因素 3 中主要的因子為 MLSS，因此將因素 3 定義為 MLSS 因素。因素 4 中主要的因子為 SVI，因此將因素 4 定義為 SVI 因素。

分別依據其各輸入參數之因子負荷量以及標準化後之各參數進行線性組合，其計算如下：

(1) 因素 1 =  $0.906 \times \text{曝氣槽進流 COD 濃度} + 0.886 \times \text{曝氣槽 COD 體積負荷} + 0.852 \times \text{食微比} + 0.691 \times \text{曝氣槽進流 SS 濃度} - 0.118 \times \text{曝氣槽 HRT} + 0.06908 \times \text{曝氣槽進流量} + 0.198 \times \text{MLSS} + 0.153 \times \text{SVI} - 0.222 \times \text{DO} - 0.07887 \times \text{SRT} - 0.113 \times \text{曝氣槽 pH}$

(2) 因素 2 =  $0.173 \times \text{曝氣槽進流 COD 濃度} - 0.331 \times \text{曝氣槽 COD 體積負荷} - 0.243 \times \text{食微比} - 0.02534 \times \text{曝氣槽進流 SS 濃度} + 0.975 \times \text{曝氣槽 HRT} - 0.971 \times \text{曝氣槽進流量} + 0.008543 \times \text{MLSS} + 0.06789 \times \text{SVI} + 0.04525 \times \text{DO} + 0.12 \times \text{SRT} + 0.188 \times \text{曝氣槽 pH}$

(3) 因素 3 =  $0.287 \times \text{曝氣槽進流 COD 濃度} + 0.242 \times \text{曝氣槽 COD 體積負荷} - 0.305 \times \text{食微比} + 0.32 \times \text{曝氣槽進流 SS 濃度} - 0.00982 \times \text{曝氣槽 HRT} - 0.0308 \times \text{曝氣槽進流量} + 0.96 \times \text{MLSS} + 0.08126 \times \text{SVI} - 0.09389 \times \text{DO} - 0.107 \times \text{SRT} - 0.009825 \times \text{曝氣槽 pH}$

(4) 因素 4 =  $0.131 \times \text{曝氣槽進流 COD 濃度} + 0.07915 \times \text{曝氣槽 COD 體積負荷} + 0.04835 \times \text{食微比} + 0.127 \times \text{曝氣槽進流 SS 濃度} + 0.0102 \times \text{曝氣槽 HRT} - 0.07785 \times \text{初沉池放流量} + 0.08664 \times \text{MLSS} + 0.979 \times \text{SVI} + 0.05885 \times \text{DO} + 0.01691 \times \text{SRT} + 0.04877 \times \text{曝氣槽 pH}$

## 5.2 活性污泥系統放流水質預測

經由主成分分析進行活性污泥系統各項參數的分析得到 4 個因素-水質因素、水量因素、MLSS 因素、SVI 因素進行活性污泥系統類神經網路運作。活性污泥系統平均水利停留時間為 19.79 小時，較為接近 24 個小時，因此本研究由放流點向前推算，取時間 t-1 之水質因素、水量因素、MLSS 因素、SVI 因素等四項輸入進行時間 t 之活性污泥系統放流水質 COD 濃度之預測。神經元數的測試範圍由 1 個神經元測試至 (輸入神經元數+輸出神經元數) × 2 個神經元數。網路使用可變學習速率以及及早停止法則進行。由於類神經網路每次訓練結果可能不盡相同，故每個網路進行 3 次重複訓練

取其最佳 test-R 值，其網路規劃如下：

隱藏層層數：1 層

隱藏層神經元數目：1~(輸入神經元數+輸出神經元數)×2 個，儲存各最佳網路模式

梯度下降演算法：Levenberg-Marguardt

訓練範例：取 89 年 8 月至 91 年 5 月之實測數據

測試範例：取 91 年 6 月至 91 年 9 月之實測數據

表 5-5 活性污泥系統放流水 COD 濃度預測隱藏層神經元數測試結果

隱藏層神經元數	train-MSE	train-R	test-R
1	0.0332	0.1877	0.1163
2	0.0318	0.3576	0.3148
3	0.0894	0.4813	0.2571
4	0.0311	0.3742	0.3017
<b>5</b>	<b>0.0294</b>	<b>0.4536</b>	<b>0.3557</b>
6	0.0267	0.5726	0.2325
7	0.0299	0.3735	0.3029
8	0.0274	0.4061	0.3302
9	0.0297	0.1622	0.1722
10	0.0260	0.4391	0.2950
平均值	0.0355	0.3808	0.2678

由表 5-5 得知活性污泥系統放流水 COD 濃度預測網路最佳隱藏層神經元數為 5 個，train-MSE 值為 0.0294，train-R 為 0.4536，test-R 值為 0.3557，網路之散佈、訓練及預測如圖 5-2~5-5 所示。由於預測效能欠佳，因此擬加入活性污泥系統之前的各處理單元水質參數做為網路輸入項目，以活性污泥系統放流水質 COD 濃度為預測項目進行二級處理的放流水質預測。

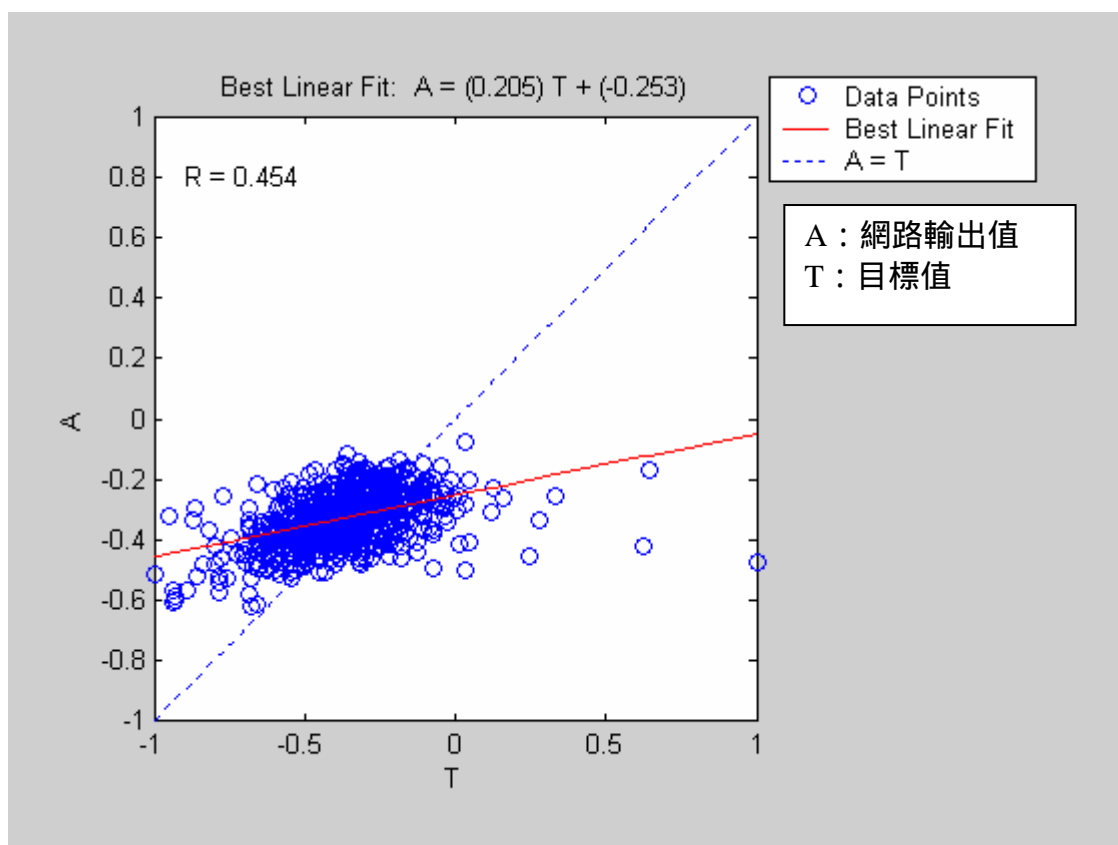


圖 5-2 活性污泥系統放流水 COD 濃度網路訓練散佈圖




圖 5-3 活性污泥系統放流水 COD 濃度網路預測散佈圖




圖 5-4 活性污泥系統放流水 COD 濃度網路訓練圖



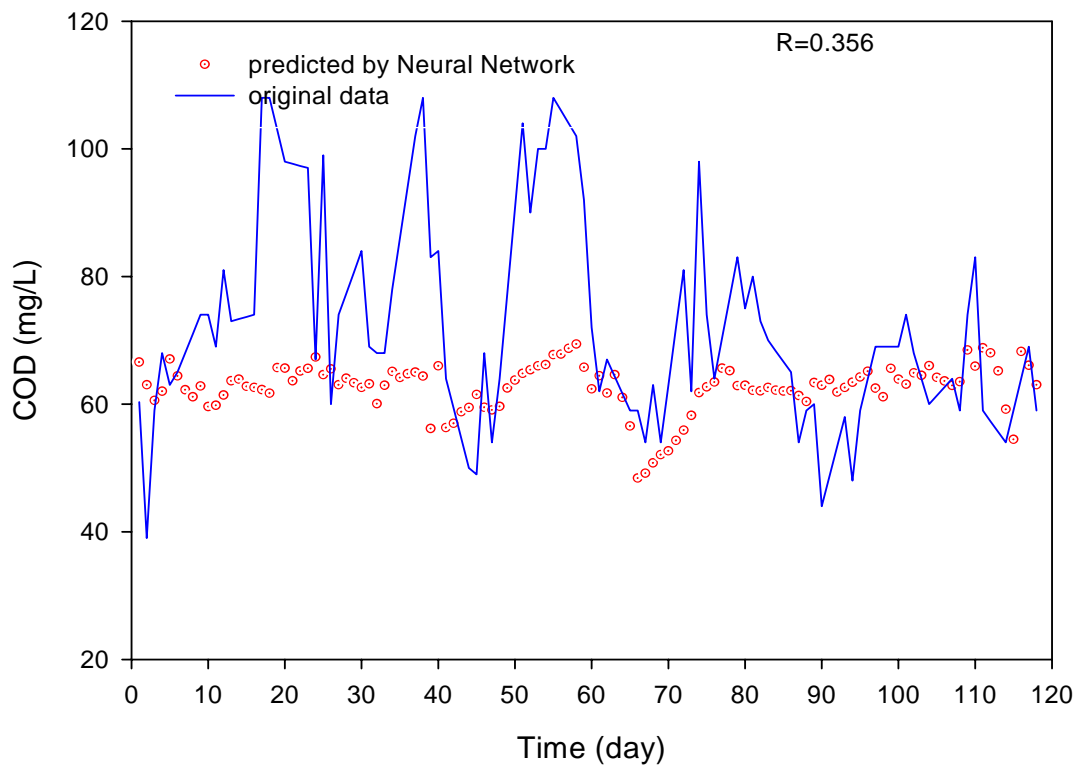


圖 5-5 活性污泥系統放流水 COD 濃度網路預測圖

污水自進流至活性污泥系統放流平均水力停留時間為 37 小時，較為接近 48 個小時；由排放點向前推算初沉池進流時間為二沉池平均停留時間 10.67 小時+曝氣池平均停留時間 10.42 小時+初沉池平均停留時間 4.42 小時=25.51 小時以前，較為接近 24 個小時；曝氣池進流時間為二沉池平均停留時間 10.67 小時+曝氣池平均停留時間 10.42 小時=21.09 小時以前，較為接近 24 個小時。因此本研究以時間  $t-2$  之進流量、時間  $t-2$  之進流 SS 濃度、時間  $t-2$  之進流 COD 濃度、時間  $t-1$  之初沉池進流 SS 濃度、時間  $t-1$  之初沉池進流 COD 濃度、時間  $t-1$  之水質因素、時間  $t-1$  之水量因素、時間  $t-1$  之 MLSS 因素、時間  $t-1$  之 SVI 因素等九個輸入項目進行時間  $t$  之放流水質 COD 濃度之預測。其網路規劃如下：

隱藏層層數：1 層

隱藏層神經元數目：1~(輸入神經元數+輸出神經元數)×2 個，儲存各最佳網路模式

梯度下降演算法：Levenberg-Marguardt

訓練範例：取 89 年 8 月至 91 年 5 月之實測數據

測試範例：取 91 年 6 月至 91 年 9 月之實測數據

表 5-6 二級處理 9 個輸入項放流水 COD 濃度預測隱藏層神經元數測試結果

隱藏層神經元數	train-MSE	train-R	test-R
1	0.0317	0.4561	0.2391
2	0.0296	0.4930	0.3074
3	0.0290	0.4974	0.2253
4	0.0267	0.5390	0.1862
5	0.0242	0.5836	0.2652
6	0.0241	0.5884	0.3291
<b>7</b>	<b>0.0247</b>	<b>0.4064</b>	<b>0.4296</b>
8	0.0213	0.6605	0.3615
9	0.0241	0.5148	0.3229
10	0.0209	0.5627	0.2865
11	0.0217	0.4794	0.2702
12	0.0179	0.6857	0.2087
13	0.0216	0.2766	0.2822
14	0.0224	0.5126	0.4135
15	0.0174	0.6862	0.2942
16	0.0213	0.4543	0.2760
17	0.0207	0.6210	0.2533
18	0.0213	0.3556	0.3540
19	0.0200	0.5809	0.2551
20	0.0281	0.2933	0.2804
平均值	0.0234	0.5124	0.2920

由表 5-6 得二級處理放流水 COD 濃度預測網路最佳隱藏層神經元數為 7 個，train-MSE 值為 0.0247，train-R 為 0.4064，test-R 值為 0.4296。以下嘗試於輸入項中再加入進流 pH、初沉池進流 pH 等兩項，以時間 t-2 之進流量、時間 t-2 之進流 SS 濃度、時間 t-2 之進流 COD 濃度、時間 t-2 之進流 pH、時間 t-1 之初沉池進流 SS 濃度、時間 t-1 之初沉池進流 COD 濃度、時間 t-1 之初沉池進流 pH、時間 t-1 之水質因素、時間 t-1 之水量因素、時間 t-1 之 MLSS 因素、時間 t-1 之 SVI 因素等 11 個輸入項目進行時間 t 之放流水質 COD 濃度之預測，以期能有更好之成效。

表 5-7 二級處理 11 個輸入項放流水 COD 濃度預測隱藏層神經元數測試結果

隱藏層神經元數	train-MSE	train-R	test-R
1	0.0308	0.4855	0.2411
2	0.0306	0.2573	0.2087
3	0.0249	0.6066	0.3852
4	0.0279	0.5373	0.3261
5	0.0251	0.4928	0.2979
6	0.0275	0.3776	0.3187
7	0.0203	0.6895	0.2612
8	0.0221	0.5837	0.2492
9	0.0210	0.4612	0.2012
10	0.0199	0.2628	0.2911
11	0.0197	0.6818	0.2871
12	0.0177	0.3566	0.2206
13	0.0196	0.4524	0.3514
14	0.0210	0.5793	0.3191
15	0.0156	0.7365	0.2356
<b>16</b>	<b>0.0172</b>	<b>0.4539</b>	<b>0.4325</b>
17	0.0172	0.3679	0.2749
18	0.0148	0.5411	0.2173
19	0.0226	0.4828	0.3089
20	0.0139	0.7253	0.2529
21	0.0136	0.6109	0.2169
22	0.0134	0.6962	0.2747
23	0.0153	0.3968	0.3304
24	0.0134	0.5705	0.4003
平均值	0.0202	0.5170	0.2876

二級處理放流水 COD 濃度預測網路在加入進流 pH、初沉池進流 pH 兩項後，由表 5-6 及 5-7 中得知加入 pH 項目後，對於 train-data 的部份效能有些許的提升，但對於 test-data 的部份平均而言沒有什麼幫助。二級處理放流水 COD 濃度預測網路最佳模式出現在 11 個輸入項模式中，最佳隱藏層神經元數為 16 個，train-MSE 值為 0.0172，train-R 為 0.4539，test-R 值為 0.4325，網路之散佈、訓練及預測如圖 5-6~5-9 所示。




圖 5-6 二級處理放流水 COD 濃度網路訓練散佈圖

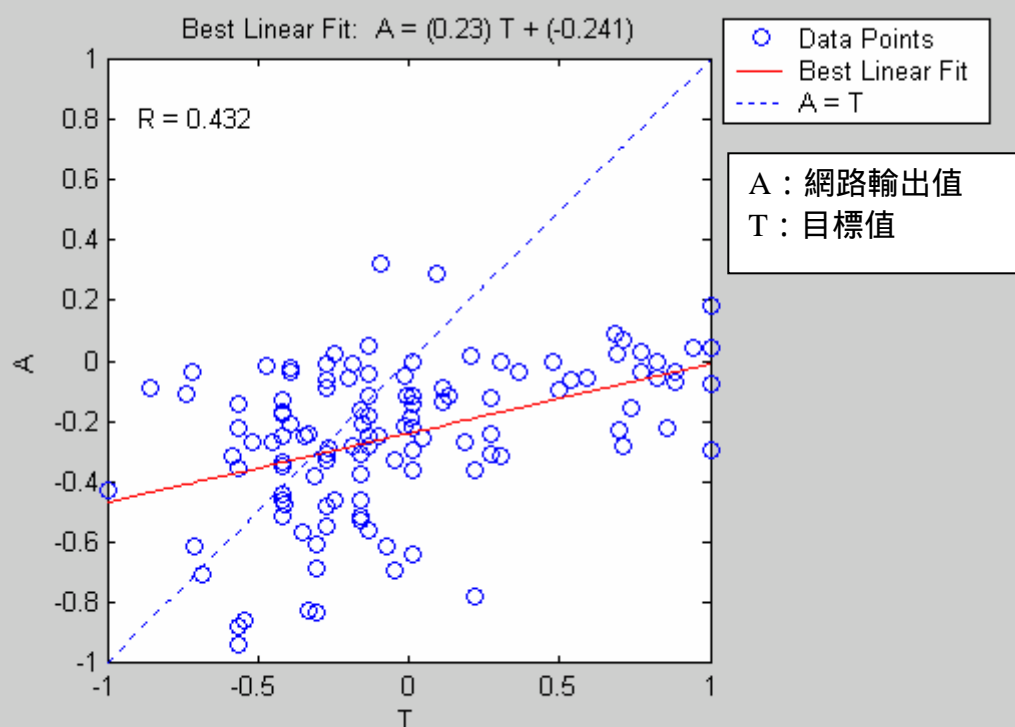


圖 5-7 二級處理放流水 COD 濃度網路預測散佈圖




圖 5-8 二級處理放流水 COD 濃度網路訓練圖

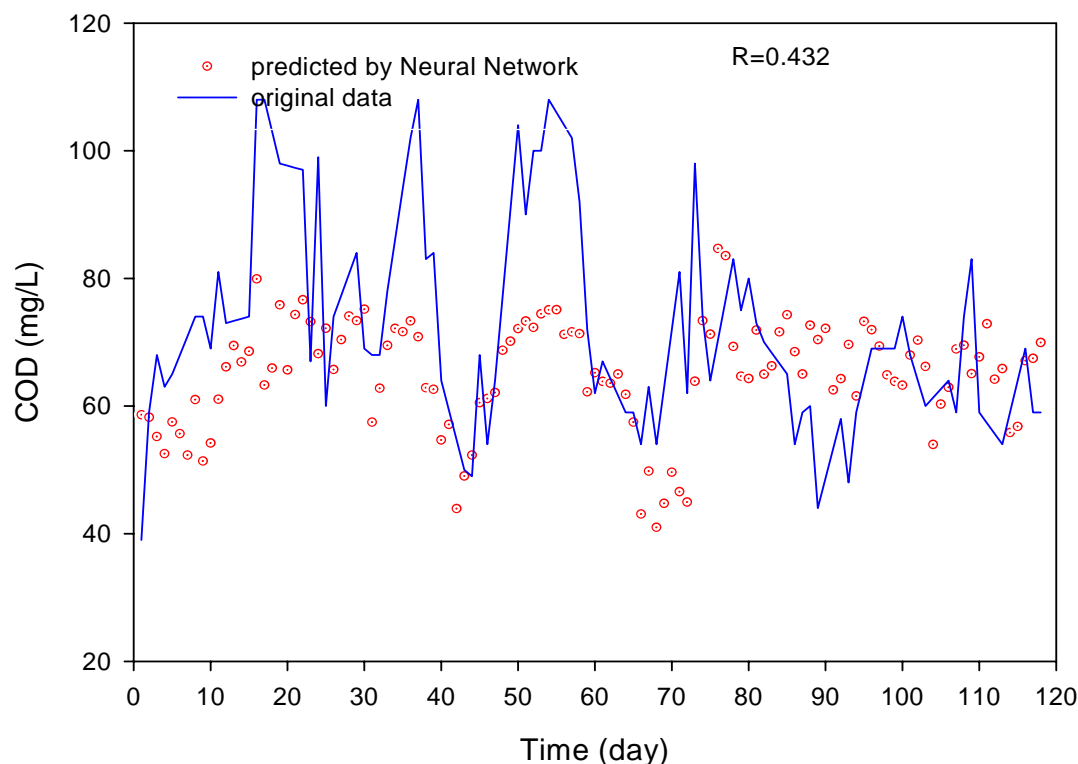


圖 5-9 二級處理放流水 COD 濃度網路預測圖

### 5.3 整體污水處理廠放流水質預測

污水處理場平均水力停留時間為 42 小時，較為接近 48 個小時；由排放點向前推算初沉池進流時間為三沉池平均停留時間 4.81 小時+二沉池平均停留時間 10.67 小時+曝氣池平均停留時間 10.42 小時+初沉池平均停留時間 4.42 小時=30.32 小時以前，較為接近 24 個小時；曝氣池進流時間為三沉池平均停留時間 4.81 小時+二沉池平均停留時間 10.67 小時+曝氣池平均停留時間 10.42 小時=25.9 小時以前，較為接近 24 個小時；三沉池進流時間為三沉池平均停留時間 4.81 小時以前，小於 12 個小時。因此本研究以時間  $t-2$  之進流量、時間  $t-1$  之初沉池進流 SS 濃度、時間  $t-1$  之初沉池進流 COD 濃度、時間  $t-1$  之水質因素、時間  $t-1$  之水量因素、時間  $t-1$  之 MLSS 因素、時間  $t-1$  之 SVI、時間  $t$  之三沉池進流 SS 濃度、時間  $t$  之三沉池進流 COD 濃度等 9 個輸入項目進行時間  $t$  之放流水質 COD 濃度之預測，其網路規劃如下：

隱藏層層數：1 層

隱藏層神經元數目：1~(輸入神經元數+輸出神經元數)×2 個，儲存各最佳網路模式

梯度下降演算法：Levenberg-Marguardt

訓練範例：取 89 年 8 月至 91 年 5 月之實測數據

測試範例：取 91 年 6 月至 91 年 9 月之實測數據

表 5-8 整廠 9 個輸入項放流水 COD 濃度預測隱藏層神經元數測試結果

隱藏層神經元數	train-MSE	train-R	test-R
1	0.0291	0.4536	0.5839
2	0.0289	0.6934	0.4885
3	0.0254	0.7392	0.4602
4	0.0243	0.7190	0.4996
5	0.0249	0.8409	0.6953
6	0.0256	0.7394	0.4180
7	0.0235	0.6655	0.5724
8	0.0200	0.8105	0.5594
9	0.0208	0.8189	0.6723
<b>10</b>	<b>0.0197</b>	<b>0.7250</b>	<b>0.6831</b>
11	0.0193	0.8324	0.6207
12	0.0200	0.8118	0.4687
13	0.0187	0.8545	0.4463
14	0.0182	0.8786	0.4393
15	0.0234	0.8594	0.6270
16	0.0181	0.7991	0.4188
17	0.0155	0.8795	0.5220
18	0.0139	0.9074	0.4464
19	0.0165	0.4707	0.6650
20	0.0171	0.7666	0.5399
平均值	0.0211	0.7633	0.5413

由表 5-8 得整廠放流水 COD 濃度預測網路最佳隱藏層神經元數為 10 個，train-MSE 值為 0.0197，train-R 為 0.7250，test-R 值為 0.6831。以下嘗試於輸入項中再加入初沉池進流 pH、三沉池進流 pH 等兩項，時間 t-2 之進流量、時間 t-1 之初沉池進流 SS 濃度、時間 t-1 之初沉池進流 COD 濃度、時間 t-1 之初沉池進流 pH、時間 t-1 之水質因素、時間 t-1 之水量因素、時間 t-1 之 MLSS 因素、時間 t-1 之 SVI、時間 t 之三沉池進流 SS 濃度、時間 t 之三沉池進流 COD 濃度、時間 t 之三沉池進流

pH 等 11 個輸入項目進行時間  $t$  之整廠放流水質 COD 濃度之預測，以期能有更好之成效。

表 5-9 整廠 11 個輸入項放流水 COD 濃度預測隱藏層神經元數測試結果

隱藏層神經元數	train-MSE	train-R	test-R
1	0.0291	0.6430	0.6610
2	0.0280	0.7105	0.5151
3	0.0261	0.7064	0.6000
4	0.0228	0.8485	0.5999
5	0.0215	0.8392	0.5792
6	0.0208	0.7552	0.4847
7	0.0188	0.8891	0.6358
<b>8</b>	<b>0.0190</b>	<b>0.6386</b>	<b>0.7095</b>
9	0.0217	0.4087	0.5384
10	0.0236	0.7538	0.5530
11	0.0204	0.6606	0.5020
12	0.0218	0.8313	0.5694
13	0.0153	0.8857	0.5711
14	0.0178	0.5435	0.5638
15	0.0152	0.8436	0.4928
16	0.0182	0.6785	0.4826
17	0.0146	0.9007	0.6814
18	0.0145	0.7294	0.6411
19	0.0154	0.5936	0.6386
20	0.0147	0.6223	0.6795
21	0.0175	0.5733	0.6525
22	0.0191	0.7746	0.6385
23	0.0170	0.7125	0.6237
24	0.0245	0.4295	0.4862
平均值	0.0199	0.7072	0.5875

整廠放流水 COD 濃度預測網路在加入初沉池進流 pH、三沉池進流 pH 兩項後，由表 5-8 及 5-9 中得知加入 pH 項目後，對於 test-data 的部份效能有些許的提升，以最佳值和平均值而言都沒有顯著的提升。整廠放流水 COD 濃度預測網路最佳模式出現在 11 個輸入項模式中，最佳隱藏層神經元數為 8 個，train-MSE 值為 0.0190，train-R 為 0.6386，test-R 值為 0.7095，網路之散佈、訓練及預測如圖 5-10~5-13 所示。






圖 5-10 污水處理廠放流水 COD 濃度網路訓練散佈圖




圖 5-11 污水處理廠放流水 COD 濃度網路預測散佈圖

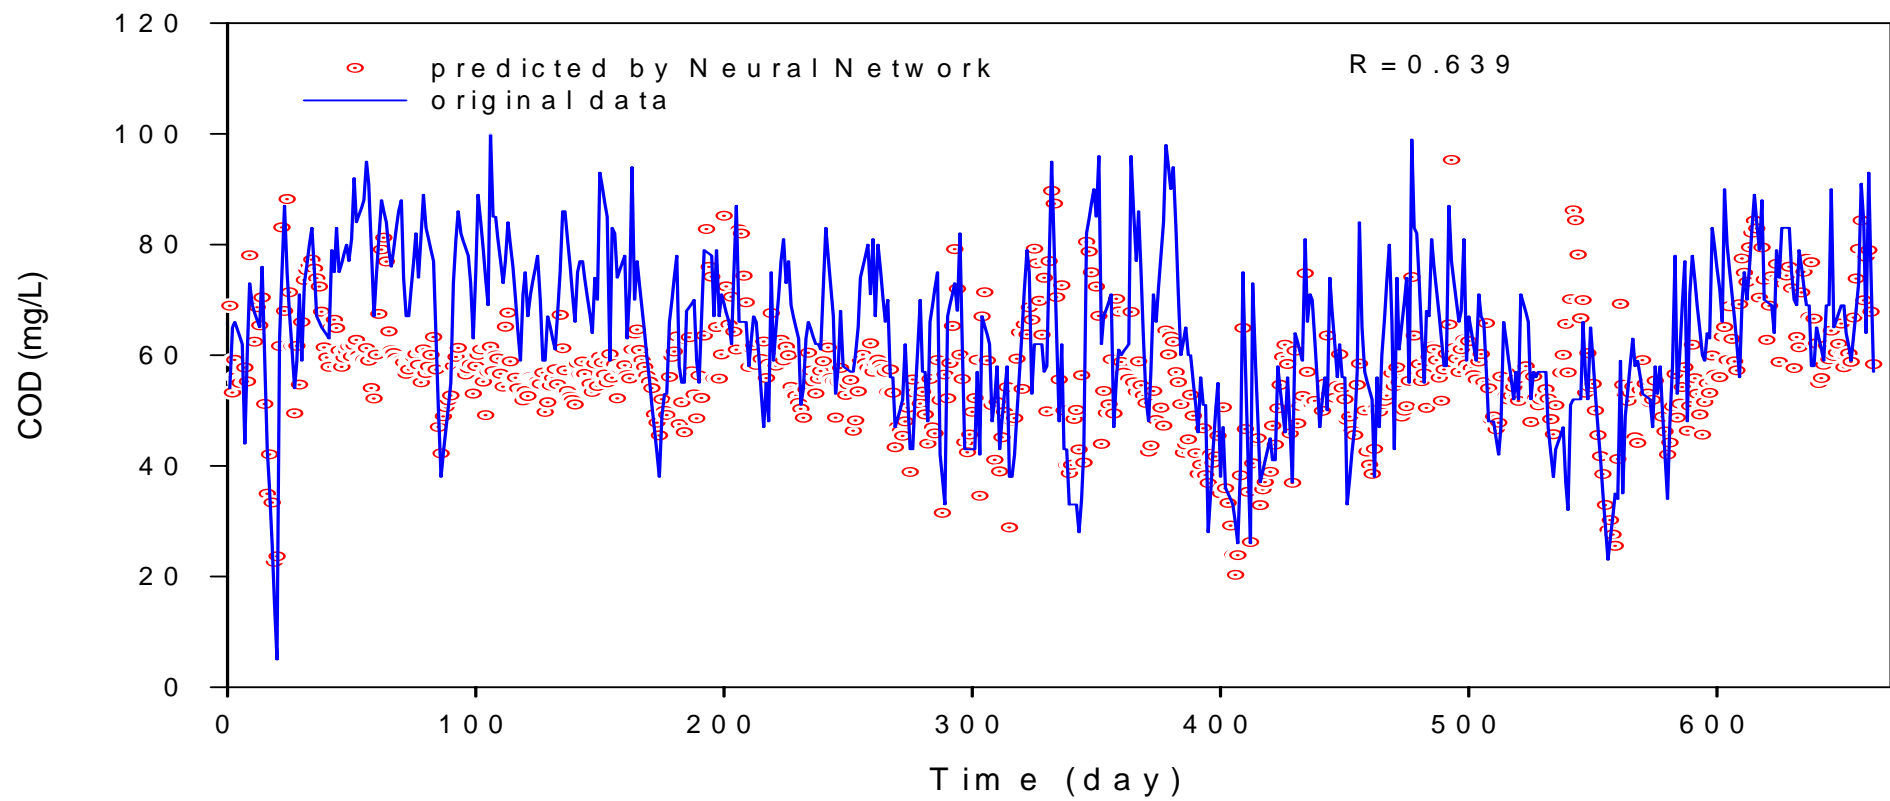


圖 5-12 污水處理廠放流水 COD 濃度網路訓練圖




圖 5-13 污水處理廠放流水 COD 濃度網路預測圖

#### 5.4 網路效能比較及改善測試

本研究活性污泥系統放流水質之預測輸入項目為時間  $t-1$  之水質因素、水量因素、MLSS 因素、SVI 因素等，最佳隱藏層神經元數為 5 個，train-MSE 值為 0.0294，train-R 為 0.4536，test-R 值為 0.3557，由於效能明顯不佳，因此再加入活性污泥系統之前的各處理單元水質參數，以時間  $t-2$  之進流量、時間  $t-2$  之進流 SS 濃度、時間  $t-2$  之進流 COD 濃度、時間  $t-2$  之進流 pH、時間  $t-1$  之初沉池進流 SS 濃度、時間  $t-1$  之初沉池進流 COD 濃度、時間  $t-1$  之初沉池進流 pH、時間  $t-1$  之水質因素、時間  $t-1$  之水量因素、時間  $t-1$  之 MLSS 因素、時間  $t-1$  之 SVI 因素等 11 個輸入項目進行時間  $t$  之二級處理放流水質 COD 濃度之預測，最佳隱藏層神經元數為 16 個，train-MSE 值為 0.0172，train-R 為 0.4539，test-R 值為 0.4325。

施東河等, (1997) 以活性污泥模廠資料進行類神經網路放流水SS濃度之預測, 每30分鐘監測1筆數據, 所使用之輸入變數包含進流量 ( $t$ 、 $t-3$ ) MLSS濃度 ( $t-2$ ) 迴流污泥濃度 ( $t$ ) 迴流污泥量 ( $t-1$ ) 進流水COD濃度 ( $t$ 、 $t-1$ ) 放流水SS濃度 ( $t$ 、 $t-1$ 、 $t-4$ ) 等, 得到網路測試R值為0.76的預測結果。Tomida *et al.*, (1999) 預測活性污泥處理模場之放流水COD濃度, 每小時監測1筆數據, 以曝氣槽進流水COD濃度, 操作運轉時間, 曝氣槽HRT及放流水溫度等四項作為輸入項, 得到平均誤差為5.5%的預測結果。Belanche *et al.*, (1999) 使用類神經網路以模廠進行放流水COD濃度之預測, 所使用之輸入變數包含進流流量、迴流流量、廢棄污泥量、曝氣槽曝氣量、進流水COD濃度、進流水BOD濃度、進流水TSS濃度、放流水COD濃度及放流水BOD濃度等, 得到的預測結果幾乎都在95%的區間內。Tay *et al.*, (2000) 以厭氧處理單元資料分別進行類神經網路 volumetric methane production rate (VMP,  $\text{Ch}_4/\text{l-d}$ ) ( $t$ ) total organic carbon (TOC,  $\text{mg/l}$ ) ( $t$ ) volatile fatty acid (VFA,  $\text{mg/l}$ ) ( $t$ ) 之預測, 使用之輸入變數包含organic loading rate (OLR,  $\text{gTOC/l-d}$ ) ( $t-1$ ) hydraulic loading rate (HLR,  $\text{l/l-d}$ ) ( $t-1$ ) alkalinity loading rate (ALR,  $\text{g/l-d}$ ) ( $t-1$ ) VMP ( $\text{Ch}_4/\text{l-d}$ ) ( $t-1$ ) TOC ( $\text{mg/l}$ ) ( $t-1$ ) VFA ( $\text{mg/l}$ ) ( $t-1$ ) 等, 得到測試R值皆在0.9以上的預測結果。何佳祥等, 2002 以上流式厭氧污泥床單元資料進行類神經網路放流水COD濃度之預測, 預測結果以自身預測之效果最佳, 輸入時間區間以 $t \sim t-4$ 為最適當, 當輸入變數含放流水COD濃度時, 得到測試R值皆在0.9以上。與上述各系統單元放流水質預測之文獻相比較, 本研究之單元網路預測效能較為低落。

本研究污水廠整體放流水質之預測以時間 $t-2$ 之進流水量、時間 $t-1$ 之初沉池進流SS濃度、時間 $t-1$ 之初沉池進流COD濃度、時間 $t-1$ 之初沉池進流pH、時間 $t-1$ 之水質因素、時間 $t-1$ 之水量因素、時間 $t-1$ 之MLSS因素、時間 $t-1$ 之SVI、時間 $t$ 之三沉池進流SS濃度、時間 $t$ 之三沉池進流COD濃度、時間 $t$ 之三沉池進流pH等11個輸入項目進行時間 $t$ 之整廠放流水質COD濃度之預測, 最佳隱藏層神經元數為8個, train-MSE值為0.0190, train-R為0.6386, test-R值為0.7095。

陳清暉，(1999)使用類神經網路以污水處理廠實際日監測資料進行放流水質SS濃度預測，經網路反覆比對後以輸入項為放流水SS濃度( $t-t-4$ )、進流水SS濃度( $t-t-4$ )、進流水pH( $t-t-4$ )等之結果最佳，得到網路測試R值為0.614的預測結果。Wan *et al.*, (2000)使用類神經網路以污水處理廠實際日監測資料進行放流水質SS濃度預測，輸入項為廢水進流量、進流SS濃度、進流BOD濃度、進流BOD濃度、進流COD濃度、進流pH、HRT、食微比、MLSS、DO、RES、RESC、放流SS濃度等，得到測試識別率為75%的預測結果。與上述各污水處理整廠放流水質預測之文獻相比較，本研究之網路有與之相比不遜色的預測能力。

綜合歷來以放流水質作為預測項目文獻，本研究進行檢討與修正。Choi *et al.*, (2001)以模廠之活性污泥系統實際比較直接以參數群作為輸入的類神經網路預測(ANN)與經PCA合成後之參數進行類神經網路預測(PCA+ANN)，結果顯示(ANN)在train-data的部份能較逼近實際值，在test-data的部份(PCA+ANN)則有較佳的預測結果，(PCA+ANN)之效能已被證實。本研究使用工業區聯合污水處理廠之日操作監測資料作為數據來源進行類神經網路之預測，工業區聯合污水處理廠易受廠區內之工廠產品特性、製程原料以及其產銷淡旺季之影響，使得水質、水量、操作、處理等更加繁雜。陳清暉，(1999)、魏維國，(2000)同樣使用聯合工業區污水處理廠日操作監測資料作為數據來源，其中陳清暉，(1999)使用經過比對挑選的12個輸入項進行放流水質之預測，預測的精確度與本研究相仿。魏維國，(2000)以工程實務的角度出發，以曝氣池及二沉池之操作參數MLSS、F/M、HRT、表面溢流率及進流COD及SS水質濃度進行生物處理單元COD去除率預測，其test  $R^2$ 值為0.0234。以進流量、進流COD及SS水質濃度、調整池出流量、調整池出流COD及SS濃度、初沉池表面負荷率、生物處理程序之MLSS、F/M、HRT、表面溢流率、三級化學處理之PAC加藥量、三沉池表面溢流率、快濾之濾速等14個輸入項進行放流水COD濃度之預測，其test  $R^2$ 值為0.2087。

由於(PCA+ANN)之效能經實際驗證後已被證實，使用於聯合工業區污水處理廠之活性污泥系統上進行類神經網路整廠放流水濃度之預測，相較於其他同性質之文獻，已有不錯之預測能力。活性污泥系統部分，本研究使用(PCA+ANN)進行活性

污泥系統放流水質預測，所得到最佳test-R值僅0.3557，在加入活性污泥系統之前的各處理單元水質參數共計11項參數所得到最佳test-R值也只提昇至0.4325，然而在整廠放流水濃度之預測最佳test-R值可達0.7095，魏維國，（2000）也遇見同樣的問題，在生物處理程序中類神經網路無法進行有效推估，在整廠放流的部份網路表現較佳。推測可能原因為工業區聯合污水處理廠每日進流水組成皆不相同，其中也可能包含毒性物質無法掌控，造成活性污泥系統生物處理受影響，因此處理效果差距甚大。由於在實際的使用上預測之精確度不足，因此再比較歸納出下述可能改善本研究放流水質預測效能的方式：

#### 一、精確的相關輸入時間：

由於本研究採用聯合工業區污水處理廠的日監測資料進行放流水質預測，例行一天進行一筆的數據檢測，為配合污水處理廠實際上的使用，故只使用比較接近的相關輸入時間，無法使用較精確的相關輸入時間。

#### 二、使用可能的相關輸入時間共同進行類神經網路預測：

本研究依據各處理單元之水利停留時間判定影響放流水質的相關時間區段，並非直接依據網路運算結果，且若將所有時間階次共同進行類神經網路運算，將造成網路結構過於龐大，將失去主成份分析精簡輸入參數的意義。

#### 三、輸入變數中加入預測項目之自身歷史值：

以放流水質作為預測項目文獻中，施東河等，（1997）Belanche *et al.*,（1999）、陳清暉，（1999）、Wan *et al.*,（2000）、Tay *et al.*,（2000）、何佳祥等，（2002）皆使用預測項目之自身歷史值作為輸入項目之一，何佳祥等，（2002）指出預測結果以自身預測之效果最佳。此外類神經網路之文獻中林逸塵，（2002）實際比較網路輸入含自身歷史值與否之差異，提出自身歷史值為不可忽略的重要變數。簡家宏，（2004）認為向後預測的類神經網路中，自身的歷史值參數是類神經網路輸入變數中最為重要，也是影響最大的項目。為能提高網路預測效能，嘗試於輸入變數中加入預測項目之自身歷史值。

#### 5.4-1 活性污泥系統放流水質預測效能改善測試

本研究依據5.2節中活性污泥系統放流水質預測網路所使用的時間 $t-1$ 之水質因素、水量因素、MLSS因素、SVI因素等及時間 $t-1$ 之活性污泥系統放流水COD濃度自身歷史值等五項輸入進行時間 $t$ 之活性污泥系統放流水質COD濃度之預測。神經元數的測試範圍由1個神經元測試至（輸入神經元數+輸出神經元數） $\times 2$ 個神經元數。網路使用可變學習速率及及早停止法則進行。由於類神經網路每次訓練結果不盡相同，故每個網路進行3次重複訓練取其最佳test-R值，其網路規劃如下：

隱藏層層數：1層

隱藏層神經元數目：1~（輸入神經元數+輸出神經元數） $\times 2$ 個，儲存各最佳網路模式。

梯度下降演算法：Levenberg-Marguardt

訓練範例：取89年8月至91年5月之實測數據

測試範例：取91年6月至91年9月之實測數據

表 5-10 含自身項活性污泥系統放流水 COD 濃度預測隱藏層神經元數測試結果

隱藏層神經元數	train-MSE	train-R	test-R
1	0.0198	0.7144	0.7278
2	0.0187	0.7285	0.7279
<b>3</b>	<b>0.0189</b>	<b>0.7274</b>	<b>0.7342</b>
4	0.0182	0.7407	0.6097
5	0.0179	0.7462	0.7032
6	0.0173	0.7349	0.7085
7	0.0184	0.7087	0.6885
8	0.0177	0.7275	0.6439
9	0.0165	0.6776	0.6722
10	0.0171	0.7221	0.6261
11	0.0160	0.7513	0.6710
12	0.0168	0.5433	0.7177

由表 5-10 得知，含自身項活性污泥系統放流水 COD 濃度類神經網路與表 5-5 所示之不含自身項活性污泥系統放流水 COD 濃度類神經網路相比較，在不同隱藏層神經元數的表現不論是在 train-data 的部份或 test-data 的部份，含自身項活性污泥系統放流水 COD 濃度類神經網路皆優於不含自身項活性污泥系統放流水 COD 濃度類神經網路。網路最佳隱藏層神經元數為 3 個，train-MSE 值為 0.0189，train-R 為 0.7274，test-R 值為 0.342，網路之散佈、訓練及預測如圖 5-14~5-17 所示。




圖 5-14 污水處理廠放流水 COD 濃度含自身項網路訓練散佈圖






圖 5-15 污水處理廠放流水 COD 濃度含自身項網路訓練圖




圖 5-16 污水處理廠放流水 COD 濃度含自身項網路預測散佈圖




圖 5-17 污水處理廠放流水 COD 濃度含自身項網路預測圖

本研究是以活性污泥系統各項操作及監測參數進行因子分析，取特徵值大於 1 的因素依據各因子負荷量使用線性組合出新的參數，所選取出之水質因素、水量因素、MLSS 因素、SVI 因素等 4 個因素可解釋總變異百分比為 76.339%，為印證此 4 個因素足以表達活性污泥系統各項操作及監測參數所呈現的意義，本研究進一步以時間 t-1 之水質因素、水量因素、MLSS 因素、SVI 因素，再加入時間 t-1 之活性污泥系統放流水質 SS 濃度自身歷史值進行時間 t 之活性污泥系統放流水質 SS 濃度之類神經網路測試，其網路規劃如下：

神經元數的測試範圍由 1 個神經元測試至 (輸入神經元數+輸出神經元數)×2 個神經元數。網路使用可變學習速率及及早停止法則進行，每個網路進行 3 次重複訓練取其最佳 test-R 值，其網路規劃如下：

隱藏層層數：1 層

隱藏層神經元數目：1~ (輸入神經元數+輸出神經元數)×2 個，儲存各最佳網路模式

梯度下降演算法：Levenberg-Marguardt

訓練範例：取 89 年 8 月至 91 年 5 月之實測數據

測試範例：取 91 年 6 月至 91 年 9 月之實測數據

表 5-11 含自身項活性污泥系統放流水 SS 濃度預測隱藏層神經元數測試結果

隱藏層神經元數	train-MSE	train-R	test-R
1	0.0133	0.6796	0.7408
2	0.0126	0.6910	0.7351
3	0.0112	0.6917	0.7421
4	0.0113	0.6595	0.6555
5	0.0113	0.7112	0.7280
6	0.0107	0.5462	0.6898
7	0.0084	0.7366	0.6430
8	0.0120	0.7041	0.6243
<b>9</b>	<b>0.0109</b>	<b>0.6965</b>	<b>0.7453</b>
10	0.0082	0.7692	0.5635
11	0.0072	0.7277	0.6445
12	0.0095	0.7527	0.6149

由表 5-11 得知以水質因素、水量因素、MLSS 因素、SVI 因素以及活性污泥系統放流水質 SS 濃度自身歷史值進行活性污泥系統放流水質 SS 濃度之類神經網路測試,網路之 train-MSE 值介於 0.0072~0.0133 之間,train-R 值介於 0.5462~0.7527 之間, test-R 值介於 0.5635~0.7453 之間。最佳測試網路模式隱藏層神經元數為 9 個,網路之 test-R 值為 0.7453,網路之散佈、訓練及預測如圖 5-18~5-21 所示。經由網路實作後結果得知,水質因素、水量因素、MLSS 因素、SVI 因素等即足以表達活性污泥系統各項操作及監測參數所呈現的意義,再加入預測項目自身歷史值後對於活性污泥系統的放流水 COS 濃度及放流水 SS 濃度的預測皆有不錯的效能。




圖 5-18 活性污泥系統放流水 SS 濃度含自身項網路訓練散佈圖

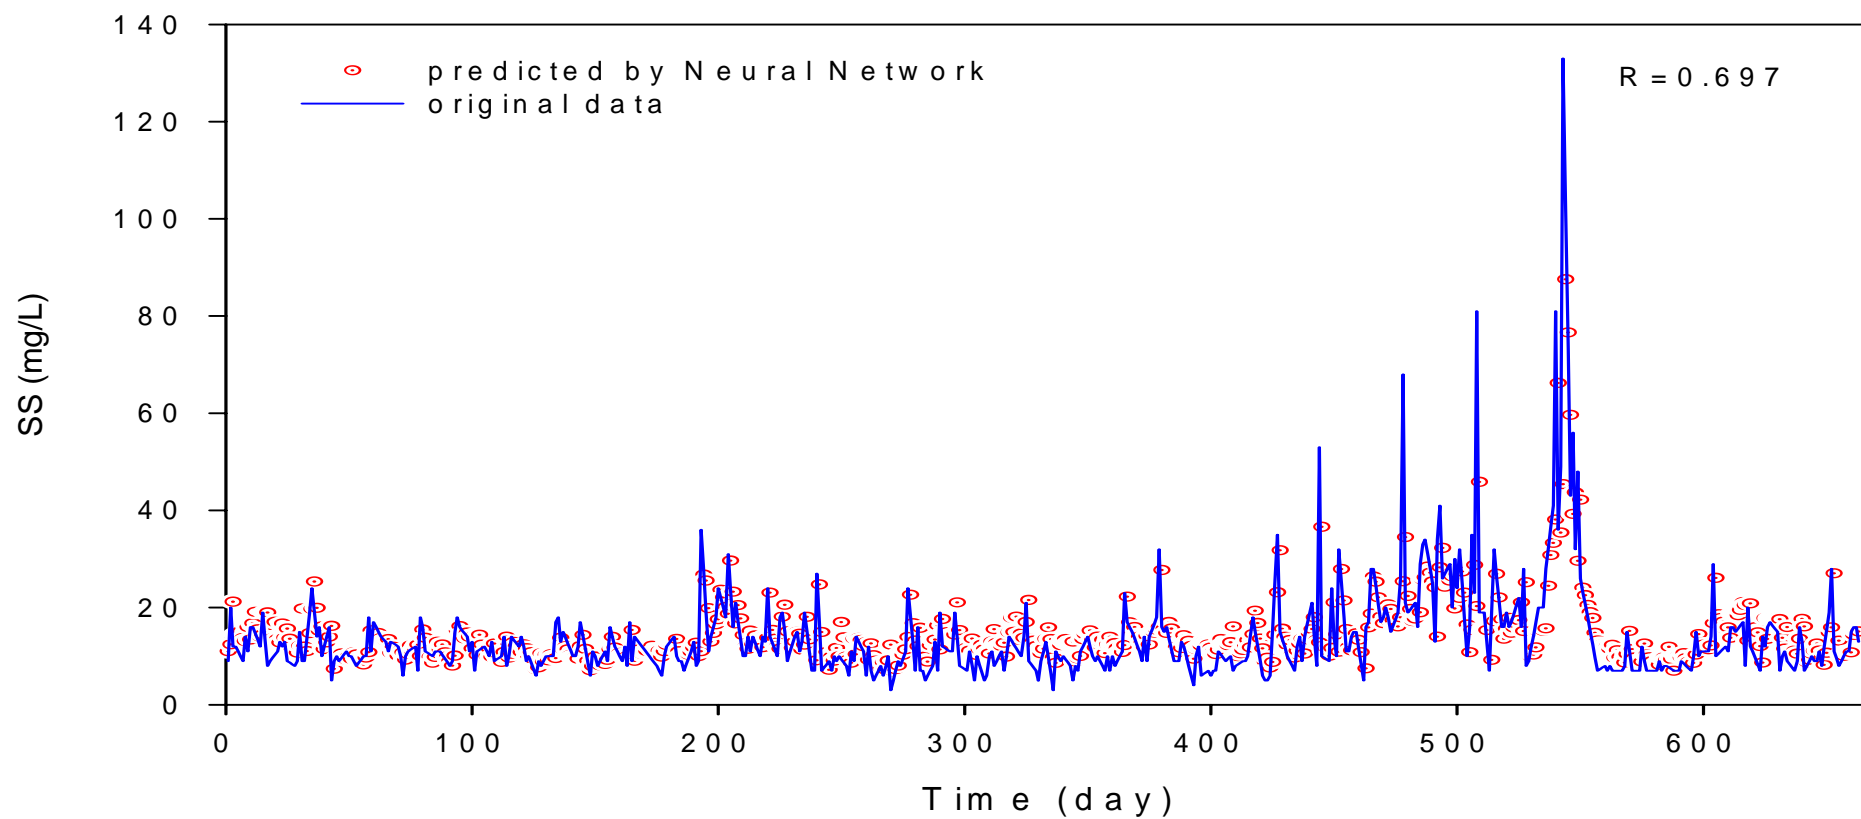


圖 5-19 活性污泥系統放流水 SS 濃度含自身項網路訓練圖




圖 5-20 活性污泥系統放流水 SS 濃度含自身項網路預測散佈圖




圖 5-21 活性污泥系統放流水 SS 濃度含自身項網路預測

#### 5.4-2 整體污水處理廠放流水質預測效能改善測試

本研究污水廠整體放流水質之預測最佳test-R值為0.7095，與其他污水處理整廠放流水質預測之文獻相比較已有不遜色的預測能力，為求更精簡的網路架構以及更佳的網路預測效果，再針對網路輸入變數進行檢討。

本研究污水處理廠整體放流水質COD濃度之預測網路輸入變數為廢水進流量，初沉池系統的進流SS濃度、進流COD濃度、進流pH，活性污泥系統的曝氣槽進流量、曝氣槽進流COD濃度、曝氣槽進流SS濃度、曝氣槽COD體積負荷、食微比、曝氣槽HRT、MLSS、SVI、DO、SRT、曝氣槽pH值等11項所萃取出的4個因素，以及三沉池的進流SS濃度、進流COD濃度、進流pH。案例污水處理廠中影響處理效率最主要的單元在於進行生物反應的活性污泥系統，眾多的活性污泥參數皆會直接影響放流水質的狀況，是為整體污水處理廠中最為重要的單元。在初沉池的部份，影響其處理效率主要在於停留時間的長短，而停留時間受限於廢水進流量的多寡，因此其操作狀況對於整體污水處理廠造成的影響有限。在三沉池的部份，三沉池於案例污水處理廠設計中主要用於三級化學混凝，而於原始日監測報表中89年8月至91年9月有效日數781日中僅有49日有使用化學添加藥品進行化學混凝，佔總資料的6.27%，因此將三沉池視為一般沉澱池。又三沉為案例污水處理廠中最後一個處理單元，平均水力停留時間為4.81小時，即是距離最終放流時間為4.81小時，因此網路的輸入是以時間 $t$ 作為輸入時間。本研究之最初目的是在於能及早預知放流水質狀況，若網路需使用預測天時間 $t$ 的輸入，即喪失了及早預知的意義。為此將三沉池的部份於輸入參數中去除，以變能達到及早預知的效果。

由於沉澱池水力停留時間皆受限於廢水進流量的多寡，為能精簡網路輸入變數，在此嘗試將初沉池的參數以廢水進流量為代表，輸入變數簡化為廢水進流量、水質因素、水量因素、MLSS因素、SVI因素等五項。其中4個因素是由活性污泥系統的曝氣槽進流量、曝氣槽進流COD濃度、曝氣槽進流SS濃度、曝氣槽COD體積負荷、食微比、曝氣槽HRT、MLSS、SVI、DO、SRT、曝氣槽pH值等11項所萃取而來的，而廢水進流量與曝氣槽進流量之相關性達0.784，因此廢水進流量與曝氣槽進流量兩者嘗試取曝氣槽進流量為代表，為實際有效的提高網路預測效果再加入預測項目之自身歷

史值，最後決定以時間t-1的水質因素、水量因素、MLSS因素、SVI因素及放流水COD濃度等五項輸入進行時間t之整體污水處理廠放流水質COD濃度之預測。神經元數的測試範圍由1個神經元測試至（輸入神經元數+輸出神經元數）×2個神經元數。網路使用可變學習速率及及早停止法則進行。由於類神經網路每次訓練結果可能不盡相同，故每個網路進行3次重複訓練取其最佳test-R值，其網路規劃如下：

隱藏層層數：1 層

隱藏層神經元數目：1~（輸入神經元數+輸出神經元數）×2 個，儲存各最佳網路模式

梯度下降演算法：Levenberg-Marguardt

訓練範例：取 89 年 8 月至 91 年 5 月之實測數據

測試範例：取 91 年 6 月至 91 年 9 月之實測數據

表 5-12 含自身項污水處理場放流水 COD 濃度預測隱藏層神經元數測試結果

隱藏層神經元數	train-MSE	train-R	test-R
1	0.0395	0.7740	0.7739
2	0.0384	0.7749	0.7748
3	0.0380	0.7818	0.7518
4	0.0390	0.7646	0.7711
5	0.0386	0.7780	0.7736
<b>6</b>	<b>0.0374</b>	<b>0.7771</b>	<b>0.7805</b>
7	0.0355	0.7883	0.7154
8	0.0375	0.6935	0.7638
9	0.0352	0.7739	0.7182
10	0.0360	0.7781	0.7576
11	0.0338	0.7553	0.7365
12	0.0346	0.7903	0.7731






圖 5-22 污水處理場放流水 COD 濃度含自身項網路訓練散佈圖




圖 5-23 污水處理場放流水 COD 濃度含自身項網路預測散佈圖




圖 5-24 水處理場放流水 COD 濃度含自身項網路訓練圖




圖 5-25 水處理場放流水 COD 濃度含自身項網路預測圖

由表 5-12 得知，含自身項整廠放流水 COD 濃度類神經網路與表 5-9 所示之不含自身項整廠放流水 COD 濃度類神經網路相比較，在不同隱藏層神經元數的表現不論是在 train-data 的部份或 test-data 的部份，含自身項活性污泥系統放流水 COD 濃度類神經網路皆優於不含自身項活性污泥系統放流水 COD 濃度類神經網路。網路最佳隱藏層神經元數為 6 個，train-MSE 值為 0.0374，train-R 為 0.7771，test-R 值為 0.7805，網路之散佈、訓練及預測如圖 5-22~5-25 所示。

經由網路實作後結果得知，在案例穩定操作之污水處理廠中，以活性污泥系統參數為代表，其他操作單元視為常態操作，再加入預測項目自身歷史值後對污水處理廠整體放流水質 COD 濃度進行預測，即能得到不錯的效果。

為印證此種網路架構對於污水處理廠的適用性，本研究再以時間  $t-1$  之水質因素、水量因素、MLSS 因素、SVI 因素等及污水處理場放流水質 SS 濃度自身歷史值進行時間  $t$  之污水處理場放流水質 SS 濃度之類神經網路測試，其網路規劃如下：

神經元數的測試範圍由 1 個神經元測試至（輸入神經元數+輸出神經元數） $\times 2$  個神經元數。網路使用可變學習速率及及早停止法則進行，每個網路進行 3 次重複訓練取其最佳 test-R 值，其網路規劃如下：

隱藏層層數：1 層

隱藏層神經元數目：1~（輸入神經元數+輸出神經元數） $\times 2$  個，儲存各最佳網路模式

梯度下降演算法：Levenberg-Marguardt

訓練範例：取 89 年 8 月至 91 年 5 月之實測數據

測試範例：取 91 年 6 月至 91 年 9 月之實測數據

表 5-13 含自身項污水處理場放流水 SS 濃度預測隱藏層神經元數測試結果

隱藏層神經元數	train-MSE	train-R	test-R
1	0.0292	0.5488	0.7015
2	0.0290	0.5535	0.6914
<b>3</b>	<b>0.0284</b>	<b>0.5507</b>	<b>0.7103</b>
4	0.0253	0.5742	0.6345
5	0.0277	0.5673	0.6971
6	0.0265	0.5857	0.6602
7	0.0262	0.5631	0.5682
8	0.0248	0.5493	0.6234
9	0.0262	0.5337	0.6406
10	0.0250	0.5708	0.4036
11	0.0254	0.5691	0.4288
12	0.0261	0.5643	0.6855




圖 5-26 污水處理場放流水 SS 濃度含自身項網路訓練散佈圖




圖 5-27 污水處理場放流水 SS 濃度含自身項網路預測散佈圖




圖 5-28 污水處理場放流水 SS 濃度含自身項網路訓練圖

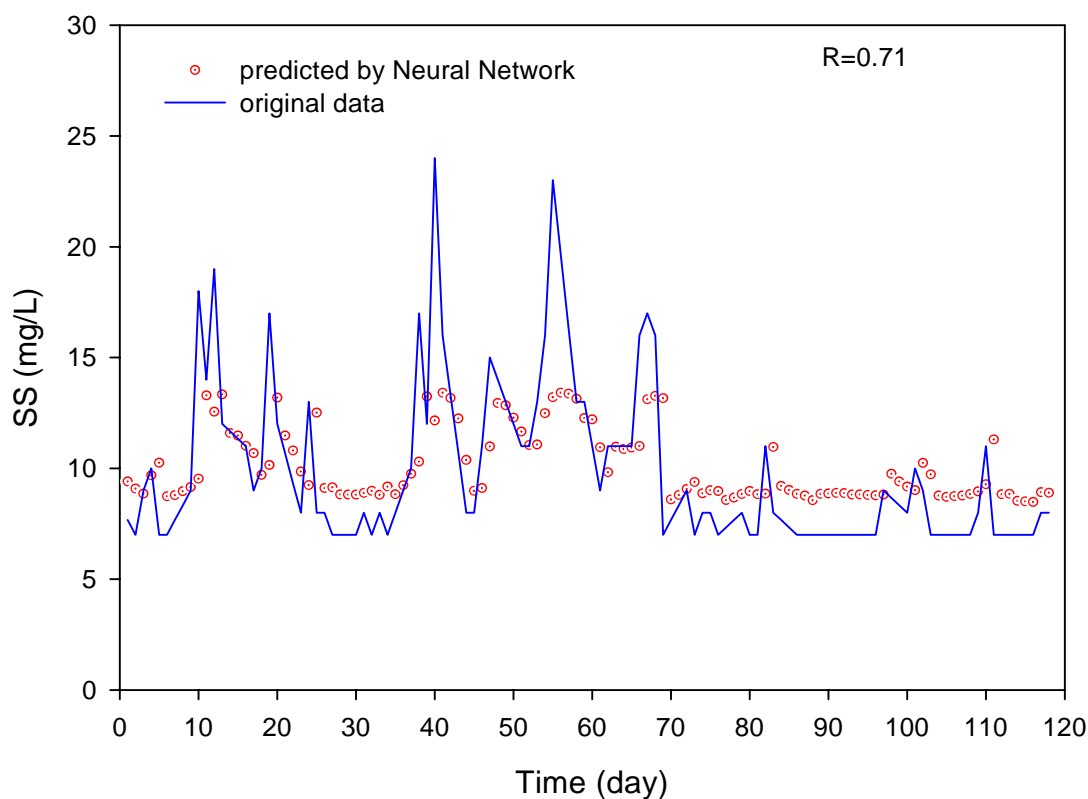


圖 5-29 污水處理場放流水 SS 濃度含自身項網路預測圖

由表 5-13 得知以水質因素、水量因素、MLSS 因素、SVI 因素等再加入污水處理場放流水質 SS 濃度自身歷史值進行污水處理場放流水質 SS 濃度之類神經網路測試,網路之 train-MSE 值介於 0.0248~0.0292 之間,train-R 值介於 0.5337~0.5857 之間, test-R 值介於 0.4036~0.7103 之間。最佳測試網路模式隱藏層神經元數為 3 個,網路 test-R 值為 0.7103,網路之散佈、訓練及預測如圖 5-26~5-29 所示。經由網路實作後結果得知,在案例穩定操作之廢水處理廠中,以活性污泥系統參數為代表,其他操作單元視為常態操作,再加入預測項目自身歷史值後對於污水處理廠即有不錯的解釋能力,對污水處理廠整體放流水質 COD 濃度以及流水質 SS 濃度進行預測,皆能得到不錯的效果。

## 第六章 結論與建議

### 6-1 結論

本研究將類神經網路應用於南部某聯合工業區污水處理廠放流水COD濃度及放流水SS濃度之預測,以主成分分析將案例污水處理廠活性污泥系統主要參數分析出的因素以線性迴歸的方式組合成全新的輸入變數;依據各處理單元水力停留時間進行最相近時間階次的網路實作比較。以活性污泥系統代表總變異量76.339%之因素以及其他處理單元監測參數進行類神經網路放流水質濃度預測,比照其他相關文獻進行網路結構的精簡以及網路預測效能的改善。茲將研究結果彙整於下:

- 1、以工業區聯合污水處理廠為研究對象,由類神經網路預測結果可得知,因子分析得到的因素,不同的污水處理廠個案可能會篩選出不同數目的因素,以特徵值 1 為分野加以線性組合成的參數,可以完整呈現原始眾多參數所代表的意義,並且在有效的精簡網路輸入項目同時也有具有足夠的廣義性。本研究分別針放流水質 COD 濃度及放流水質 SS 濃度進行類神經網路預測,皆有不錯的成效。
- 2、穩定操作的污水處理廠主要影響放流水質處理效率的處理單元在於活性污泥處理部份,本研究嘗試使用活性污泥系統之篩選後之水質因素、水量因素、MLSS 因素、SVI 因素以及預測項目自身歷史值等五項進行倒傳遞類神經網路運算,結果顯示除對於活性污泥系統放流水質 COD 濃度及 SS 濃度之預測有不錯的預測能力之外,對於整體污水處理廠放流水質 COD 濃度及 SS 濃度之預測也有很好的成效。
- 3、本研究針對活性污泥系統使用主成分分析進行各項參數的精簡,使用所得的水質因素 ( $t-1$ )、水量因素 ( $t-1$ ) MLSS 因素 ( $t-1$ ) SVI 因素 ( $t-1$ ) 以及待預測項目自身歷史值 ( $t-1$ ) 針對活性污泥系統放流水質 COD 濃度 ( $t$ )、活性污泥系統放流水質 SS 濃度 ( $t$ )、整體污水處理廠放流水質 COD 濃度 ( $t$ )、整體污水處理廠放流水質 SS 濃度 ( $t$ ) 等皆有不錯的預測果,對於污水處理廠實際使用上不需分別針對 COD 類神經網路及 SS 類神經網路採用不同的網路架構,利於使用的便利性。



## 6-2 後續研究建議

- 1、使用因子分析作為類神經網路的輸入篩選前置處理可以確實降低在輸入變數選擇上的困難及不確定性，並針對個案污水處理廠做更適合的判斷，並提升類神經網路應用於工業區聯合污水處理廠放流水品質預測之效能。又本研究僅使用倒傳遞類神經網路模式來進行聯合工業區污水處理場放流水質之預測，未來研究可依照本研究之網路輸入篩選方法來探討其他網路模式是否更為合適。
- 2、在網路輸入的相關時間皆次判定中，本研究根據各處理單元實際水力停留時間來判定相關輸入時間區間，以案例污水處理廠而言已足以進行類神經網路之預測，而無須將所有時間階次共同進行類神經網路運算，可避免造成網路結構過於龐大，失去主成份分析精簡輸入參數的意義。
- 3、本研究於二級處理放流水質預測以及整廠放流水質預測中針對水質 pH 項目進行比較，在本研究案例污水處理廠中由網路結果判知 pH 項目對於網路預測結果並無太大影響，未來在建構網路時如網路結構過於龐大，可考慮將 pH 項目去除。
- 4、本研究針對主成分分析合成之因素代表原參數群進行類神經網路放流水濃度之運算，可以較少的輸入參數得到尚可的預測結果，未來可進一步針對各污水處理廠之進流廢水性質進行網路分季運算的探討，在污水處理廠實際的運用上提高網路預測的精準度。

## 參考文獻

- 王俊凱，2000，「台灣地區大氣氣膠特性之研究-高雄、台北都會區氣膠特性與污染」，碩士論文，中央大學，環境工程研究所。
- 吳明隆，1999，「SPSS 統計應用實務」，松崗電腦圖書資料股份有限公司。
- 何佳祥、莊淳元、林玉萍、陳建谷、萬騰州，2002，「應用類神經網路系統及灰色系統理論於 UASB 廢水處理程序放流水水質之預測」，第十五屆環境規劃與管理研討會論文，中華民國環境工程學會。
- 李維斌，2000，「運用類神經網路於銀行業實施全面品質管理之研究-以花蓮地區銀行業為例」，碩士論文，東華大學，企業管理學系。
- 李宗霖、林宏明、盧育聘、吳信宏，2002，「類神經網路在公路邊坡破壞潛能之評估」，第七屆人工智能研討會。
- 林茂文，1992，「時間數列分析與預測」，華泰文化事業公司。
- 林逸塵，2002，「類神經網路應用於空氣品質預測之研究」，碩士論文，中山大學，環境工程研究所。
- 林碧霜，2003，「基隆市漁港水質差異及其變動特性」，碩士論文，海洋大學，漁業科學系。
- 洪明松，2004，「工業廢水處理廠放流水質模擬—軟性演算之應用」，碩士論文，朝陽科技大學，環境工程與管理系。
- 施東河、萬騰州、倪榮興，1997，「污水處理廠水質管理專家系統之研究」，雲林技術學院學報，第 6 卷，第 2 期，245~252 頁。
- 陳育偉，1995，「應用多變量統計方法辨識水庫優養化」，碩士論文，台灣大學農業工程研究所。
- 陳清暉，1999，「類神經網路結合遺傳演算法應用於工業區聯合廢水處理廠放流水品質預測之研究」，碩士論文，雲林科技大學環境與安全工程系碩士班。
- 陳瑞龍，2001，「運用類神經網路於醫院實施全面品質管理之研究-以花蓮地區醫院為例」，碩士論文，東華大學，企業管理研究所。

- 陳順宇，2001，「多變量分析」，華泰文化事業公司。
- 陳柏蒼、林永禎、陳昶憲，2002，「利用倒傳遞類神經網路建構未設測站流量推估模式之研究」，第七屆人工智能研討會。
- 郭益銘、劉振宇，2000，「雲林沿海地區地下水質變化分析：多變量因子分析法」，台灣水利，第 48 卷，第 1 期，1~8 頁。
- 張智星，2000，「MATLAB 程式設計與應用」，清蔚科技出版。
- 黃俊英，1995，「多變量分析」，華泰文化事業公司。
- 黃建源，2000，「多變量統計方法在日月潭水庫水質管理之應用」，碩士論文，逢甲大學，土木及水利工程研究所。
- 黃宗仁，2000，「利用類神經網路預測台中都會區臭氧趨勢之研究」，碩士論文，中興大學，環境工程學系。
- 葉怡成，1999，「類神經網路模式應用與實作」，儒林圖書有限公司。
- 劉興明，2004，「結合自我迴歸與類神經網路應用於電力負載預測」，碩士論文，東華大學，資訊工程學系。
- 蔡勇斌，1993，「活性污泥系統自動化與最佳化動態操作控制之研究」，博士論文，中央大學土木工程研究所。
- 蔡明昊，2002，「德基水庫不同位址底泥、土壤與水質之關係」，碩士論文，中興大學，土壤環境科學系。
- 鄭百乘，2003，「台灣地區周界環境中戴奧辛指紋圖譜和分佈之探討」，碩士論文，清華大學，化學系。
- 賴怡瑾、張淳智，2002，「運用類神經網路於壽險業業務人員服務績效評估之研究」，第七屆人工智能研討會。
- 歐崇明，1998，「MATLAB 使用入門手冊」，高立圖書有限公司。
- 羅華強，2001，「類神經網路-MATLAB 的應用」，清蔚科技出版。
- 簡家宏，2004，「應用基因類神經網路於空氣品質短期預測及監測資料異常值診斷之研究 - 以台中縣沙鹿空品測站為例」，碩士論文，雲林科技大學，環境與安全工程系。

魏維國，2000，「污水處理廠操作最佳化之研究」，碩士論文，中央大學，環境工程研究所。

Berthouex P.M., Hunter W.G. and Pallesen L., 1978. Dynamic Behavior of An Activated Sludge Plant, *Water Research*, **12**: 957-972.

Belanche Lluís A., Valde's J. J., Comas J., Roda I. R., Poch M., 1999. Towards a Model of input-output Behaviour of Wastewater Treatment Plants Using Soft Computing Techniques, *Environmental Modelling & Software*, **14**: 409-419.

Choi D.J and Park H., 2001. A Hybrid Artificial Neural as A Software Sensor for Optimal Control of A Wastewater Treatment Process, *Water Research*, **35**: 3959-3961.

Debelak K. A. and Sims C. A., 1981, Stochastic Modeling of An Industrial Activated Sludge Process, *Water Research*, **15**: 1173-1183.

Hornik K., Stinchcombe M., and White H., 1989 . Multilayer Feedforward Networks are Universal Approximators , *Neural Networks*, **2**: 359-366.

Hack M. and Kohne M., 1996. Estimation of Wasterwater Process Parameters Using Neural Networks, *Wat.Sci.Tech.*, **33**(1): 101-115.

Herniter, M. E., 2001. Programming in MATLAB, Wadsworth Group, a division of Thomson Learning, Inc.

Jorquera, H., Perez R., Cipriano A., Espejo A., Letelier M. V., and Acuna G., 1998. "Forecasting Ozone Daily Maximum Levels at Santiago,Chile", *Atmospheric Environment*, **32**(20): 3415-3424.

Lech R. F., Grady C. P. L. Jr., Lim H. C., and Koppel L. B., 1977. Automatic Control of The Activated Sludge Process-II. Efficacy of Control Strategies, *Water Research*, **12**: 91-99.

Prybutok V. R., Yi J., and Mitchell D., 2000. Comparison of Neural Network Models with ARIMA and Regression for Prediction of Houston's Daily Maximum Ozone Concentrations, *European Journal of Operational Research*, **122**: 31-40.

- Pratap, R., 2002. Getting Started with MATLAB a Quick Introduction for Scientists and Engineers, Oxford University Press, Inc.
- Stenstrom M. K., and Andrews J. F., 1979. Real-Time Control of Activated Sludge Process, *Journal of the Environmental Engineering Division*, **105**(EE2): 245.
- Spellman G., 1999. An Application of Artificial Neural Networks to the Prediction of Surface Ozone Concentrations in United Kingdom, *Applied Geography*, **19**: 123-136.
- Tay J. W. and Zhang X., 2000. A Fast Predicting Neural Fuzzy Model for High-Rate Anaerobic Wastewater Treatment Systems, *Water Research*, **34**: 2849-2860.
- The Math Work Inc. Matlab, Neural Network Toolbox, User's Guide.
- Tomida S., Hanai T., Ueda N., Honda H., and Kobayashi T., 1999. Construction of COD Simulation Model for Activated Sludge Process by Fuzzy Neural Network, *Journal of Bioscience and Bioengineering*, **88**(2): 215-220.
- Wan T. J., Chen C. H., Chang Y. S. and Chen J. C., 2000. An Application of Artificial Neuromolecular System for Effluent Quality Prediction of Wastewater Treatment Plant, *Journal of Chinese Institute of Environmental Engineering*, **10**(3): 155-162.
- Yi J., and Prybutok V.R., 1996. A Neural Network Model Forecasting for Prediction of Daily Maximum Ozone Concentration in An Industrialized Area, *Environment Pollution*, **92**(3): 349-357.

## 個人資料



一、姓 名：林修平  
出生日期：1977 年 4 月 6 日  
出 生 地：苗栗縣

二、學 歷：  
立德管理學院資源環境學系碩士班 2001/09~2004/01，2005/09~2006/01  
嘉南藥理科技大學環境工程與衛生學系 1999/09~2001/06  
萬能工商專科學校環境工程科 1997/09~1999/06

三、專業證照：  
甲級廢水處理專責人員  
甲級廢棄物處理技術人員  
甲級毒性化學物質專業技術管理人員  
勞工急救人員證

四、研究成果：  
編纂書籍：  
苗栗縣環保局施政統計報告書（2004），苗栗縣環保局。  
  
論文發表：  
林修平，2003，類神經網路結合主成分分析及時序偏自我相關應用於工業區  
污水處理廠放流水質動態之預測，第一屆資源與環境管理學術研討會，立德  
管理學院。

專題製作：  
台灣地區電動機車發展現況與推廣探討（1999），萬能工商專科學校。

五、聯絡方式：  
聯絡地址：苗栗縣頭份鎮中山路 53 號  
聯絡電話：(037) 665081  
E- m a i l：s123456@pchome.com.tw