

逢 甲 大 學
工 業 工 程 與 系 統 管 理 研 究 所
碩 士 論 文

應 用 ARIMA 模 型 對 影 響 台 灣 工 業 生 產 指 數
之 產 業 預 測 與 分 析



Using ARIMA Models to Forecast and
Analyze Industries Influencing Taiwan's
Industrial Production Index

指 導 教 授：林 棋 瑋 博 士
研 究 生：余 光 倫

中 華 民 國 一 百 一 十 一 年 七 月

逢 甲 大 學
工 業 工 程 與 系 統 管 理 學 系
碩 士 學 位 論 文

應用 ARIMA 模型對影響台灣工業生產指數
之產業預測與分析

Forecasting and Analysis of Factors Affecting Taiwan
Industrial Production Index Using ARIMA Model

- | | |
|--|--|
| <input checked="" type="checkbox"/> 學術論文 | <input type="checkbox"/> 成就證明(應用科技類) |
| <input type="checkbox"/> 作品(藝術類) | <input type="checkbox"/> 技術報告(應用科技類) |
| <input type="checkbox"/> 書面報告(藝術類) | <input type="checkbox"/> 專業實務報告(專業實務類) |

研究生：余光倫

經碩士學位考試合格特此證明

評審委員

蔡文傑

林相璋

莊文傑

指導教授

林相璋

主任/所長

王逸行

考試日期：中華民國 111 年 7 月 14 日

逢甲大學研究生無違反學術倫理聲明書

FCU Graduate Student Academic Ethics Statement

本人已完全瞭解學術倫理之定義與行為規範，謹此嚴正聲明，本人所呈繳之學位論

文(包含作品、成就證明連同書面報告、技術報告或專業實務報告)：(題目)應用

ARIMA 模型對影響台灣工業生產指數之產業預測與分析，如有抄襲、舞弊或違反

著作權法等違反學術誠信與倫理之行為時，願自行承擔所有法律責任，以及概括承

受一切後果，並無條件同意註銷本人之碩(博)士學位，絕無異議。

I am fully aware of and understand the University's regulations on plagiarism. And I declare herewith, that the thesis/ written report/ technical report/ professional practice report entitled "(Thesis title) Using ARIMA Models to Forecast and Analyze Industries Influencing Taiwan's Industrial Production Index" is a presentation of my original work. In addition, I understand that any false claim or plagiarism in respect of this work will result in disciplinary action in accordance with University's regulations. I assume legal liability for this and completely agree to the withdrawal of the Master's/ Doctor's degree if any violation of academic ethics in the thesis is confirmed to be true.

聲明人 Student Signature : 余光倫

(請親筆書寫簽名 Signature)

學號/ID.NO : M0926126

系所/Department : 工業工程與系統管理學系

日期 Date : 2022 / 07 / 20 (YYYY/MM/DD)

本人為 余光倫 之指導教授，經檢視其學位論文內容，確實無抄襲或剽竊之行為。

To the best of my knowledge, this thesis has no plagiarism or violations of academic ethics.

指導教授(Academic Advisor) : 林錫山 (親筆簽名 Signature)

聲明日期(Date) : 2022 年(Y) 07 月(M) 20 日(D)

*本聲明書正本請與學位考試申請文件一併附上，電子檔請檢附於電子論文中，影本請裝訂於紙本學位論文內。

The original statement should be included in your thesis defense application; The e-file should be included in your e-file of the thesis, the copy should be included in your thesis.

誌 謝

沒想到寫誌謝的時刻到了，回首研究所兩年，一切彷彿雲煙般，從修課、考試到論文，一路上得到許多人幫助，在此致上最深謝意！

首先，要感謝的是林棋瑋教授，不論最初的論文開題、每次討論給的建議跟方向，到內容格式的修改，每個不同的階段都可以讓我學到新的東西，是您讓我的思維更開闊，教會我遇到困境時如何解決問題的能力，對於我來說，這些比學科內容更來的重要，謝謝老師！

再來，要感謝的是我的父母，一路上的支持，不管是物質上還是精神上的，每次回家都是我最放鬆的時刻，如今換我準備出社會了，沒有你們的支持，肯定不會有現在的我，謝謝。

再來，要感謝的是許馨云跟許歐元姊弟，很抱歉時常把負面情緒到回家裡，但沒有你們的陪伴，這兩年我一定撐不下去，家裡有人等著的感覺是如此美好，謝謝。

最後要感謝自己，每當想放棄的時候，謝謝自己有努力撐下去，總是抱著再撐一下就好的心態，如今總算完成了，謝謝。

余光倫 謹至於

逢甲大學工程與科學學院

中華民國 111 年 7 月

摘要

台灣工業生產大致可分為礦業及土石採取業、製造業、電力及燃氣供應業、用水供應業等 4 大類。這些產業之生產總值占整體經濟比重不少，因此，工業生產與 GDP 兩者間存在相當程度的關係。本文旨在建構影響台灣工業生產指數之產業趨勢模型。趨勢預測的方法有很多種，時間序列是良好的方法之一。由於時間序列分析的基本原理是基於數據驅動而且是相對直觀的，因此它可以透過進行時間序列數據的處理、推導、應用和預測來有效地提取隱含的時間樣態，考慮到此次研究對象的數據並不是太龐大，並且詳閱各種文獻後，確定本次研究以時間序列分析方法進行模型的建立。

本研究運用時間序列建立2000年到2021年的趨勢模型，以影響工業生產指數之產業為研究目標。首先我們先將此方法跟線性預測與神經網路的結果互相比較，結果發現此方法在短期預測時誤差較小，之後我們再將這方法運用在影響工業生產指數之產業。研究架構包含Dickey-Fuller Test、整合自迴歸移動平均ARIMA、並探討預測不同期數之誤差，透過預測誤差衡量方法之絕對百分RMSE求得最適參數。研究發現，季節性ARIMA模型對於短期的趨勢預測能力有很強的效率，能有效判定此案例的未來趨勢。

關鍵詞：ARIMA、時間序列、工業生產指數

Abstract

Taiwan's industrial production can be divided into four categories: mining and soil mining, manufacturing, electricity and gas supply, and water supply. The GDP of these industries accounts for a large proportion of the overall economy. Therefore, there is a considerable degree of relationship between industrial production and GDP. The purpose of this paper is to construct an industry trend model that affects Taiwan's industrial production index. There are many methods for trend forecasting, and time series is one of the good methods. Since the basic principle of time series analysis is data-driven and relatively intuitive, it can effectively extract the implicit time patterns by processing, deriving, applying, and predicting time series data. The data is not too huge, and after reading various literatures, it is determined that this study uses the time series analysis method to establish the model.

This study uses a time series to build a trend model from 2000 to 2021, targeting industries that affect the industrial production index. First, we compare this method with the results of linear forecasting and neural network, and it is found that this method has less error in short-term forecasting, and then we apply this method to industries that affect the industrial production index. The research framework includes Dickey-Fuller Test, integrated autoregressive moving average ARIMA, and explores the forecast errors of different periods, and obtains the optimal parameters through the absolute percentage RMSE of the forecast error measurement method. The study found that the seasonal ARIMA model has strong efficiency for short-term trend prediction ability and can effectively determine the future trend of this case.

Keywords: ARIMA 、 Time Series 、 Industrial Production

目 錄

第一章緒論	1
1.1 研究動機及背景	1
1.2 研究目的	2
1.3 研究範圍	3
1.4 研究流程	4
第二章文獻探討	6
2.1 工業生產指數	6
2.2 平穩應檢驗	8
2.3 時間序列預測方法	10
第三章研究過程與方法	20
3.1 時間序列拆解	21
3.2 AR、MA 模型	22
3.3 ARIMA 模型	24
第四章方法比較與實際案例	29
4.1 方法比較	29
4.2 實際案例分析	35
第五章結論與建議	42
5.1 結論	42
5.2 建議	43
參考文獻	44

圖目錄

圖1 研究流程圖	5
圖2 研究架構	20
圖3 ARIMA 模型流程	25
圖4 德國基本金屬時間序列拆解	30
圖5 差分前單根檢定	31
圖6 時間序列差分後圖示化	31
圖7 差分後單根檢定	32
圖8 各產業圖示化	35
圖9 各產業季節性循環	36
圖10 民生工業差分後 DF 檢驗	37
圖11 各產業差分後圖示化	38
圖12 民生工業差分後 DF 檢驗	38
圖13 預測趨勢與實際趨勢	40

表目錄

表 1 不同方法優缺點	19
表 2 模型與其 AIC 值	32
表 3 預測期數與其 RMSE	34
表 4 民生工業不同參數 AIC 值	39
表 5 各產業最佳模型參數	40
表 6 各產業預測斷後 RMSE 誤差	41

第一章 緒論

1.1 研究動機及背景

在台灣，工業生產指數是反映工業發展速度的重要指標，其包含礦業、製造業、水電燃氣及公用事業等等，且有些產業的生產總額占整體經濟龐大比重，對於經濟變動的反應是十分敏銳的；因此，工業生產指數實為觀察景氣變動的重要量測指標。根據這個原因，本研究將分析台灣工業生產指數中，佔據整體較多權重之產業。

在過去的30年中，出現了許多關於時間序列的平穩測試和建模的文獻。他們大多主要專注在神經網路架構上，例如：Zhang and Patuwo and Hu(1998)、Darbellay and Slama (2000)、Qi and Tkacz (2001)，然而，Zhang et al. (1998) 表明儘管這些模型功能較強大，但神經網絡模型的經驗預測性能卻是相當混雜。

自 Box and Jenkins(1976)提出的 ARIMA 模型以來因其開放性的架構經過四十餘年來學者專家的參與發展後，它的預估模式已有了較佳的配置效果，因此，本研究使用由 Box and Jenkins(1976)所提出的 ARIMA 模型，透過對驅動參數的調整對未來數值趨勢的預測。

1.2 研究目的

本研究採用時間序列方式應用工業生產指數之預測，建立可預測未來趨勢之模型，提供相關單位或用戶能有一個經過數據科學驗證過的依據可以參考。

本研究主要目的如下：

一、分析中華民國經濟部統計處資料，使用整合自迴歸移動平均 ARIMA 方法，針對佔據工業生產指數多數比重之產業進行模型的建立，並驗證其準確度。

二、分析不同預測期數，並測試最準確之預測期數。



1.3 研究範圍

本研究對象及資料範圍如下：

一、依台灣公部門所屬單位統計處統計：化學、民生、基本金屬、電力及天然氣、電子、機械佔台灣整體工業生產比重五成以上，因此，使用以上六種產業為研究對象。

二、此次研究所使用之時間序列資料，區間為西元2000年1月1日至2021年9月30日。



1.4 研究流程

本研究之流程包括確立研究目的與範圍、文獻探討、綜合結論與建議等項目，研究流程如圖1所示，各項目分別說明如下：

一、確立研究目的與範圍

確立研究目標及方向，包含確定問題、界定研究範圍並尋找適合之方法進行使用，以期能達成最終目標。

二、文獻探討

針對此次研究所討論的主題，進行相關文獻的蒐集與整理，內容包含數據分析與檢驗、時間序列方法與預測模型建立等相關文獻。

三、方法比較並套入此次案例

首先將本次研究所使用方法與過往案例比較，再將本次研究中會使用到的數據分別處理，並使用方法建立趨勢預測模型，最後以評估指標比較模型預測之能力。

四、綜合結論與建議

歸納經過研究後之分析與結果，對此次研究提出結論以及針對這次研究方向提出建議。

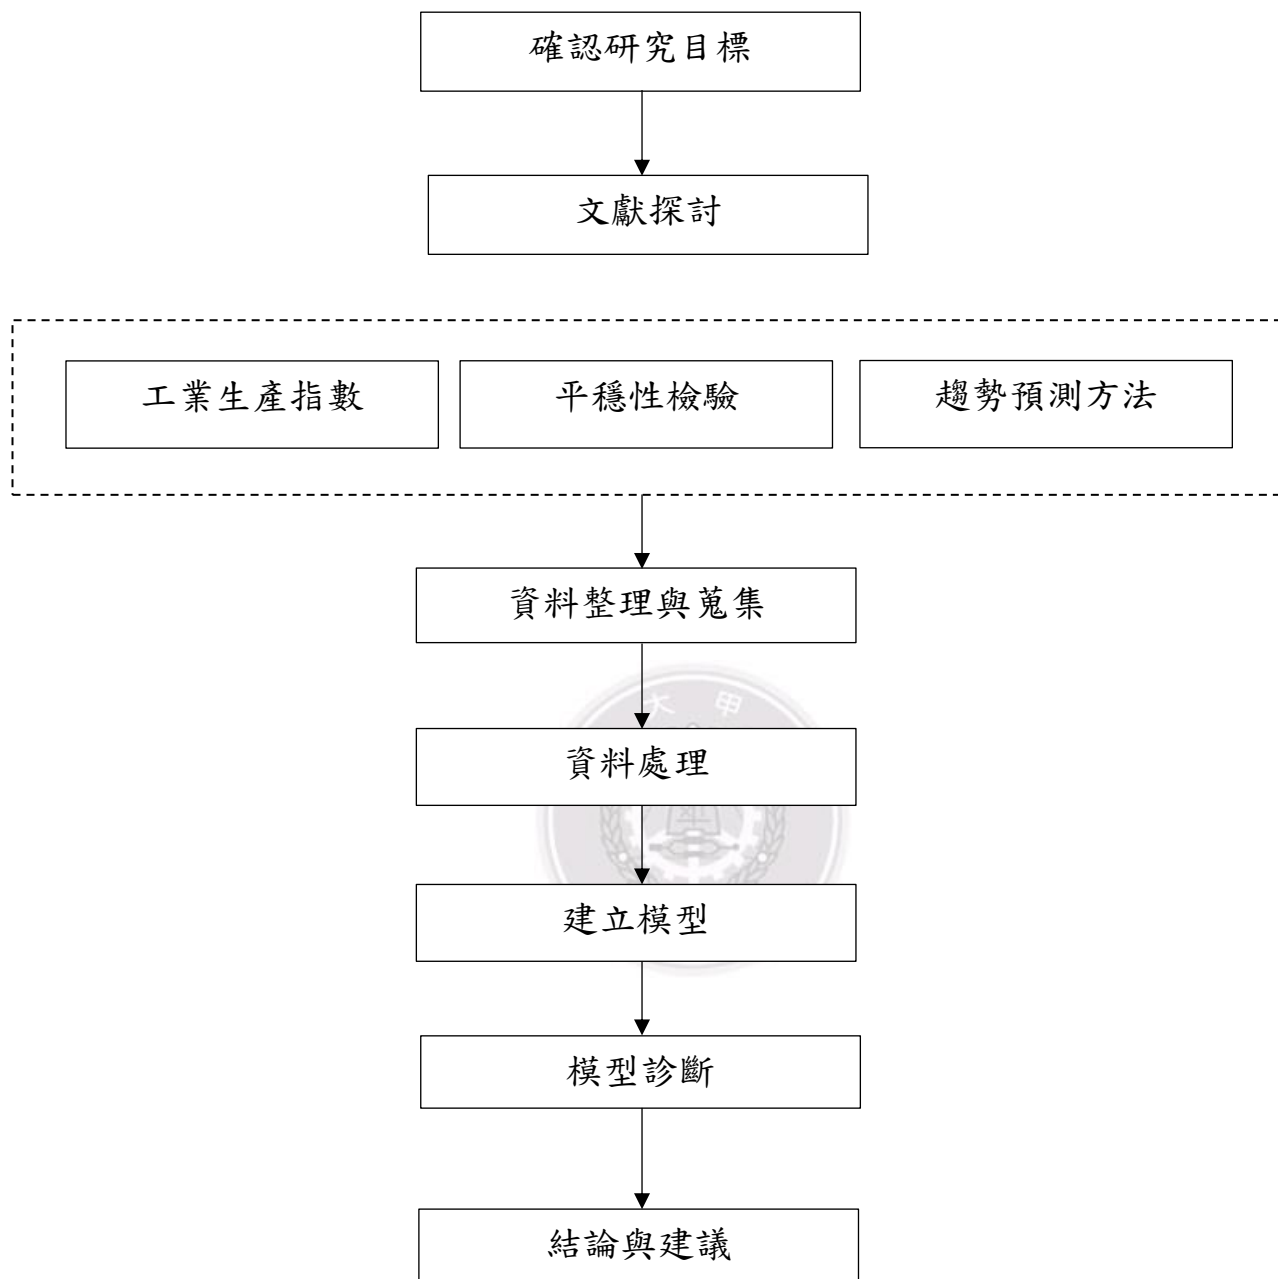


圖1、研究流程圖

第二章 文獻探討

本研究將文獻探討劃分成三個部分。由於此次研究對象為影響工業生產指數之產業，所以第一部分主要介紹台灣景氣指標的發展與工業生產指數的發展及相關文獻探討；第二部分主要介紹時間序列的平穩性的檢驗方法及相關文獻探討；第三部分主要介紹在時間序列的問題中常見之趨勢預測方法。以上為本章節文獻探討欲探討的三個部分。

2.1 工業生產指數

2.1.1 台灣景氣指標的進展

台灣景氣指標是由公部門建設委員會自民國86年起按每月份為單位發布，當中包括景氣綜合指數與景氣對策信號。現階段景氣綜合指數有領先指標、同時指標跟落後指標。

領先指標可預測景氣高峰谷底的出現，同時指標則能同步反映當時景氣之變化，至於落後指標則可用於事後驗證或比對同時即領先指標在過去的運行上是否準確。若根據上述三種指標構成的因子多寡來區分，則可劃分為以下兩類：

(一) 綜合指標(Comprehensive Indicators)：

如：領先指標(Leading Indicator)、同時指標(Coincident Indicator)等。

(二) 單一指標(Individual Indicator)：

如：工業指數(Industrial Production)、股價指數(Stock Price)等。

近20年來，由於全世界經濟體制劇烈變遷，先是2008年的金融海嘯；後因各國採取積極性擴張性的政策，加上以亞洲為主之新興國家快速的發展帶動，全球景氣於2009年走出陰霾。然後，上述幾

個全球性的經濟影響，使得大環境之經濟體制急遽變化，進而導致近幾年台灣的景氣也隨之劇烈波動。因此，徐志宏與黃月盈於2013年末對景氣燈號構成項目與檢查職進行修訂，篩選出更適合之因子用於合成新的同時指標，並與當前之標杆進行比較。最終指出：同時指標中的「商業營業額指數」因具有領先性質，建議改其名稱以「商業營業額」替代。

2.1.2 台灣工業生產指數

台灣之工業生產統計創始於1953年，其算法是用加權算術平均數編製的指數，可衡量製造業、礦業及公共事業等等行業的實質總產出。係由當前工業生產結構中，選取相對代表性的產出品，每月調查其生產量、銷售量及存貨量，且以指數之型式表現工業產銷量值的變化，通常在衡量工業生產指數興衰時，我們習慣以工業生產指數趨勢作為衡量依據：當工業生產指數年增率趨勢持續上升，代表製造業、礦業、水電燃氣業等生產量持續增強，為工業景氣好轉的象徵；當工業生產指數年增率趨勢持續下滑，代表當中重要產業持續減弱，為工業景氣轉弱的象徵。因此，饒秀華(2001)使用分期馬可夫轉換模型(MS Model)，將研究模型的高、低之年變化率期望值與變異數配置成兩組或兩組以上，用以闡釋開發中地區在不同經濟發展過程，總體變數之景氣軌跡波動狀況。再者，林淑華(2010)使用格蘭傑因果關係檢驗、向量自我迴歸模型(Vector Autoregression Model, VAR)、與衝擊反映函數，來解析工業生產指數、物價、利率、油價、貨幣額跟匯率各要素之間互相引影響之情形。

計算工業生產指數調查的產品依據公部門統計處編列之工業產品分類調查共(共2,657項)，再將相同性質產品合併為630項產物群，並將它們編列至報表中，台灣之工業生產指數採用的是拉皮斯爾式 (Laspeyres) 基期加權總值式，其計算公式如下：

$$I_{0i} = \frac{\sum Q_i P_0}{\sum Q_0 P_0} \times 100 \quad (1)$$

算式中 Q_i ：計算其生產量， Q_0 ：基期生產量， P_0 ：基其生產淨值單價。

2.2 平穩性檢驗

研究通常會對一個未經處理的時間序列數據進行平穩性檢驗。平穩性檢驗的用意是為了確定沒有隨機趨勢或確定趨勢，否則將可能會出現偽迴歸的現象。當偽迴歸出現時，代表時間序列的資料分析產生的高度相關僅僅是因為二者同時隨時間有向上或向下的變動趨勢，並沒有實質上的相依關係，換句話說，資料中的季節性等因素無法消除，會導致在殘差分析中無法準確進行分析。平穩性檢驗的方法大致可分為以下三類：

2.2.1 時序圖檢驗：

根據平穩時間序列平均值、變異數為常數的特徵，平穩序列的時序圖應該顯示出序列始終在一個常數值附近隨機波動，而且波動具有：範圍有界限、無明顯趨勢及週期特徵。一個平穩的時間序列在圖表上往往表現出一種圍繞在平均值附近不斷波動的進程；而非平穩序列則表現出在不同時間段具有不同的平均值（如趨勢持續上升

或持續下降)。由於此方法只依據序列的平均值、變異數進行判斷，而沒有考慮它的均方差，故準確性相對來說較低。

2.2.2 自相關圖檢驗：

自我相關函數(Autocorrelation)，也叫序列相關，是一個訊號於其自身在不同時間點的互相關。簡單來說，它就是兩次觀察之間的相似度對它們之間的時間差的函數，它能有效找出重複模式（如白噪音掩蓋的週期訊號），或識別出隱含在序列頻率中季節性的特徵。它常用於分析函數。

2.2.3 迪基-福勒檢驗（Dickey-Fuller Test），DF 檢驗：

是 Dickey and Fuller(1979)由模型 $y_t = py_{t-1} + u_t$ 生成 n 個觀測 y_1, y_2, \dots, y_n ，其中 y_0 是一個固定常數， $\{u_t\}_t = 1^n$ 是一個平均值為 0 的獨立序列，方差為 σ^2 之隨機變量，而在 $p = \pm 1$ 的假設下獲得 p 的迴歸估計量性質，進而導出了 p 的估計量和迴歸 t 檢驗的極限分佈。結論為 p 的估計量和迴歸 t 檢驗提供了檢驗 $p = 1$ 假設的方法。主要用來測試一個自迴歸模型是否存在單根。單根是指一時間序列隨時間的經過，其前一期的自我相關係數將趨近於 1，則此數列存在單根的特性，而當一個時間序列存在單根時，表示其並非一組平穩之時間序列。其函式如下：

$$y_t = py_{t-1} + u_t \quad (2)$$

y_t 是要檢驗的序列， t 是時間， p 是係數， u_t 是誤差項，如果 $|p| \geq 1$ 則可以說明單位根是存在的，模型是非平穩的。

2.3 時間序列預測方法

時間序列被人們廣泛應用在統計學、數學或大部分牽涉時間數據勘測的工程中。決策者在進行計畫考量時，很多時候都是使用過去經驗及做決定，但面對瞬息萬變的大環境，單靠過去經驗有很大的機會造成決策上的錯誤，若在決策前以統計方法做為出發點，讓相關單位在進行決策時，能有更多樣化之考量範圍。以下將在現行眾多預測方法中，以人工神經網路、ARIMA 及多元迴歸進行實際案例說明，各預測方法都有其優缺點，對於它們之間的比較，列舉實例以評估。

2.3.1 人工神經網路

類神經網路(Artificial Neural Network，ANN)為一種模擬人類大腦神經元結構的數學函式。人類會有感知動作是因為外界的刺激透過神經細胞傳遞到大腦，再由大腦下達指令做出的反應，以長時間頻繁訓練執行作出最適當判斷，並使大腦記住。ANN 模型運作方式如同大腦重複學習，建構不同演算法進行訓練，讓神經網路能如同大腦一般輸出所需之結果。ANN 建構神經元與結點進行相互連結，利用神經元之間的運算函數，進行大量平行演算、工作處理與分散儲存，透過訓練大量的樣本數與自動化學習，在巨量的資料庫中找出少量且正確之結果，人工神經網路也一種被大量使用於時間序列分析的方式，因此，Heravi et al. (2003) 比較了神經網路與線性方法在預測英國、法國及德國三者影響個別工業生產指數之產業，由各產業在其工業生產指數中的占比中，篩選出 8 個產業做為研究對象，分別為：食品、化學品、基本金屬、金屬加工、機械、電機、車輛和電力/天然氣行業。研究結果發現，神經網絡模型在預測這些

產業時，在未來趨勢方向方面具相對於線性方法有明顯優勢。方法比較的案例包括，Vhatkar et al. (2016) 針對口腔保健的產品，以 ANN 模型、ARIMA 跟 SVN 模型進行需求預測，雖然研究目標是典型的週期短且低成本的消耗性產品，但由於週期短且需求量極高，因此積累的利潤也相當龐大，在三種方法的比較之下，ANN 在此案例中有較準確的結果。

再者，陳彥佑(2015) 將倒傳遞類神經網路(Back Propagation Neural Network, BPN)使用在心血管疾病患者之住院天數預測：隨著生活方式的變遷，優良的醫療品質也提升了國人平均壽命，病人住院的時間間接影響了病床的配置方式，在最有利的人力及空間資源下，如何保持醫療品質與成本掌控，使用住院資料來訓練導傳遞神經網路的適應性與預測效力，將收集到的資料以梯度下降法來估計連接點相關權重，將住院病床的配置最佳化。或是，黃志瑋(2015) 使用人工神經網路預測高雄捷運班次運量：隨著大眾運輸使用量的成長，有效分配車輛調度與排班，才能應付大量乘車人數，此研究運用過去高低峰時段訓練神經網路模型，對搭乘人數流量進行分析，找出流量之區間，提升營運方向與改善服務策略；高雄捷運目前有兩條主線，將訓練過後所產生數據結果與實際搭乘人數做分析比較，結果表明為調度上有供過於求的情形發生，未如預期流量，改善方案則可透過促銷式拉攏客群，或減少班次降低成本，以提升營運績效。以及，李天傑(2016)將倒傳遞類神經網路模型運用在台灣電力之使用量：電力幾乎為台灣最不可或缺之能源，特別是現在工業與科技業迅速發展的環境，電力損耗與分配不均造成能源浪費，如何在缺電的年代，如何有效調配才能優化台灣能源需求問題，利用機器學習，以影響電力分配要素進行訓練與建構，變數因子包括

濕度、溫度、平均負載量與能源消費總值等，以梯度下降法估計出連接點權重，將實際值與估計值進行比較，兩者落差約在 2% 以下，具有高度準確性預測性能，表明此案例在透過神經網路良好訓練後，能有效預測結果。或是，Barunik et al. (2016) 運用神經網路對原油價格起伏做預測：原油價格牽動著各行各業的發展，在最有限資源情況下，複雜性的需求與原油採集的起伏決定它的價格，此研究透過動態模型強化神經網路效能，對於不穩定的原油價格更能減少錯誤性預測。

另外一方面，神經網路不僅可以用在產能預測，也能運用在產品的需求預測上。像是，Lau et al. (2013) 找出企業供應鏈最佳需求預測模型，改變其運作方式：產品需求的不確定性，造成企業過多的庫存成本且日漸提升，由於神經網路屬於非線性預測，針對隨機性之需求建構模型能做出及時反應，利用MDL產生多筆優化神經網路，建構出符合實際需求之預測模型。再者，Wei et al. (2015) 利用非排序自適差發分法優化其神經網路模型，解決時尚界短期補給需求：時尚界的產品生命之週期普遍偏短，在客戶端需求不確定的情況下，預測過程無法用單一變數解決缺陷，因為時尚單品多呈現高坡動性的情況，而單一變數之數據則為恆定狀態，因此，需要建構一個反應快且能力高的模型才能達成解決即時性捕獲的目標。以及，張智皓(2015) 運用人工神經網路對太陽能需求量進行研究：隨著工業發展迅速，各行各業對電力的需求也日漸增高，太陽能雖並非現在發電方式之主流但其環保的優點促使越來越多人使用它，由於太陽能能量來源屬於間歇性的，整體效率會因為太陽的東升西落而改變，而神經網路好處就在於可以加入相關函數進行長期性地訓練，雖然耗費時間被拉長，卻能讓估計出的數據更接近實際值，不

論是長短期，皆能做為決策時之參考依據。研究目標小至票卷買賣也可以，像是 Ghiassi et al. (2015) 的研究目標為電影市場之需求：製作電影需要消耗大量的金錢與時間，收入來源取決於票房的麥麥，以類神經網路增加做決策時所缺乏的準確性，利用巔峰時刻之開放式消費數據，建構出未來需求導向之模型。

2.3.2 時間序列之 ARIMA(p, d, q)模型

整合移動平均自我迴歸模型 (Autoregressive Integrated Moving Average Model; ARIMA) 屬於單變量之預測模型，演算方式是透過自相關性逐次推移並建模，資料型態可為年、季、月、日等分式。ARIMA 在建立模型時並不會考量外在影響要素，單純是透過自相關係數移動的過程，判斷研究目標數據是否存在趨勢或季節性，以自相關係數建構趨勢模型，藉由實際值與預測值進行比較，對未來趨勢進行參考評估。因此，李台亮(2013)以過往住房量為觀測數據，使用 ARIMA 模型對花蓮飯店進行需求預測，建構出旅遊業通用的模式：研究目標以不同客層進行研究，包含國內外之旅遊團、合約公司，政府推出的觀光方案，運用 ARIMA，改善花蓮旅館過在離峰時需求過剩問題，建構出一套最有效且資源調度最順暢之手法，做為類似產業參考目標。以及，Arunraj et al. (2015) 對新鮮食品進行銷售預測：鮮食的零售考慮到食用期限短，進貨數量的多寡，都有可能造成不必要的浪費或庫存短缺的問題，ARIMA 模型適合用以日為預測單位，加上季節行循環增加模型的多樣性，相較於機器學習，ARIMA 模型能提供更好的時間間隔，每種鮮食保存情況不同時，如何正確預測需求才能同時達到顧客滿意與減少浪費，ARIMA 模型在中短期時間序列預測性能較佳，讓決策者能做出精準判斷。或是，

翁雅君(2015)使用ARIMA模型研究公共腳踏車使用情形：政府推行節能減碳後，腳踏車的租借成為上班族的選擇之一，使用率頻頻上升的情況下，時常會有供不應求的情形，針對 32 個租借站使用量，得出校區共停站比率較高且穩定，交通站周圍之站點租借率較高，但不確定要素也高於其他地方，表明ARIMA對趨勢性時間序列能有效地進行分析，找出影響需求主因。以及，Su et al.(2012)探討開放大陸人來台觀光，對於別的國家觀光客是否依舊有高度旅台意願進行分析：台灣屬於小島國家，政府開放中國觀光客的到來，有利於經濟快速發展，但隨著遊客量的提升，導致台灣旅遊業有過多的負擔，進而促成住宿業與餐廳過多設立等相關問題，造成品質參差不齊的現象。針對中國、香港、美國與日本旅客各別建立數量模型，運用ARIMA 模型研究開放大陸觀光客來台後所帶來之影響，檢視此決策是否會影響其他國家來台意願，由於中國觀光客為台灣帶來龐大觀收入，以長期考量而言，台灣需要時間做出適當地調整，以應付超載的旅遊量而會破壞的聲譽。時間序列趨勢分析相關研究也包含，Babai et al.(2013)建立ARIMA模型改善產品供應鏈中，存貨與預測效能問題：研究目標為歐洲銷貨買賣紀錄，在過往例子中，存貨管理跟需求預測兩者處理模式分別進行的，此次研究則是在兩者之間加入資源共享的因子，找出適合兩者的最佳函數，改善供給與需求的水準問題。或是，Rames et al.(2015)針對女性用鞋類進行零售銷售研究。零售產品易受到流行指標與季節性要素影響，供應與需求不易找到一個平衡點，進而影響企業營利狀況，模型建構以女用六大鞋款進行分析，建構預測模型時時，依照類別特質進行個別分析，女鞋屬於生命循環短且淘汰率高之產品，找出可能買量巔峰時間，提早實施促銷方案減少庫存，達到研究用途。以及，何

武勇(2015) 使用ARIMA對中國彩妝品零售價格進行建模並預測。化妝品的銷售隨著大環境對審美的變化也跟著提高，需求量呈現指數向上的趨勢，中國地區消費者對彩妝品的空間需求高過其他地區，ARIMA適合判斷物品需求趨勢，後續探討可再加入其他因子，讓模型變為多變量的，可提升精確度。再者，Yuan et al.(2016) 對中國一次性能源進行建模：隨著中國各行業的崛起，對能源的渴望也越強大，能源價格的攀升也造成大陸經濟成長率的降低，如何有效率利用資源成為中國主要議題之一，ARIMA模型能有效找出用量趨勢使政府做重大策略時能有相關依據。

另一方面，黃柏瑞(2016)進行了方法的比較：使用ARIMA模型跟迴歸分析對於生產電路板及半導體出口產值進行建模預測，並比較兩者方法。台灣製造業近年來以電子業為主，生產與人力成本相較於其他代工地區高出不少，在勞動資源與產業外移的情況下，針對產值進行研究，找出有效趨勢模型，而ARIMA模型對半導體出口預測則有較高之準確率。

2.3.3 多元迴歸分析

多元迴歸分析(Multiple Regression Analysis)又稱複迴歸，用意在於探討兩個或以上之變數間是否有關與特徵強度，並於過程中建立趨勢模型以觀察目標變數來預測感興趣的變數。迴歸模型是建構單一變數對應變量進行預測，對於多變的目標起伏無法及做適當的回應，而多元迴歸分析可同時納入多個可能影響結果之因子，因為影響變因並非單一因子，迴歸模型可以協助研究者了解在只有單一自變數變化時應變數的變化量，換句話說，我們可以通過迴歸分析輸入的自變數預測應變數的期望值。因此，黃詩珉(2013)針對影響台灣

住宿業營業額收入之要素，進行分析探討：使用多元迴歸分析影響營利收入之原因分析，變因包括消費物者價指數、旅宿業住房率跟旅遊人士，以上述三種因子建構收入預測模型，研究各因子對於總營利之影響幅度，此研究成果表示，三者確實對收入有正向影響。或是，許勝源(2013)以影響台灣超商冷藏飲品之銷售變化因子，進行研究分析：以多元迴歸模型設定內在跟外部變數因子，內在變數包括飲品項目、旺淡季、優惠方案跟地域性，外部變數包含環境溫度、降雨機率跟各種天氣型態，研究結果表示，產品雖然受到外部因子溫度的影響，大部分數據則是因為內在有無優惠方案左右銷量，此證實也有利於未來做銷售決策與存貨管理，降低企業銷售成本。再者，余清芬(2014)以多變量迴歸模型分析團體旅遊之價格，再進行策略上的分析：針對消費者對價格有敏感的嗅覺，旅遊業者時常利用低價吸引購買人潮，以滲透定價、吸脂定價、消費背景、消費者滿意度、旅遊品質跟消費忠誠度做為此研究模型之變因，探討以上因素與銷售績效的關係，研究結果表示，消費者與業者在價格認知上有落差，出乎意料的，人們對於高價旅遊的需求高於低價的，證實消費者在旅遊方面著重在事前的期待並非事後品質訴求。

甚之，王柏晟(2014)以多元迴歸分析建構 IC 封裝測試廠的製造成本模型：為有效降低生產成本，使用管理成本當作此次案例的依變數，建立能夠分析成本的模型，而此次研究結果表示，用管理成本預測後的水準可以達 89% 的精准度，也表明此方法在此案例中確實可行。以及，林淑娟(2014)探討光學膜之未來需求：隨著 3C 產品使用週期的縮短與日漸競爭的情況下，產品需求的波動也變得頻繁，在製程中如何控制產出、庫存跟配送是企業需要思考的議題，將出貨量、實際產出跟市場價格當作此次研究的依變數，進行模型

建構，比較了多元迴歸與類神經網路，由於數據需求波動大且觀測量不夠的缺陷，複迴歸模型預測出的結果優於其他方法。再者，陳怡靜(2014)研究目標是對影響高雄捷運運量之原因進行分析：變數因子包括當地人口、遊客景點、經濟結構跟醫療人數等。近年來，高雄隨著觀光建設劇增，進而增加旅遊人次，對遊客來說最便利的交通工具就是捷運，結論證實，旅遊景點與運量有正相關，如果能針對相關變因拋出更完整轉乘交通和優惠方案，能有效提升載量。

另一方面，洪承(2014)討論影響房地產策略之變因：近年隨著經濟的起飛，房地產的銷售量也隨之升高，房地產價格的多寡往往受到政府策略的影響，如何在天時地利人和時，推出適當政策，天時包括當期之房產買氣等，地力包含地段吸引力，人和則是建商名氣或是產品優點等，在建案買賣期間進行銷售率趨勢預測，研究成果顯示，房產本身條件跟販售金額對於預測結果最為顯著，以多變量模型的實用性，針對變因改善行銷策略有利於提高銷售量。再者，張書豪(2014)針對氣候對於百貨通路之進口服飾品牌進行銷售量影響探討：將影響天氣之變因做為此研究案立迴歸模型的依變數，包括溫度、大氣壓力、濕度、降水量日照時數以及雲量多寡，進行不同販賣間隔影響探討，在排除最直觀的價格影響下，溫度與降雨量為影響買賣量的主要原因，但在產品促銷期間，氣候的好壞對於銷售量毫無影響，說明對於消費者來說價格因素比天氣因子更具影響力。

2.3.4 方法比較與說明

此次研究根據列舉類神經網路、整合移動平均自我迴歸模型跟多元迴歸模型結果進行說明：在前幾章節提到的幾個方法中，類神經網路為當今較主流之預測方法，其主要特色在於可以針對非線性的模型跟難度較大的實驗進行分析，以模擬大腦學習的過程結合不同演算法進行訓練，建構出一套經驗模型，但由於執行時需要高度專業知識與資金，較不適用於小企業使用。

多元迴歸係是透過因果關係找出影響觀測結果之主要變因，利用單一或數個變因，試著找出影響觀察數據之趨勢原因，而缺點在於影響變因有可能因為性質類似而導致共線性的連結，造成錯誤判別，或者無法最有效找出真正變因，提供準確剖析跟預測。

ARIMA 係以自身過去所發生之紀錄來推斷未來趨勢，實行此模型之最初預設是往後趨勢不會有跳躍性變化，而是漸進性移動，把訓練數據就構成一組自我相關係數，並以圖像形式判斷趨勢方向，在建模的過程中，並不會將影響觀測值之變因加入模型中，單純以數據自身相關性建立。本研究在無法取得可能影響觀結果之情形下，使用 ARIMA 模型進行趨勢分析，透過過去生產值表現進行建模，找出未來趨勢，供相關單位參考。表1為各方法優點及缺點比較。

表1、不同方法優缺點

方法	預測期數長短	優點	缺點
神經網路	長、中跟短期	有能力解決非線性數據，與複雜問題。	建模過程需要大量數據，執行者需要專業分析能力。
多元迴歸模型	中短期	透過依變數與自變數兩者關係找出最大變因，可同時考慮多種因素。	需考慮共線性而導致偽迴歸的問題。
ARIMA	中短期	模型建構時不需考慮外界影響因素，而是以自我本身發生過程向外找出影響觀測值本身外在因，能分析季節性波動。	當今多數時間序列皆為不穩定狀態，經過差分後也有可能導致過度穩定。

第三章 研究過程與方法

本章節將說明實際案例分析的過程以及其中所使用到之方法与原理，包括資料收集與處理、不同方法的比較、ARIMA 模型建立跟分析以及預測模型的評估最後則是本研究之建議。第一階段將蒐集整理好的資料以圖形描述，並觀察其時間序列特性，判斷是否具有季節性週期，即是否為平穩序列，第二階段將與其他方法進行比較，實證在短期預測時本方法效能較佳，比較之後才進行此次案例模型的建構，第三階段則是檢視模型的效能。研究架構如圖2

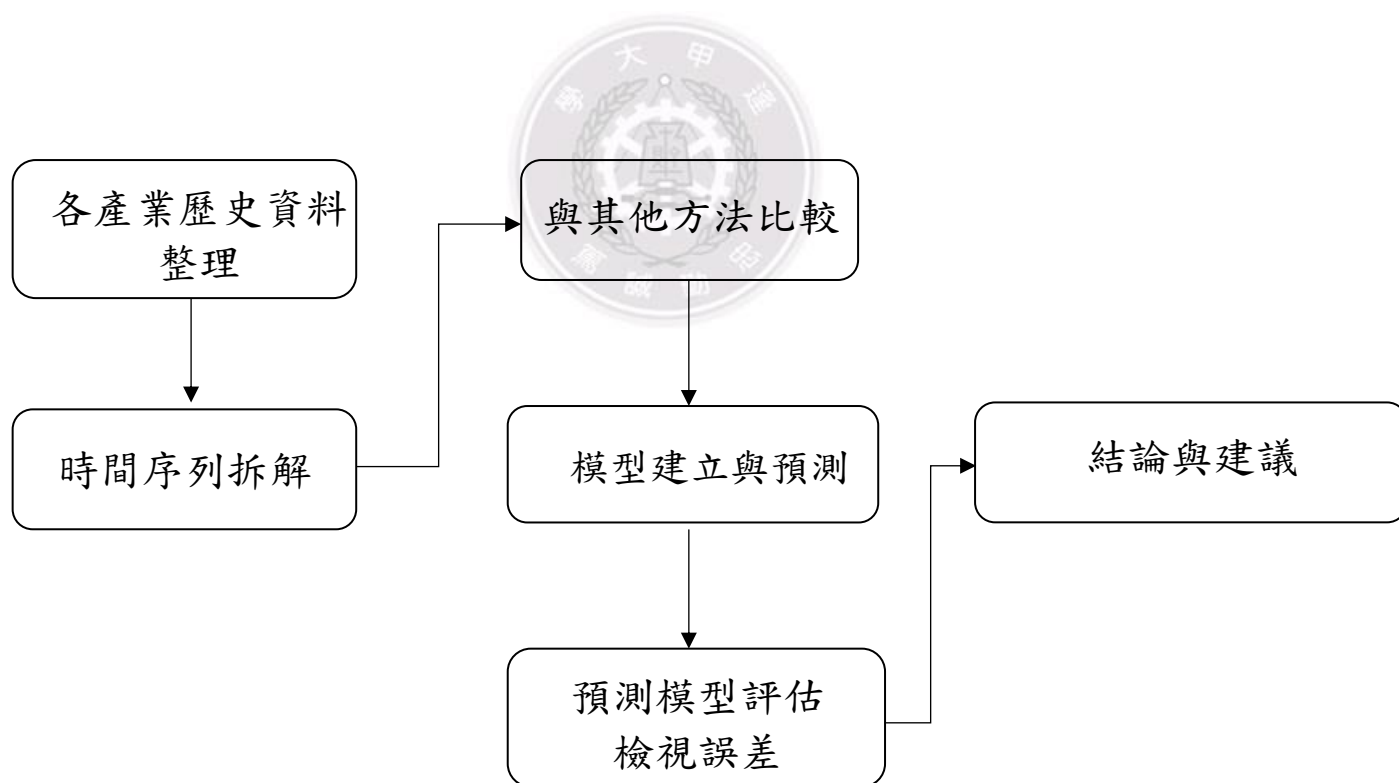


圖2、研究架構

3.1 時間序列拆解

一條時間序列是可以被拆解的，可以在其中找出四個要素，分別是趨勢、季節性、循環與隨機性，各別的數值變化被不同的原因所影響，這些原因有的是影響長期的，也有些是決定短期趨勢的；有的可以預知可控的因素，有的則無法，這些因素互相作用並干擾，進而使得一條時間趨勢的變化表現出不同的特色，各因素敘述說明如下：

- 長遠趨勢(Secular Trend，後簡稱 T)：

指的是某一數值在長遠的尖閣時間內，受到特定原因的干擾，圖形顯示出持續下降或上升的趨勢。

- 季節性變化(Seasonal Variation，後簡稱 S)：

指的是資料數值受自然環境、生產限制和生活性質等因素的干擾，隨著季節的變換而表現的周期性變動，此類循環通常為1年。其特點是它是有規律性的，表現為逐年、月或季度有相似的變化趨勢和大致相同的變化波幅。

- 循環變化(Cyclical Variation，後簡稱 C)：

循環變化與季節性變化的週期不一樣，它在曲線圖上的顯現出的是波浪狀的週期變化，換句話說，其代表在數據中波峰到另一個波峰的時間間隔，如同谷底至另一個谷底的時間段。

- 不規則變化(Irregular Variation，後簡稱 I)：

時間序列產生不規則變化是由於某些隨機變因導致的數值變化，這些變因包含無法預測的與沒有規律的，因此兩者對時間序列產生的效果是不規則變動，換句話說，一條時間序列如果去除季節、趨

勢跟循環現象後、剩下的就是殘差。

以上四點特性通過以下兩種模型構成時間序列，以下說明：

- 疊加模型：四種特性是各自獨立的關係，其模型展示為：

$$X_t = T_t + S_t + C_t + I_t$$

- 乘積模型：四種特性間存在彼此影響的關係，其模型展示為：

$$X_t = T_t + S_t + C_t + I_t$$

如果時間數列的波幅保持固定，就可以直接使用疊加的模型，但若季節性變化明顯，波動愈來愈大，代表各種變動特性間的關係發生變化，則使用相乘的模型；然而，在大多時間序列中，鮮少有變化特性是各自獨立的，各成分或多或少都存在一定關係，所以日常生活中大多使用乘積模型當作研究方法。

3.2 AR、MA 模型

整合移動平均自我迴歸模型(Autoregressive Integrated Moving Average Model; ARIMA)，是從AR (Autoregression)、MA (Moving Average) 以及ARMA模型演變而來的，於1971年由Box and Jenkins兩位研究者所發表，也稱為Box- Jenkins方法，近幾年研究之內容若是以AR模型體制執行計畫，大多會用ARIMA模型來測試預測準確率，是目前被使用的時間數列模型之一，該模型是獲得過往數據，透過自我相關係數與偏相關性等特性，應用模型判斷、參數估計及模型診斷等三階段內容建構函數，找出一最佳模型作預測。

時間序列資料分為平穩和非平穩兩種，基本上，不管是 AR、MA 或是 ARMA 都是用於分析平穩時間序列，ARIMA 則是通過差分

處理非平穩時間序列；在說明深入一點，各方法的用處如下：

- AR：針對歷史之值的模式。
- MA：針對歷史資料的殘差項的模式。
- ARMA：同時加入過去的值以及殘差項的模式。
- ARIMA：同時考慮過去值、殘差項以及穩定（Stationary）問題的模式。

以下將針對各模型做進一步說明：

1. AR 模型

當一個時間序列的任意值可以被表示成下列的迴歸方程式，代表該時間數列服從 p 階的自迴歸過程，可以表示為 $AR(p)$ ，其過程是用一個變數的歷史資料來預測現值，不是 x 預測 y ，而是用 X_{t-1} 預測 X_t ：

$$X_t = c + \sum_{i=1}^p \varphi_i X_{t-i} + \varepsilon_t \quad (3)$$

2. MA 模型

當一個時間數列的任意值可以被表示成下列的迴歸方程式，代表該時間序列服從 p 階的移動平均過程，可以表示為 $MA(p)$ ，其過程是使用過去資料預測的誤差來建立一個類似迴歸的模型，也被當成一個線性組合。：

$$X_t = \mu + \varepsilon_t - \sum_{j=1}^q Q_j X_{t-j} \quad (4)$$

任一時間點的值等於白噪音序列的加權總和，如：迴歸方程中，白噪音有三項，該移動平均過程則為 3 階移動平均過程，示 $MA(3)$ 。

3. ARMA 模型

自迴歸移動平均模型由兩部分組成，如其名，由自迴歸和移動平均建構，因此包含兩個階數，可以表示為 $ARMA(p, q)$ ， p 為自迴歸階數， q 則是移動平均階數，可表示為：

$$X_t = c + \varepsilon_t + \sum_{i=1}^p \varphi_i X_{t-i} + \sum_{j=1}^q \theta_j X_{t-j} \quad (5)$$

自迴歸移動平均模型結合了 AR 和 MA 兩種模型，在 ARMA 模型中，移動平均的演算其實可以當成自迴歸進程的補充，解決自迴歸方差中白噪音的問題；自迴歸過程可以量化當前資料與前期數據彼此之間的關係，移動平均進程則可以處理隨機變動項的求解問題。

3.3 ARIMA 模型

上述三種模型皆用於平穩時間序列的應用，但如研究對象為非平穩資料，則 ARIMA 模型能夠用於其次非平穩時間序列的分析，將原先非平穩的時間數列經過 d 階差分後成為平穩之數列。

如今現實生活中，大多為非平穩的時間序列，它們的均值和方差是隨著時間前進而變化的，但是經過差分處理後，形成新的時間序列就可以變成平穩時間序列了。整合移動平均自我迴歸模型寫成 $ARIMA(p, d, q)$ 。

p 為自迴歸階數； d 為差分次數； q 為移動平均階數。其模型可表示為：

$$(1 - \sum_{i=1}^p \varphi_i L^i)(1 - L)^d X_t = (1 + \sum_{j=1}^q \theta_j L^j) \varepsilon_t \quad (6)$$

以 Box-Jenkins 方法建立 ARIMA 流程約三個步驟如圖3：平穩性檢驗、模型參數估計（Estimation）以及模型診斷檢查（Diagnostic Check），摘要概述如圖後。

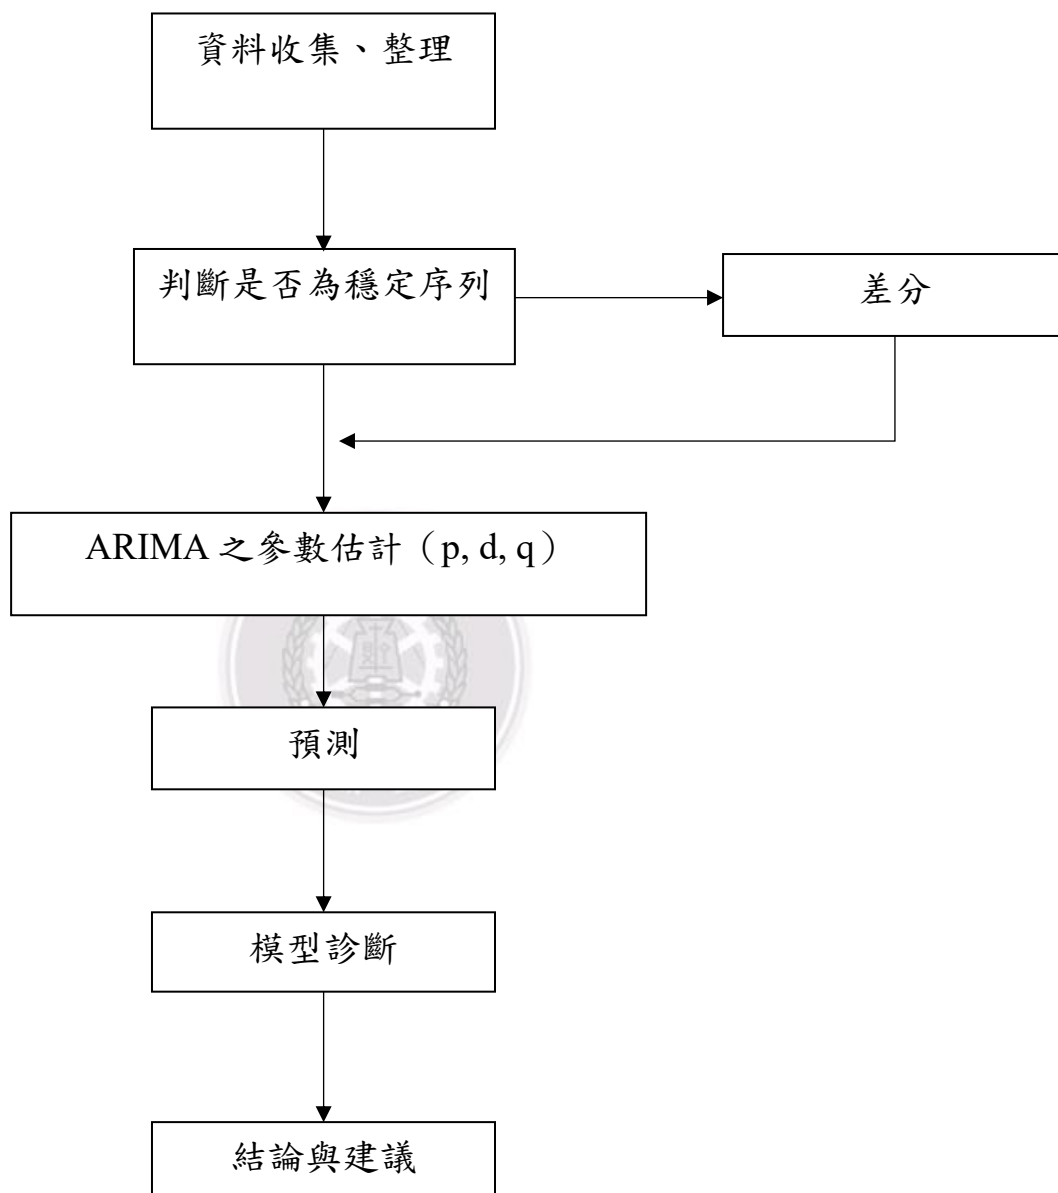


圖3、ARIMA 模型流程

一、模型判定

在進入時間數列分析前，要先判定數列是否為穩定狀態，若數列不穩定則採差分處理，方法包括圖解的自我相關函數圖

(Autocorrelation Function, ACF) 及本研究採用的 Dickey and Fuller (1981) 單根檢定法判斷數列是否為穩態，然後再分析(p, q) 項，摘述如後：

- I. ACF 判定：透過自我相關函數圖判斷，在判斷途中數列無猛然消失時，顯示該數列為非平穩型序列，故需執行差分；直到序列之自我相關函數很快消失為止，即表示數列經過差分後已變為平穩序列。
- II. 單根檢定法 (DF)判定：單根檢定為判斷資料是否為穩態的一種方法，DF 單根檢定可以以下公式表示：

$$y_t = \rho y_{t-1} + u_t \quad (7)$$

其假設過程為， $H_0: \alpha = 0$ 時存在單根， $H_1: \alpha < 0$ ，不存在單根，若拒絕虛無假設，表示此序列不具單根，為平穩型時間序列；若不拒絕虛無假設，則序列具有單根，為非平穩型時間序列。

二、參數估計

若存在多組參數顯著的模型話，以Akaike (1974) 整理之AIC初步選取幾種可能的模型，並檢定這幾組模型的殘差是否存符合白噪音，亦即殘差符合無自我相關及常態分配的檢定。另外郭明月與肖枝洪 (2009) 提出若無法通過白噪音檢定則表示暫定之ARIMA 模式為不適合之模式，因此需再進行調整，直至序列穩定為止，此時

通過檢定之ARIMA模式。

赤池弘次情報準則：日本統計專家赤池弘次為了估計模型之品質並避免參數過度配置情形導致模型失準的問題，於1974年提出一種衡量準則，稱為赤池弘次情報準則(簡稱AIC準則)：

$$AIC = N \ln (SSE) + 2k \quad (8)$$

模型當中 $\ln (n)$ 是樣本總數取自然對數， k 是模式總參數個數，AIC的數值越小，模型所選之 p 、 d 、 f 的配適愈佳。

三、預測準確度檢驗方法

當今研究常使用之預測準確度檢驗的方法有MAE (Mean Absolute Error)、MAPE (Mean Absolute Percent Error)、MSE (Mean Square Error) 及RMSE (Root Mean Squared Error)四種，上述幾種計算結果愈小者表示其預測誤差愈小，也表示模型預測能力較佳。下列摘述中， f_i 表示預測值， y_i 代表實際值。

● MAE (Mean Absolute Error)

平均絕對誤差，為衡量每筆預測值與實際值之誤差，MAE方法將每筆誤差取絕對值後再加總，後計算其平均誤差，換句話說，MAE就是模型的預測值與實際值之間平均相差多大，其公式如下：

$$MAE = \frac{1}{n} \sum_{i=1}^n |f_i - y_i| \quad (9)$$

- MAPE (Mean Absolute Percent Error)

平均絕對百分比誤差，MAPE 是將每筆資料之相對預測誤差進行衡量，P 的意思就是百分比，可避免 MAD 方法及 MSE 法方中，因資料本身數值較大進而造成計算結果過大的缺點，公式如下：

$$MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{f_i - y_i}{f_i} \right| \quad (10)$$

- MSE (Mean Square Error)

平均平方誤差，算法是計算預測值和實際值兩者差的平方的平均值，其只考慮誤差值平均之大小，並不會考慮其方向，公式如下：

$$MSE = \frac{1}{n} \sum_{i=1}^n (f_i - y_i)^2 \quad (11)$$

- RMSE (Root Mean Squared Error)

均方根誤差，簡單來說，就是將 MSE 開根號，可衡量預測值和實際值之間的平均差異，藉此估計預測模型預測目標值的準確程度。公式如下：

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (f_i - y_i)^2} \quad (12)$$

本研究說明預測模型能力指標為上述四種方法，江政儒(2019)表明因 RMSE 不受單位與數值大小之影響，判斷之根據相對客觀，通常為大多研究人員使用之方法，故此研究使用 RMSE 作為判斷預測模型之能力指標。

第四章 方法比較與實際案例分析

本章節首先會先預測影響歐洲工業生產指數的行業並將結果與 Denise R. Osborn(2003)所使用的方法進行比較，驗證 ARIMA 模型在短期預測時有較好的效能，再來進行此次研究目標，對影響台灣工業生產指數之產業進行模型建立。

各步驟將在以下不同小節分別摘述，將分為兩小節，前半段為方法比較，後半段為研究案例。

4.1 方法比較

4.1.1 資料收集

Denise R. Osborn(2003)所使用的資料為德國、法國跟英國三個國家到1995年4月的數據，資料起始時間分別為1978年1月、1985年1月跟1986年1月。

依照歐盟官方統計資料指出，影響歐洲三個國家工業生產指數之產業為：食品工業、化學工業、基本金屬、金屬製品、機械工業、電機工業、車輛工業和電力與天然氣工業。

4.1.2 判斷時間序列是否穩定

我們可以先將時間序料資料圖示化並拆解，由於研究對象有三個國家，各八種產業，因此以下過程以德國之基本金屬產業圖表示，全部之比較結果將展示於本小節最後。

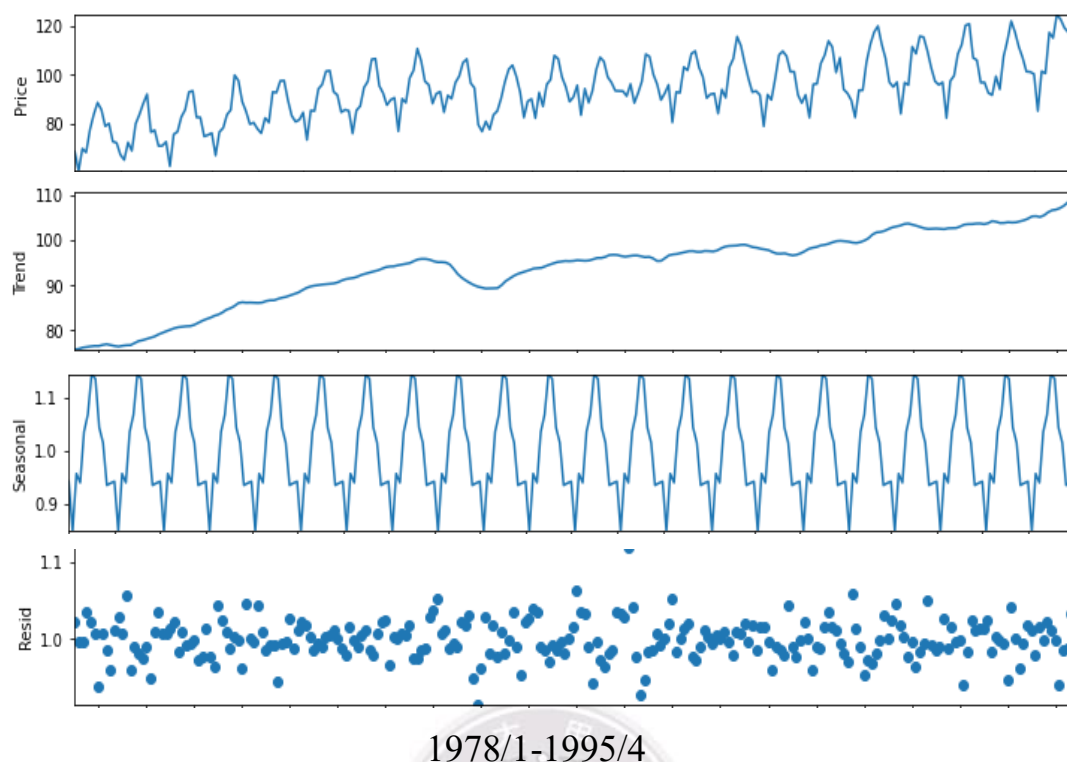


圖4、德國基本金屬時間序列拆解

圖4為德國基本金屬之時間序列拆解圖，第一列為將資料視覺化的結果，往下分別為趨勢、季節性跟殘差，需要注意的地方是第三張圖的循環，可以從圖中看到此產業是有季節性因素的，很大的機率代表它並非為一個穩定的時間數列，但是光從圖片無法真正確定，因此本研究主要依據以下判斷。

一組時間序列資料是否為穩態，會大程度干擾到後面步驟模型的設計，大部分的模型建構前期都有一個相呼應的穩態假設，首先判斷序列是否穩態，常用的方法為 Dickey-Fuller 單根檢定，在 DF 檢定中，如果檢驗統計量小於臨界值，我們可以拒絕原假設，也就是說序列是平穩的，但當檢驗統計量大於臨界值時，則無法拒絕原假設也代表數列是非平穩的。

將資料輸入至統計軟體後，得到結果如圖5。

```
Results of Dickey-Fuller Test
=====
Test Statistic                1.198351
p-value                      0.995974
#Lags Used                   12.000000
Number of Observations Used  251.000000
Critical Value (1%)          -3.456674
Critical Value (5%)          -2.873125
Critical Value (10%)         -2.572944
dtype: float64
=====
The data is non-stationary, so do differencing!
Results of Dickey-Fuller Test
```

圖5、差分前單根檢定

從圖中可以看到檢驗統計量(Test Statistic)遠大於臨界值(Critical Value (10%))，因此下一步就需要進行差分處理。

在將原來的時間序列經過差分處理後，我們可以得到一個新的序列，如圖6。從差分過後的圖形中可以明顯看到新的時間序列少了季節性，數列保持再-20~30之間，再將新的數列進行一次DF單根檢定，可以從檢驗統計量小於臨界值結果得知，時間數列已是穩態。如圖7

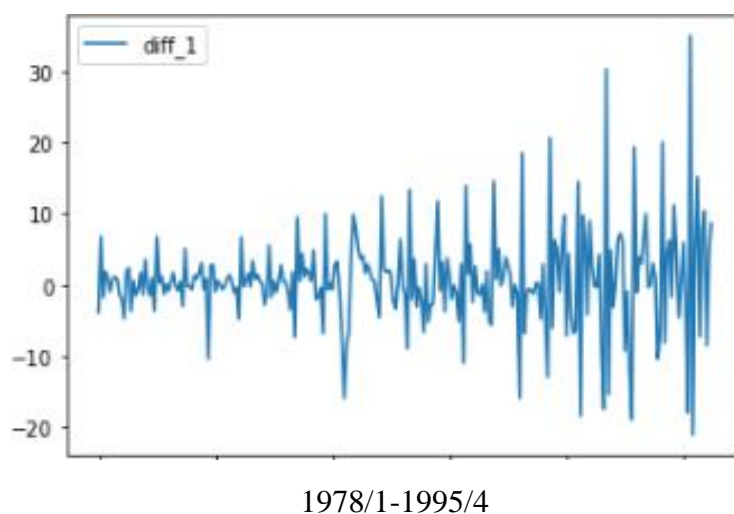


圖6、時間序列差分後圖示化

```

=====
Test Statistic                -3.921036
p-value                      0.001885
#Lags Used                   11.000000
Number of Observations Used  251.000000
Critical Value (1%)          -3.456674
Critical Value (5%)          -2.873125
Critical Value (10%)         -2.572944
dtype: float64
=====
The data is stationary. (Critical Value 1%)

```

圖7、差分後單根檢定

4.1.3 ARIMA(p, d, q)參數估計

在獲得一條平穩的時間序列後，就要開始對模型進行參數的估計，建構 ARIMA 模型主要是根據大期數的標準誤差所識別出顯著之模型階數並進行參數估計，根據大期數的標準誤差計算結果，顯著係數為趨勢性以 ARIMA(p, d, q) 模型表示之。

經過軟體運算後結果有 9 組估計模型是通過篩選，將此 9 組內部無存在自相關性之估計模型所得到的估計殘差，根據 Akaike (1974)，所提出之 AIC 方法計算出最小值之模型為最適切模型，簡單來說，AIC 的目的是找出訓練模型與實際模型最擬合參數，避免參數過度配置情形導致出現模型失準的問題，數值越小代表越擬合。

將資料輸入至統計軟體後，得到結果如表 2。

表 2、模型與其 AIC 值

ARIMA(0,1,0)	AIC=2.009
ARIMA(0,1,1)	AIC=1.755
ARIMA(0,1,2)	AIC=1.721
ARIMA(1,1,0)	AIC=1.861

ARIMA(1,1,1)	AIC=1.720
ARIMA(2,1,0)	AIC=1.781
ARIMA(2,1,1)	AIC=1.720
ARIMA(3,1,1)	AIC=1.715
ARIMA(3,1,2)	AIC=1.727

可以從結果表格中得知在ARIMA(3,1,1)時模型表現最佳，也意味著透過AIC所選出的模型是9組中估計出來與原數據最相近之模型。

4.1.4 模型診斷

本研究使用RMSE(均方根誤差)來診斷模型準確率，分別診斷預測3期與6期的誤差，與欲比較之研究相同，方便觀察與對比，結果如表3，從表格中可以看出雖然在長期的預測期時，ARIMA模型並沒有優於類神經網路與線性預測，但在短期預測方面時，每一個項目的RMSE皆小於另外兩種，也就是說，在此種類型的時間數列中，ARIMA在短期的預測能力是優於其他兩種的。

表3，預測期數與其 RMSE

	3 months ahead			6 months ahead		
	Liner	Neural Net	Arima	Liner	Neural Net	Arima
GERMANY						
Food Products	2.69	2.93	0.88	3.25	4.20	3.99
Chemicals	4.64	4.75	1.14	6.24	6.24	6.07
Basic Metals	4.32	3.87	2.10	4.48	4.97	4.55
Fabricated Metals	4.36	4.64	1.62	4.90	5.54	5.13
Machinery	3.45	3.56	1.02	2.98	3.20	3.07
Electrical Machinery	3.45	3.47	0.97	4.38	5.25	4.43
Electricity & Gas	3.16	4.36	1.01	3.52	3.56	3.02
Vehicles	5.96	8.67	3.81	5.40	5.50	5.51
France						
Food Products	2.09	2.10	0.43	2.04	2.02	2.31
Chemicals	3.80	3.80	0.69	3.49	4.40	3.72
Basic Metals	6.98	6.91	2.88	5.67	7.77	4.65
Fabricated Metals	3.99	5.65	2.23	6.43	7.10	5.22
Machinery	3.30	4.32	1.11	4.57	5.49	6.89
Electrical Machinery	4.59	4.80	1.62	5.36	5.23	4.67
Vehicles	9.81	13.58	4.40	14.78	14.11	10.31
Electricity& Gas	5.00	7.81	2.39	5.25	6.60	4.91
UK						
Food Products	2.07	2.13	0.33	2.31	2.26	0.18
Chemicals	2.02	1.97	0.25	1.98	2.06	2.01
Basic Metals	4.58	6.48	1.03	5.29	5.65	4.33
Fabricated Metals	3.23	3.80	0.98	3.94	4.16	2.32
Machinery	2.84	2.80	0.62	3.13	3.07	3.25
Electrical Machinery	3.76	4.20	0.4	3.58	3.70	2.25
Vehicles	5.09	5.64	0.11	6.56	6.70	4.23
Electricity & Gas	6.58	6.53	0.23	7.04	7.50	5.23

4.2 實際案例分析

4.2.1 資料蒐集

本研究所使用資料範圍為2000年1月1年到2021年12月，以影響台灣工業生產指數之產業為研究目標，根據公部門統計處統計篩選出六個占比較多之產業，這些產業加起來超過整體比例的一半之多，它們分別為：化學工業、民生工業、基本金屬、電子工業、機械工業跟電力與天然氣工業。將資料轉換成視覺化，如圖8。




圖8、各產業圖示化

4.2.2 判斷時間序列是否平穩

在得到視覺化的資料後，可以從圖中判斷出許多資訊，例如在 2008 及 2009 年時每個產業的指數都有大幅下滑現象，由於當是遇到金融海嘯而導致；或是，可以從圖中看出每筆資料都是有趨勢性的，也就是說我們大概可以判定它們皆為非平穩序列，以下將拆解出數列中的季節性循環，如圖 9 與進行 DF 單根檢驗以證實。

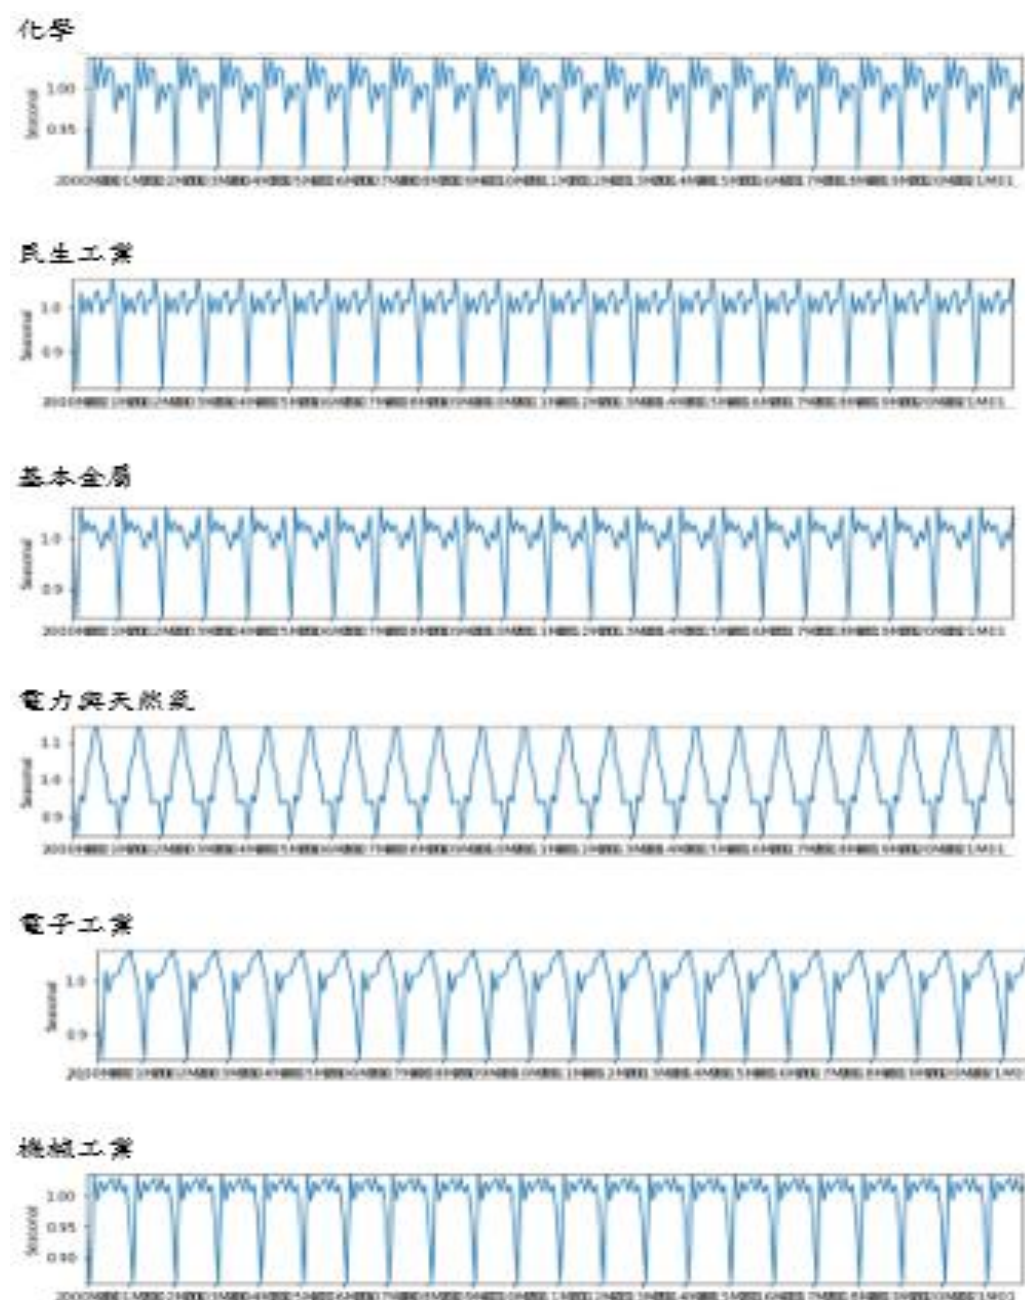


圖9、各產業季節性循環

本文依舊會對全部資料進行單根檢驗但將以趨勢較不明顯的民生工業為範例。因為其他資料經過視覺化，大致可以認定它們為非平穩序列，雖然在季節性中民生工業是有循環的，但在原始資料中很難看出其趨勢。

在 DF 檢定中，如果檢驗統計量小於臨界值，我們可以拒絕原假設，也就是說序列是平穩的，但當檢驗統計量大於臨界值時，則無法拒絕原假設也代表數列是非平穩的。

將民生工業資料輸入至統計軟體後，得到結果如圖10。

```
Results of Dickey-Fuller Test
=====
Test Statistic           -2.146407
p-value                   0.226268
#Lags Used                14.000000
Number of Observations Used 249.000000
Critical Value (1%)       -3.456888
Critical Value (5%)       -2.873219
Critical Value (10%)      -2.572994
dtype: float64
=====
The data is non-stationary, so do differencing!
Results of Dickey-Fuller Test
```

圖10 、民生工業差分前 DF 檢驗

從圖中可以看到檢驗統計量遠大於臨界值(Critical Value (10%))，因此下一步就需要進行差分處理。

在將原先六個時間序列經過差分處理後，我們可以得到新的序列，如圖11。從差分過後的圖形中可以明顯看到新的時間序列少了季節性，大多落點保持再-30~30之間，再將新的數列(民生工業)進行一次DF單根檢定，可以從檢驗統計量小於臨界值結果得知，時間數列已是穩態。如圖12

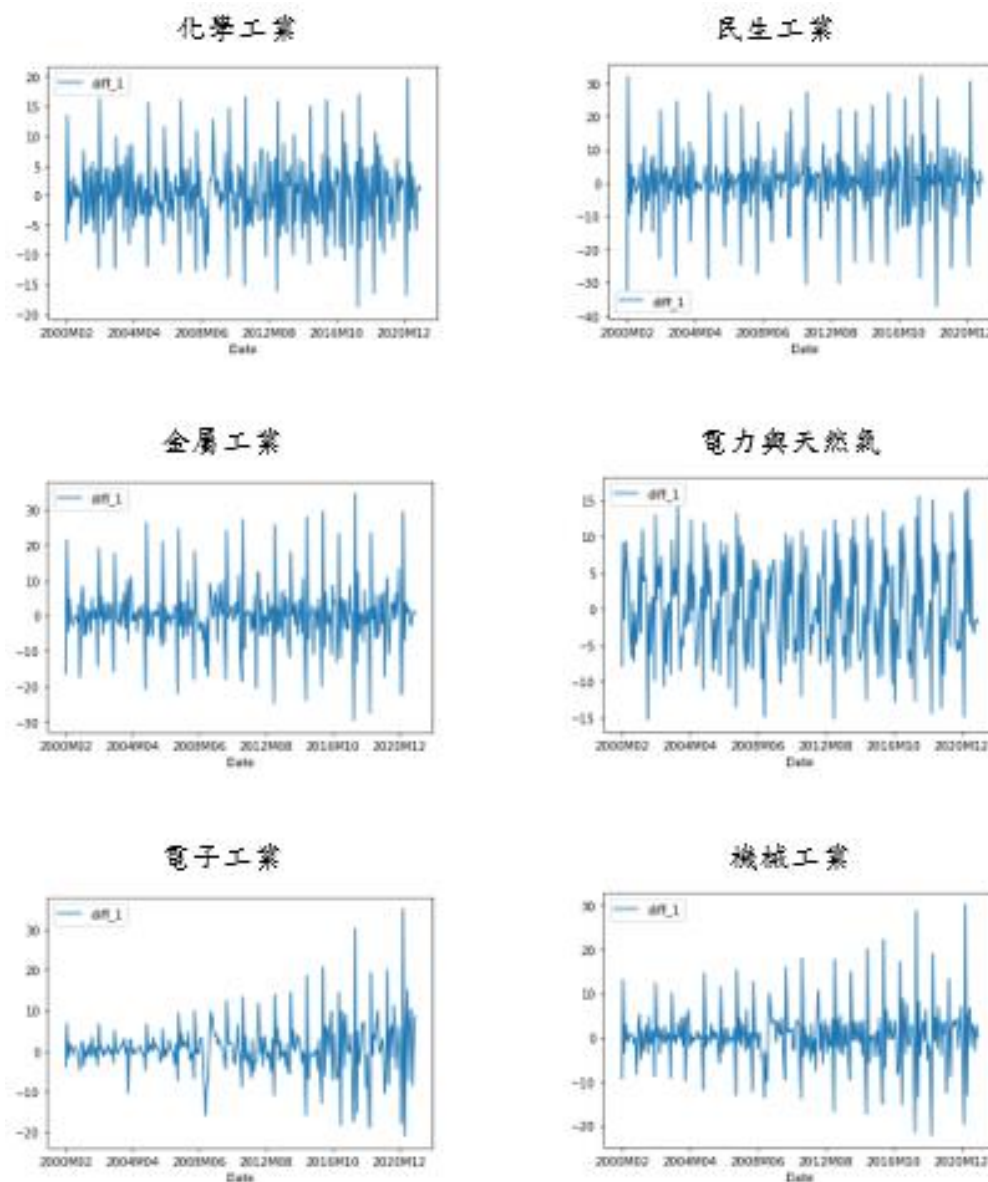


圖11、各產業差分後圖示化

```
=====
Test Statistic                -4.318032
p-value                       0.000413
#Lags Used                    13.000000
Number of Observations Used   249.000000
Critical Value (1%)           -3.456888
Critical Value (5%)           -2.873219
Critical Value (10%)          -2.572994
dtype: float64
=====
The data is stationary. (Critical Value 1%)
```

圖12、民生工業差分後 DF 檢驗

4.2.3 ARIMA(p, d, q)參數估計與預測

經過軟體運算後結果有 11 組估計模型是通過篩選，將此 11 組內部無存在自相關性之估計模型所得到的估計殘差，根據 Akaike (1974)，所提出之 AIC 方法計算出最小值之模型為最適切模型，得到結果如表 4。

表 4、民生工業不同參數 AIC

ARIMA(0,1,0)	AIC=2.009
ARIMA(0,1,1)	AIC=1.562
ARIMA(0,1,2)	AIC=1.655
ARIMA(1,1,0)	AIC=1.565
ARIMA(1,1,1)	AIC=1.502
ARIMA(2,1,0)	AIC=1.563
ARIMA(2,1,1)	AIC=1.657
ARIMA(3,1,1)	AIC=1.734
ARIMA(3,1,2)	AIC=1.798
ARIMA(3,2,2)	AIC=1.298
ARIMA(3,2,3)	AIC=1.691

可以從結果表格中得知在 ARIMA(3,2,2) 時模型表現最佳，也意味著透過 AIC 所選出的模型是 11 組中估計出來與原數據最相近之模型。

在得到最適參數後，就可以進入預測的環節了。根據上一小節得到的結果，ARIMA 在短期預測時較準確，因此在實際案例的預測也會以短期為主，將各產業得到最小 AIC 之 ARIMA(p, d, q) 如表 5，作為預測參數進行未來 3 個月的預測。得到結果如圖 13。

表5、各產業最佳模型參數

最佳(p, d, q)參數

電子工業 (2,1,3)

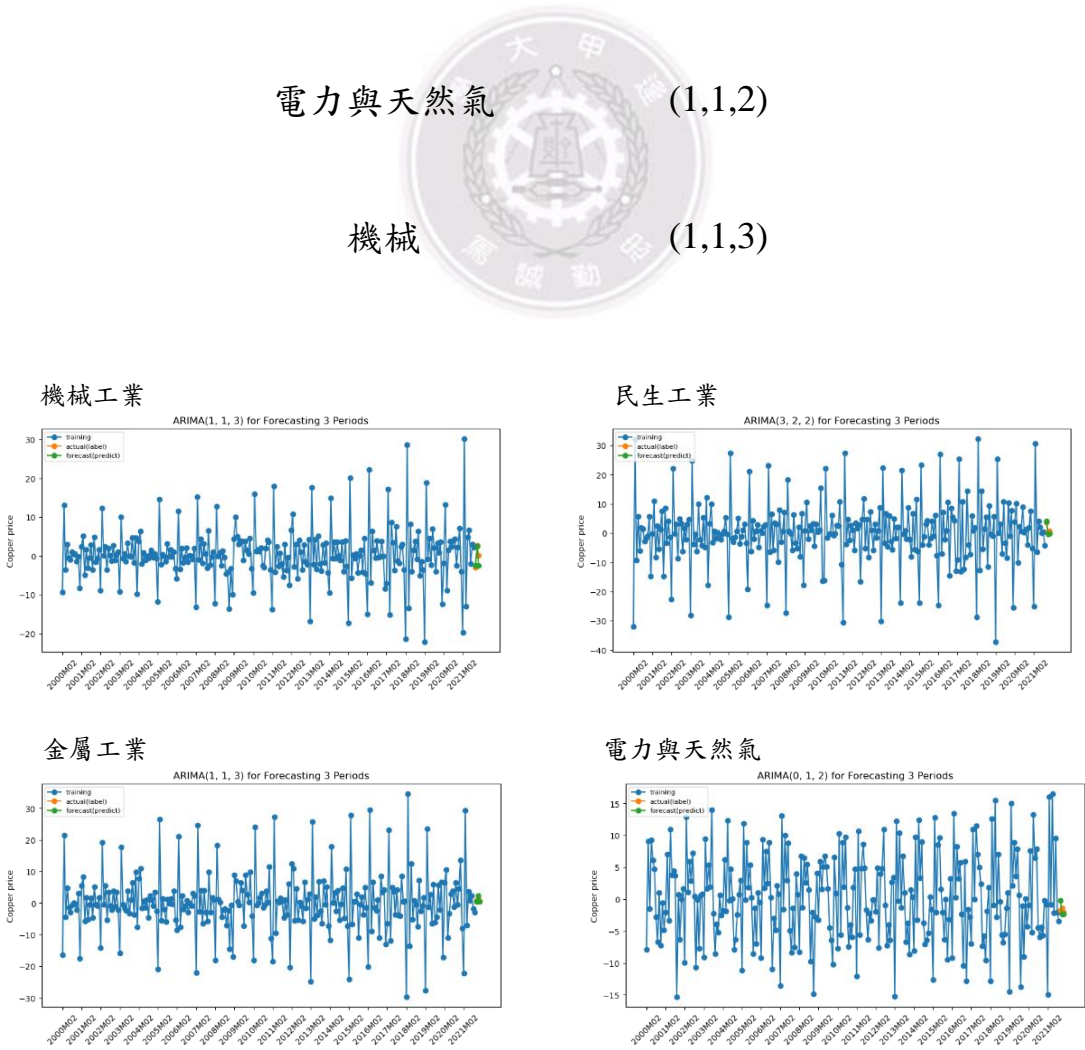
化學工業 (1,1,3)

民生工業 (3,2,2)

基本金屬 (1,1,3)

電力與天然氣 (1,1,2)

機械 (1,1,3)






圖13、預測趨勢與實際趨勢

從圖中可以看出，ARIMA 在預測趨勢方面的能力是相當優秀的，預測出的趨勢幾乎都與實際數據相同，但是本次研究依然會在下一個章節進行模型的診斷。

4.2.4 模型診斷

模型診斷的目的是要避免預測出的趨勢與實際趨勢之間的殘差過大，換句話說，診斷結果越接近 0 代表此模型越好。

本研究將前一小節預測六種產業的結果與實際值進行比較，RMSE 可以判斷兩者之間的殘差，若數值越小代表誤差越小，也代表模型越好，結果如表 6。

表6、各產業預測斷後RMSE誤差

	最佳(p, d, q)參數	RMSE
電子工業	(2,1,3)	4.0124
化學工業	(1,1,3)	0.6011
民生工業	(3,2,2)	0.6552

基本金屬	(1,1,3)	0.7160
電力與天然氣	(1,1,2)	1.0595
機械	(1,1,3)	1.5218

可以從表格中看到，在使用最佳參數所預測的趨勢模型表現都是相當良好的，各自的RMSE值都很小，這也意謂預測趨勢與實際趨勢間的誤差相當微小，並且間接證明此次之研究方法適合類似類型的時間序列。



第五章 結論與建議

面對競爭的大環境，人們時常以一個國家的 GDP 來衡量其是否為競爭力高的地區，以台灣來說，工業生產與 GDP 兩者間存在相當程度的關係。若能篩選出一個能預測此種類型的時間序列的模型，並有效預測未來趨勢，相信能供相關人士一些可用資訊。

5.1 結論

本研究提出運用差分整合移動平均自迴歸模型預測影響台灣工業生產指數的產業，透過分析過去歷史記錄所存在之自相關性與移動平均誤差特性，將訓練組的起點與終點設為2000年1月至2021年9月，預測組為2021年10月到2021年12月，經研究後得到之結論摘述如下：

一、與先前研究的方法進行比較，透過分析同一筆數據，將預測趨勢與實際趨勢進行 RMSE 誤差分析，可以發現儘管在長期預測時，本研究使用方法並未特別出色，有些案例的性能甚至較差；但在短期預測時，ARIMA 的預測則優於神經網路與線性預測。基於此原因，進行了本研究實際案例分析。

二、經過方法比較確定在短期預測時 ARIMA 的預測則優於神經網路與線性預測之後，進行案例分析。本研究針對影響台灣工業生產指數之產業進行分析，他們分別為化學工業、民生工業、基本金屬、電子工業、機械工業跟電力與天然氣工業，透過調

整與配置模型參數，對他們進行趨勢預測，將預測值與實際值比較後表明兩者誤差是相當小的，也證明 ARIMA 模型適合此種類型之時間序列。

5.2 建議

本研究以 ARIMA 進行預測模型建構，將觀測數據透過差分處理使其呈現趨近平穩狀態，然而事實上實際觀測數據可能呈現非線性關係，例如觀測值可能受到外在的社會經濟變化所影響，導致觀測數據呈現較大顯著之季節或趨勢性波動，然而當一旦發生重大事件時，預測結果有可能因為其他外在因素而有所變化，因此，後續研究可以嘗試結合多元迴歸模型，加入其他可能影響觀測數據之變因，或者是結合其他預測方法藉由修正未考慮外在變因時所造成的預測誤差，以期得到更加準確之估計結果。

參考文獻

一、中文部份

- 王柏晟與唐麗英(2014)。建構驅動 IC 封裝測試廠之製造成本預測模型-以 X 公司為例。未出版之碩士論文，交通大學管理學院工業工程與管理學程，新竹市。
- 江政儒(2020)。應用 ARIMA 建立公部門航空油料需求預測模型。未出版之碩士論文，國防大學運籌管理學系，桃園縣。
- 何武勇(2015)。中國大陸化妝品之零售價格趨勢研究。未出版之碩士論文，大葉大學財務金融學系，彰化縣。
- 余青芬(2014)。團體旅遊價格競爭策略對銷售效益影響之研究—兼論價格敏感度干擾效果。未出版之碩士論文，崇右技術學院經營管理系所，基隆市。
- 李天傑(2016)。以倒傳遞類神經網路演算法預測電力消費量—以台灣地區為例。未出版之碩士論文，中正大學訊資數位學習碩士在職專班，嘉義縣。
- 林淑娟(2014)。光學膜需求之預測方法研究。未出版之碩士論文，成功大學工業與資訊管理學系，台南市。
- 林淑華(2010)。總體經濟因子與台美匯率關係性之探討。未出版之碩士論文，樹德科技大學金融與風險管理系，高雄市。
- 徐志宏(2013)。台灣景氣對策信號編製之檢討。經濟研究，13，1-42。
- 洪承(2014)。房地產行銷策略研究~以代銷業銷售成功影響因素之探討。未出版之碩士論文，政治大學地政學系，台北市。

張書豪(2014)。進口服飾品牌銷售的天氣效應-以 P 品牌在百貨通路為例。未出版之碩士論文，台北大學國際財務金融碩士，台北市。

陳彥佑(2015)。倒傳遞類神經網路應用於心血管疾病患者住院天數預測。未出版之碩士論文，台北科技大學工業工程與管理系，台北市。

張智皓(2015)。適用於太陽能預測之多步預測即時回饋類神經網路。未出版之碩士論文，台北科技大學電機工程系，台北市。

許勝源與謝岱樺(2013)。冷藏飲品銷售預測模式建構與應用。建國科大社會人文期刊，32(2)，33-54。

陳怡靜(2014)。影響捷運運量因素之探討-以高雄捷運為例。未出版之碩士論文，中山大學經濟學研究所，高雄市。

郭明月與肖枝洪(2009)。時間序列分析與 SAS 應用武漢大學出版社 p. 198。

黃志偉(2015)。利用人工神經網絡分析短期負荷量-高雄捷運系統。未出版之碩士論文，成功大學交通管理科學研究所，台南市。

黃柏瑞(2016)。建構印刷電路板及積體電路出口產值預測模型-迴歸分析、ARIMA 與軟計算方法比較。未出版之碩士論文，輔仁大學統計資訊學系應用統計，新北市。

黃詩珉(2013)。臺灣觀光旅館營收預測模式之研究。未出版之碩士論文，台北科技大學經營管理系，台北市。

曹琇茹(2018)。運用 ARIMA 模型於汽車零件之需求預測與分析。未出版之碩士論文，明志科技大學工業工程與管理學系，新北市。

翁雅君(2015)。透過時間序列方法分析 YouBike 使用狀況：以信義

區為例。未出版之碩士論文，雲林科技大學資訊管理系，雲林縣。

饒秀華與林修葳與黎明淵(2001)。藉由分期 MS 模型分析台灣經濟景氣狀態。經濟論文，29(3)，297-319。

二、英文部份

Arunraj, N. S. and Ahrens, D. (2015). A hybrid seasonal autoregressive integrated moving average and quantile regression for daily food sales forecasting. *Int. Production Economice*, 170, 321-335.

Akaike (1974). A New Look at the Statistical Model Identification. *IEEE Transactions on Automatic Control*, AC- 19, 716-723.

Box, G. E. P. et al. (2015). *Time series analysis: forecasting and control*, 4th ed. NY: Wiley.

Babai, M. et al. (2013). Forecasting and Inventory performance in a two-stage supply chain with ARIMA(0,1,1) demand: Theory and Empirical analysis. *Int. Production Economice*, 143, 463-471.

Darbellay and Slama (2000). Forecasting the short-term demand for electricity: Do neural networks stand a better chance? *International Journal of Forecasting*, 2000, vol. 16, issue 1, 71-83.

Denise R. Osborn (2003). Linear versus Neural Network Forecasts for European Industrial Production Series. *International Journal of Forecasting*. Volume 20, Issue 3, July–September 2004, Pages 435-446.

Ramos, P. et al. (2015). Performance of state space and ARIMA models for consumer retail sales forecasting. *Robotic and Computer-Integrated Manufacturing*, 34, 151-163.

- Lau, a. H.et al. (2013). A demand forecast model using a combination of surrogate data analysis and optimal Neural network approach. Decision Support Systems, 54, 1404-1416.
- M. Ghiassi, M.et al. (2015). Pre-production forecasting of movie revenues with a dynamic artificial Neural network. Expert Systems with Application, 42, 3176-3193.
- Seed Herav(2003). Linear versus neural network forecasts for European industrial production series. International Journal of Forecasting, 20(3), 435-446.
- Su, Y. W.et al. (2012). Chinese tourists in Taiwan: Crowding out effects, opening policy and its implications. Tourism Management Perspectives, 4, 45-55.
- Tkacz(2001). Neural network forecasting of Canadian GDP growth International Journal of Forecasting, 2001, vol. 17, issue 1, 57-69.
- Vhatkar, S. and Dias, J. (2016).7th International Conference on Communication, Computing and Virtualization 2016 Oral-Care Goods Sales Forecasting Using Artificial Neural Network Model. Procedia Computer Science, 79, 238-243.
- Jozef Baruník J. and Malinská, B. (2016). Forecasting the term structure of crude oil futures prices with neural Networks. Applied Energy, 164, 366-379.
- Zhang 、 Patuwo and Hu (1998). Time series forecasting using a hybrid ARIMA and neural network model. Neurocomputing,50,159-175.