

天主教輔仁大學應用統計研究所碩士論文

指導老師：李鍾斌 博士

類神經網路與支援向量迴歸實作之投資決策模
擬-以台灣加權股價指數為例

**Practice of an Investment Decision Support
Model by Back-Propagation Neural and Support
Vector Regression – an Example of TaiEX.**

研究生：李侖璋 撰

中華民國九十九年七月

摘要

題目：類神經網路與支援向量迴歸實作之投資決策模擬——以台灣加權股價指數為例

校（院）系所組別：輔仁大學管理學院應用統計研究所

研究生：李侓璋

指導教授：李鍾斌 博士

論文頁數：69 頁

關鍵詞：技術指標、台指期貨、類神經網路、支援向量迴歸

論文摘要內容：

台指期貨自開賣以來便受到國人的喜愛，成交量一直是呈直線上揚趨勢，探討其原因是因為期貨除了有避險功能之外，另有投機功能及價格發現功能。投資人利用期貨預先以一定的價格可以提前買進或賣出商品的特性，藉此從中獲取價差的利益，因此便有了以技術分析藉以預測股價的行為。此外，股價指數的預測除了利用技術分析判斷未來趨勢決定投資的策略以外，還有利用統計模型或者是機器學習等方法預測股價指數。機器學習方法中，最常使用的為類神經網路 (Artificial Neural Network, ANN) 與支援向量機 (Support Vector Machine, SVM) 等。本研究欲搭配技術分析並且利用預測模型做股價指數的預測。而技術指標的種類繁多，本研究利用主成份分析法萃取新的主成分作為新的輸入變數。在預測模型上究竟是以變數數目多的技術指標變數有好的效果，或者是以維度較少且變數之間互相獨立的主成份為輸入變數的預測效果較好，對於兩種預測模型及輸入變數的選擇便為本研究所欲探討的主題，因此在類神經網路與支援向量迴歸的預測模型上比較以技術指標為輸入變數與以主成份變數為輸入變數的預測績效，最後以預測的隔日收盤價判斷漲跌方向模擬一投資交易策略，計算其累積報酬率。實證結果發現支援向量迴歸適

合利用主成份變數為輸入變數且投資模擬交易策略之下的累積報酬率最高；而類神經網路則是適合使用技術指標為輸入變數。另外三種指數期貨商品的投資報酬率則是以金融指數期貨累積報酬率最高，其次則是電子指數期貨，而台股指數期貨累積報酬率最低。



Abstract

Title of Thesis : Practice of an Investment Decision Support Model
by Back-Propagation Neural and Support Vector
Regression – an Example of TaiEX.

Name of Institute : Graduate Institute of Applied Statistics, College of
Management, Fu Jen Catholic University.

Name of Student : Li, Yi-Chang

Advisor : Dr. Li, Jung-Bin


Total Pages : 69 pages

Key Words : Specification, Taiwan index futures, Artificial
Neural Network, Support Vector Regression

Abstract :

TAIEX has been sold since 1987, and it has been widely accepted by numerous investors. This phenomena has shown that in addition to providing the function of hedging, futures also fit demands such as speculation and price discovery. Since the hedgers and speculators are the main players in the financial market, investors can obtain the profit of spreading from the target of futures and then advance to buy or sell merchandise for better price. Therefore, some scholars adopted technical analysis for price discovery in literature. Technical analysis is based on stock prices, trading volumes, price and volume changes and other time parameters of the market. These variables act as the basis for investment analysis. In addition to technical analysis, statistical models and machine learning methods are also used for decision making and price prediction. Artificial Neural Network (ANN) and Support Vector Machine (SVM) are the most straightforward and common tools among machine learning

methods. This study adopts technical indices and Principle Component Analysis to formulate input variables and put them in the proposed decision support model to help ordinary investors. The performance comparison between the two models built by ANN and SVM respectively and the choice of input variables are the two major topics this study intends to explore. The empirical finding of this study shows that the SVM model with input variables by Principal Component Analysis has the best performance in terms of both prediction accuracy and accumulative profitability. The ANN has better performance when using technical indices as input variables.



謝 辭

本論文得以完成，首先要感謝恩師李鍾斌老師的指導，謝謝老師不辭辛苦的教導學生，不管是論文研究上或者是做人處事道理，學生都受益良多。也要感謝口試委員王信忠博士和盧宏益博士，謝謝王老師遠道而來為學生進行學位口試，也謝謝兩位老師給予本論文的寶貴意見及建議使得本研究更臻完善。其次感謝家人在這兩年給我的幫助和鼓勵，讓我感受到家是唯一能遮風蔽雨的港口。也謝謝女友宜慧這兩年無怨無悔的陪伴，還記得口試前一天找我去聽音樂會，讓我在隔一日的口試不會如此緊張，壓力瞬間釋放，我會永遠印象深刻，謝謝妳！謝謝我的好友軒如和廖小琦，論文寫作的期間彼此之間的互相打氣和勉勵使我備感窩心並且更有動力的繼續努力下去。感謝兄弟的支持且不會在趕論文的期間打擾過讓我可以更專心的寫作。最後感謝所上的師長和同學，讓我在課業上能有所獲得。謝謝你們！



李侑璋 謹誌於

輔仁大學應用統計所

中華民國九十九年七月二十六日

目錄

目錄	I
表次	II
圖次	III
第壹章 緒論	1
第一節 研究背景與動機	1
第二節 研究目的	2
第三節 研究範圍	3
第四節 研究架構	5
第貳章 文獻探討	6
第一節 台股指數期貨相關文獻	6
第二節 技術分析相關文獻	8
第三節 類神經網路相關文獻	9
第四節 支援向量機相關文獻	10
第叁章 研究方法	13
第一節 類神經網路	13
第二節 支援向量機	17
第三節 技術分析	23
第四節 主成份分析	29
第肆章 實證研究	32
第一節 資料分析	33
第二節 倒傳遞類神經網路	44
第三節 支援向量迴歸	50
第四節 預測能力評比	54
第五節 投資績效分析	58
第伍章 結論與建議	63
第一節 結論	63
第二節 研究限制	64
第三節 後續研究建議	64
參考文獻	66
中文部份	66
英文部份	68

表次

表 1-3-1 台股期貨、金融期貨、電子期貨之契約規格.....	4
表 4-1-1 所選取的技術指標變數.....	33
表 4-1-2 台股指數相關係數.....	34
表 4-1-3 金融指數相關係數.....	35
表 4-1-4 電子指數相關係數.....	36
表 4-1-5 台股指數相關係數矩陣特徵值.....	38
表 4-1-6 金融指數相關係數矩陣特徵值.....	40
表 4-1-7 電子指數相關係數矩陣特徵值.....	42
表 4-2-1 整合主成份與類神經網路最佳參數整理表.....	49
表 4-3-1 台股指數支援向量模型.....	51
表 4-3-2 金融指數支援向量模型.....	52
表 4-3-2 電子指數支援向量模型.....	53
表 4-4-1 台股指數預測績效衡量指標.....	55
表 4-4-2 金融指數預測績效衡量指標.....	56
表 4-4-3 電子指數預測績效衡量指標.....	57
表 4-5-1 預測漲跌方向正確率.....	59
表 4-5-2 台指期貨交易費用.....	59
表 4-5-3 投資績效報酬率.....	62

圖次

圖 3-1-1 神經元運算過程	14
圖 3-1-2 多層前饋式網路	15
圖 3-2-1 決策函數分割圖	18
圖 3-2-2 尋找距離最大的兩分割超平面	18
圖 3-2-3 ε -Insensitive loss function	22
圖 4-1-1 台股指數主成份分析陡坡圖	39
圖 4-1-2 金融指數主成份分析陡坡圖	41
圖 4-1-3 電子指數主成份分析陡坡圖	43
圖 4-2-1 以主成份為輸入變數測試樣本之 RMSE 趨勢圖	45
圖 4-2-2 以技術指標為輸入變數之測試樣本之 RMSE 趨勢圖	45
圖 4-2-3 以主成份為輸入變數測試樣本之 RMSE 趨勢圖	46
圖 4-2-4 以技術指標為輸入變數之測試樣本之 RMSE 趨勢圖	47
圖 4-2-5 以主成份為輸入變數測試樣本之 RMSE 趨勢圖	48
圖 4-2-6 以技術指標為輸入變數測試樣本之 RMSE 趨勢圖	48



第壹章 緒論

第一節 研究背景與動機

科技的進步，電腦資訊的快速傳達，使得金融市場的貿易活動更為頻繁，投資人不需像以前一樣必須整天待在交易所盯盤，透過網際網路或者是媒體傳播的力量，使得“秀才不出門，能知天下事”。然而高科技的進步在金融市場並不一定會帶領投資人獲得利益，可能在投資決策的過程中稍有閃失便損失慘重，因此保守型的投資人希望能在金融市場的環境中降低風險兼獲利兩者兼顧，早期期貨推出的目的是為了避免損失的風險，然而期貨因為有操作技巧簡易，高槓桿倍數，及較無人為操縱的可能，所以期貨的商品越來越多元化。1987 年美國芝加哥商品交易所(CME)看好臺灣股市未來的前瞻性，推出第一筆關於台灣股價指數的期貨-道瓊台股指數期貨，同年新加坡國際金融交易所(SIMEX)也推出摩根台股指數，而美國芝加哥所推出的道瓊台股指數期貨由於投資人不熟悉及相關資訊不易尋找，因此不得其門而入，目前已無成交量，如同下市。國內由台灣期貨交易所(TAIFEX)於1998 年 7 月發行第一個關於本土的期貨商品 - 台股指數期貨，之後也陸續推出金融指數期貨與電子指數期貨等多樣商品，台指期貨自開賣以來便受到國人的喜愛，從一開始的日平均成交量 2223 口至現在的 98108 口，一直是呈直線上揚趨勢，探討其原因是因為期貨除了有前述避險功能之外，另有投機功能及價格發現功能。金融市場上是由避險者與投機者所組成，因此會有投資人利用期貨預先以一定的價格提前買進或賣出商品的特性，藉此從中獲取價差的利益。

在股價的預測上，對於價格發現功能便有技術分析的興起，技術分析是指以股市的市場價格、成交量、價和量的變化以及時間參數等市場行為作為投資分析的基礎。Fama 在 1970 年提出效率市場假說認為投資人皆為理性的投資者，而

且市場會立即反應新的資訊，因此價格變化是取決於新資訊的發生，股價呈隨機走勢，所以投資者不論利用基本分析或是技術分析甚至是內線消息皆不能因而持續地獲得超額報酬。然而 Elliot 於 1930 年提出波浪理論，認為股價會上漲下跌不斷重複就像海上的波浪一樣(Poser, 2003)，而此理論即是參考歷史資料的走勢判斷未來的趨勢，即為技術分析起源的概念，這是與效率市場假說相違背的。因此股價的預測便在學術研究上一直是熱門探討的主題。近期的學術研究也針對一些技術分析之功能，認為透過技術分析能獲得超額的利潤(Pruitt and White, 1988; Brock, Lakonishok and LeBaron, 1992; Levich and Thomas, 1993)。學術研究的發現間接證明效率市場假說並非一定存在，投資者仍可從過去股價及成交量變化等資料找出獲取差價超額報酬，因此技術分析在股市仍有一定的功效。

對於股價指數的預測除了利用技術分析判斷未來趨勢決定投資的策略以外，另有利用統計模型或者是機器學習等方法預測股價指數，最常使用的方法為類神經網路(Artificial Neural Network, ANN)與近幾年興起的支援向量機(Support Vector Machine, SVM)，其應用在相當多的領域，包含品管、醫療、電機、工程、資訊科技都有廣泛的討論。兩者共通的特點為原始資料不需前提的假設，即可套用在非線性的函數中，並且透過參數的設定，尋找最佳參數之後，往往會有不錯的效果，所以搭配技術分析並且利用預測模型做股價指數的預測。對於兩種模型預測的能力便為本研究所欲探討的主題。

第二節 研究目的

由於技術分析的指標非常多種，且技術指標的計算大多由開盤價、收盤價、最高價、最低價、成交量等換算而來，因此若採用多個技術指標作為輸入變數，彼此之間有可能存

在共線性的問題。共線性的問題過去在學理上可以利用主成份分析所轉換的主成分作為新的輸入變數予以解決，因此本研究目分為下列三個：

一、經過主成份分析後萃取出來的變數，是否對於研究模型的預測準確度有所幫助。

二、兩種預測模型類神經網路與支援向量機模型的預測能力並且比較以主成份為輸入變數與以技術指標為輸入變數套入兩種預測模型的結果。

三、為了驗證預測模型是否具有好的延伸性，同時避免只以台股指數期貨判斷兩種模型的預測效果，本研究另將金融指數期貨與電子指數期貨共計三筆資料作為模型的樣本資料，最後以模擬的投資策略進行投資交易驗證是否能獲得超額報酬，得出不同模式結果之比較。

第三節 研究範圍

(一) 研究對象

本研究的標的為台股期貨、金融期貨、電子期貨每日交易行情資料。「表 1-3-1」為三種期貨之契約規格。資料來源為台灣經濟新報資料庫(TEJ)。

(二) 研究期間

研究範圍以 2004 年 11 月 10 日至 2008 年 11 月 18 日止共 998 筆資料，其中 800 筆(2004 年 11 月 10 日至 2008 年 1 月至 29 日，約 80%)作為訓練資料，而剩下 198 筆(2008 年 1 月 30 日至 2008 年 11 月至 18 日，約 20%)資料則保留作為測試資料。

表 1-3-1 台股期貨、金融期貨、電子期貨之契約規格

商品	台股期貨	金融期貨	電子期貨
交易標的	發行量加權股價指數	金融類加權股價指數	電子類加權股價指數
英文代碼	TX	TF	TE
交易時間	營業日上午 8 點 45 分至下午 1 點 45 分		
契約價值	台股期貨指數*200 元	金融期貨指數*4000 元	電子期貨指數*1000 元
契約到期交割月份	自交易當月起連續兩個月份，另加上 3、6、9、12 月中 3 個接續的季月，總共 5 個月份的契約在市場交易。		
每日結算價	交易日下午 1 點 45 分的收盤價		
漲跌幅限制	漲跌幅限制在最大為 7% 於前一營業日的結算價		
最小升降單位	1 點為=200 元	0.02 點=200 元	0.05 點=200 元
最後交易日	該契約交割月份第三個星期三		
最後結算日	最後結算日同最後交易日		
最後結算價	以最後結算日臺灣證券交易所當日交易時間收盤前三十分鐘內所提供標的指數之簡單算術平均價訂之。		
交割方式	以現金交割，交易人於最後結算日依最後結算價之差額，以淨額進行現金之交付或收受。		
部位限制	自然人 300 個契約		
	法人機構 1000 個契約		
	法人可向期交所申請豁免部位限制		
原始保證金	7.5 萬元	6 萬元	7.5 萬元
維持保證金	5.8 萬元	4.6 萬元	5.8 萬元
結算保證金	5 萬元	4 萬元	5 萬元

資料來源：台灣期貨交易所 <http://www.taifex.com.tw/chinese/home.asp>

第四節 研究架構

本論文共分為五個章節，第壹章為緒論，介紹研究背景與動機、研究目的、研究範圍及研究架構；第貳章文獻探討，主要是針對指數期貨與應用類神經網路與支援向量迴歸的文獻，以及介紹技術分析的方法與應用。第參章研究方法為大略說明類神經網路、支援向量機與主成份分析之理論。第肆章實證研究，探討類神經網路與支援向量機的最佳參數解，比較兩種預測模型的結果。並且就本研究預測的結果，以投資交易策略比較模擬交易的績效，以買入持有的策略與過往的文獻做一綜合評比。第五章為本研究的結論與未來建議。



第貳章 文獻探討

本研究欲以指數期貨為研究標的，技術指標為原始的輸入變數，以類神經網路與支援向量機為研究方法，因此本章的主旨在探討股市期貨的應用、技術分析以及類神經網路與支援向量機等相關文獻。

第一節 台股指數期貨相關文獻

期貨是緣自於農產品交易市場。早期農夫花上幾個月的時間等待農作物的收成，但是農作物產品在今日的價格並不一定會等於往後的價格，農夫會希望價格越高越好，而市場上的商人當然希望能以較低的價格買進。農夫為了避免日後的價格下跌，商人擔心日後價格上漲，買賣雙方以少許的保證金簽訂契約，在訂定的日期以約定的數量及價格將產品賣出。因此期貨一開始的目的其實是為了避險，以少數的保證金購買未來期貨價格的契約，避免承擔損失的風險。而此農產品契約的觀念也發展至金融市場商品的股價指數期貨，也就是以未來的股價指數作為交割標的物。

股價指數的組成為加權平均股價除以基期的加權平均股價，加權平均股價為現在所選出的上市股票之發行量當作權數將所選的股票價值加總；而基期的平均股價指數代表當初剛開始發行所選的股票。兩者相除乘上 100 便為加權股價指數(李宗祥，1989)。股價指數期貨是近代發展出的衍生性金融商品，它提供股票投資人、基金經理人一個避險管道，並使之可以更有效率的調整現有部位，同時它也提供一個低交易成本、高財務槓桿、高流動性的交易環境，使交易人能更有效、更廣泛地參與股票市場。1987 年美國芝加哥商品交易所(CME)率先推出第一筆關於台灣股價指數的期貨-道瓊台股指數期貨，而 1998 年 7 月台灣期貨交易所(TAIFEX)也發行關於本土的期貨商品--台股指數期貨，而台指期貨是否在金融市場符合效率市場假說與能否從中獲取價差的利益，以及期

貨避險的效用也引起相當多的研究。效率市場假說是由美國經濟學家 Fama(1970)提出，此假說之下有三個前提假設：(1) 投資人皆為理性的，並不會盲目的跟從別人而隨之起舞，因此對於股票分析為獨立自主追求最大利益；(2) 新資訊的出現是為隨機性，也就是說即使是非理性投資者被視為隨機產生的結果，因此經過交易以後，會消除對市場價格的影響。(3) 市場會因為新資訊的發生而馬上調整價位。由於資訊都是突發事件，因此股價是隨機不可預測的。作者又將市場效率性質提出弱式效率 (Weak Form Efficiency)、半強式效率 (Semi-Strong Form Efficiency) 及強式效率 (Strong Form Efficiency)。弱式效率代表不能從過去股價的技術分析得到未來股價的資訊；半強式效率表示除了過去股價的技術分析以及情報分析得到未來股價的資訊；強式效率表示除了上述兩種效率以外，就連內線交易也無法獲得關於未來股價的資訊。因此效率市場假說常常被作為驗證股票市場是否健全的指標。

關於國內學者對期貨商品的研究，何宣儀(2000)以台股、金融與電子期貨為研究對象，利用投資組合與現貨指數間之報酬率誤差平方和最小化的方法，研究發現台股期貨市場符合弱式效率市場假說，至於金融與電子期貨，因為不符合效率市場假說，因此套利機會較多。推測原因為可能是對於金融指數期貨與電子指數期貨發展尚未成熟，面臨的風險較大，獲利的機會也會較大，投資者會以小搏大的心態從事套利交易。此外，江天佑(2003)針對台股指數之期貨之避險效果進行探討，利用傳統避險理論，認為期貨市場有規避風險功能，結合簡單避險法及最小左尾動差法，其原則為避險者應該持有現貨部位相等但方向相反之期貨部位，以此作為模擬投資的策略。研究結果發現簡單避險法與最小左尾動差法所得的報酬率分別為 0.49% 與 0.56% 高於未避險的報酬率 0.36%，顯示利用台股指數從事避險交易優於未避險的操作方式。

第二節 技術分析相關文獻

Fama(1970)的效率市場假說認為市場股價為隨機過程，所以未來的股價是不能依照過去的歷史資料分析而預測。然而，許多學者認為技術分析並非不能打敗大盤。Brock *et al.*(1992)以道瓊工業指數為研究標的，在 1897 年至 1986 年止的研究期間內，利用區間突破法則與移動平均線探討技術交易法則的有效性。研究發現模擬投資交易的報酬率優於買進持有策略。Pruitt and White(1998)也以相對強勢、移動平均線及累積成交量三種技術指標做交易規則，以 204 種股票為研究標的，研究結果顯示在交易成本千分之二十以下皆可獲得超額報酬。關於國內的研究也有探討利用技術分析模擬投資交易的文獻。陳勁帆(2005)以台灣 50 指數成分股中的 22 檔電子股為研究對象，研究期間 2000 年 1 月至 2005 年 4 月底止，利用統計製程管制圖判斷買賣訊號為研究方法探討利用技術指標進行模擬投資交易策略。研究發現在價的買賣訊號使用移動平均線與 EWMA 成交量買賣訊號均能獲得正的報酬。

Levich and Thomas(1993)則是以加幣、英鎊、日圓、馬克和瑞士法郎等外匯期貨為研究標的，研究期間為 1976 年到 1990 年止，利用濾嘴法則與移動平均線進行模擬投資交易策略，經過風險和交易成本的調整後，能獲得超額報酬。

前述之研究證明技術分析對股價的預測並非無效，因此本文以常用的十種技術指標相對強弱指標(RSI)、指數平滑異同移動平均線(MACD)、隨機指標(KD)、移動平均線(MA)、平均成交量(MV)、趨向指標(DMI)、威廉指標(WMS%R)、動量指標(MTM)、乖離率(BIAS)、心理線(PSY)作為原始輸入變數，模擬投資交易策略，驗證預測的績效。

第三節 類神經網路相關文獻

類神經網路由於有強大的學習能力，且不需前提假設，因此在應用的範圍上相當廣泛，在非線性的資料中，往往能比統計模型(迴歸分析、時間序列 ARIMA 模型等)處理的效果還要好，以下介紹近年應用於類神經網路於財務的文獻：

國外在類神經網路對股價指數預測的研究上，Komo, Chang and Ko(1994)以類神經網路預測每月道瓊工業指數，並以 RBF 類神經網路與 MLP 類神經網路做預測能力比較，研究發現預測漲跌方向其正確率皆超過九成以上，且 RBF 類神經網路正確率較 MLP 類神經網路高。另外 Kim and Han(2000)則是以日常韓國股價指數(KOSPI)為研究對象，研究期間自 1989 年 1 月至 1998 年 12 月，以基因演算法結合倒傳遞類神經網路，以隨機指標、相對強弱指標、威廉指標為輸入變數，研究結果發現結合的模型可以改進學習速率，並且縮減特徵空間的維度，預測漲跌方向準確率也高於未結合類神經網路模型。

國內的學者對台灣股價指數的研究上，楊琪倫(2002)以台灣期貨指數自 1998 年 10 月 2 日至 2000 年 12 月 31 日，以類神經網路以及 GARCH 模型、隨機漫步模型作為研究方法，研究結果顯示類神經網路預測的績效優於 GARCH 模型及隨機漫步模型，另外作者也發現台灣期貨指數開盤價預測上，增加國際股市與期貨市場的資訊可提高預測的準確度。而過往的文獻上，有學者以主成分分析法找適當的輸入變數，王基瑩(2004)以台灣期貨電子指數、金融指數、台股指數自 1998 年 1 月 3 日至 2000 年 9 月 30 日，先以相關係數及主成份分析法找出類神經網路的輸入變數藉以預測電子指數、金融指數及台股指數之開盤價與收盤價，研究結果顯示透過主成份分析找出適合的輸入變數後並以預設之交易策略來驗證電子指數、金融指數及台股指數確實具有超額報酬與準確度。

第四節 支援向量機相關文獻

Vapnik(1995)提出支援向量機的模型，根據結構化風險最小誤差法(structural risk minimization, SRM)將一般化誤差(generalized risk)設立最小的上限，目的是希望在期望誤差中找到最小值使支援向量機能夠一般化，其原理為透過適當核心函數(kernel function)的定義後將訓練樣本轉換至高維度的特徵空間進行分類。

支援向量機為近幾年興起的機器學習方法，因此常以類神經網路做預測模型的比較，Tay and Cao (2001)以芝加哥期貨交易所中五種期貨指數為研究標的。作者將原始收盤價轉換為前五日、前十日、前十五日、前二十日的相對漲跌幅度以及指數平滑加權平均指標作為輸入變數，並以支援向量迴歸與倒傳遞類神經網路作為預測模型藉以預測未來五日的漲跌幅度。在向量支援迴歸的核心函數選取方面，採用高斯函數作為核心函數的運算，研究結果指出在標準平均誤差值(normalized mean squared error, NMSE)、絕對平均誤差值(mean absolute error, MAE)、加權方向對稱性指標(weighted directional symmetry, WDS)支援向量迴歸之值比倒傳遞類神經網路來得小。而國內研究上也以支援向量迴歸和支援向量機與類神經網路，三種預測方法比較其預測效果。陳雅雯(2003)以台灣證券交易所公開上市個別股票中選取第一類股的九家公司自1998年1月1日至2001年12月31日的交易資料。作者先將選取的股市開盤價、收盤價、最高價、最低價、成交量等基本資料轉換成技術指標，然後以主成分分析取出較高的指標再以各成分包含的指標以逐步迴歸分析做輸入變數的篩選，預測模型以支援向量迴歸(support vector regression, SVR)和支援向量機(support vector machine, SVM)兩種方法預測股價的漲跌方向，其中SVR是先預測股市收盤價後再判斷其漲跌方向。研究結果顯示支援向量機分類正確率為

76.73%，支援向量迴歸分類正確率為 73.68%，兩者方法皆優於傳統類神經網路的分類正確率 55%。最後作者以支援向量迴歸預測出的股價做為模擬投資的基準，再利用漲跌方向判斷買賣時機，以這九家的公司股票為投資組合所得到的報酬率 20.81%與郵局定期存款平均利率相比 3.54%相比，具有超額報酬。

另外在選取輸入變數方面，利用傳統統計方法搭配支援向量機，在研究上也獲得不錯的效果。黃敏菁(2005)以 2001 年 1 月 2 日 2004 年 12 月 24 日間的台灣加權股價指數為研究標的，採係數 t 值檢定法篩選出作為預測模型的輸入變數再以支援向量機與類神經網路預測下一個交易日之台灣加權股價指數，研究結果顯示支援向量機在預測漲跌方向中預測正確率為 95%高於類神經網路的預測正確率 84%。劉翔瑜(2006)以日經 225 自 1999 年 9 月 1 日 2004 年 10 月 1 日現貨指數的開盤價為實證資料，作者以不同的輸入變數組合建構兩種模型並以向量支援機與倒傳遞類神經網路作為預測工具，主要目的為預測日經 225 現貨開盤價，研究結果發現以市價、最高價、最低價和前日收盤價作為輸入變數的組合對預測隔日開盤價並沒有有效的幫助增提升預測準確度，另外作者研究在兩種模型的建構下以支援向量迴歸的預測準確率皆優於類神經網路。

最後是除了選取較好的輸入變數得到好的效果，還有模型之間的整合，Pai,Chang,Lin and Hong (2005)以十間上市上櫃公司的股價為實證資料，研究時間自 2002 年 10 月 21 日至 2003 年 2 月 28 日，指出在時間序列的預測上自我迴歸移動平均模型(Autoregressive Integrated Moving Average Model, ARIMA)雖然是常常被廣泛討論，但是 ARIMA 模型通常在線性的情況才會有較好的預測效果，然而現實資料卻常常是非線性，因此預測的績效通常不佳。研究者利用 SVM 成功解決非線性迴歸模型的參數問題，因此整合 ARIMA 模型及 SVM 模型以預

測股市的收盤價。研究結果發現整合模型預測效果經由 MAE、MSE、MAPE、RMSE 與 ARIMA、SVM 模型比較，其預測效果為最佳。林船全(2008)以台指選擇權為研究樣本，資料區間自 2007 年 1 月 1 日至 2007 年 6 月 30 日。作者用價格指標整合獨立成分分析法 (independent component analysis,ICA)與支援向量迴歸(support vector regression,SVR)預測台指選擇權隔日價格的結算價並與未整合支援向量迴歸的預測結果做比較，研究結果顯示整合獨立成分分析法與支援向量迴歸的預測效果優於單純支援向量迴歸模型。另外作者指出類神經網路有三點不利條件：(1)模型需要依賴大量的參數，即網路規模、學習參數和初始值加權選取；(2)可能在非常慢的收斂下陷入局部最小點的結果；(3)訓練資料有可能過度配適導致缺少一般化的能力。



第叁章 研究方法

對於現代資料數量龐大，動輒數以萬筆，資料採礦(data mining)的研究越來越被廣泛的討論。因此想從數據中挖掘出一些有用的資訊，必定從資料採礦的技術加以下手。在數據上最常使用的方法便是分類的使用，而通常利用的方法有邏輯斯迴歸(Logistic Regression)、分類樹(Classification Tree)、Nearest Neighbor、及廣泛被討論的類神經網路(Neural Network)與近幾年興起的支援向量機(Support Vector Machine)，本研究以類神經網路與支援向量機為探討的方法，因此將其主要概念說明如下：

第一節 類神經網路

類神經網路(Artificial Neural Network, ANN)是近代新興的機器學習工具，但是類神經網路發展的過程卻不是那麼的順遂。早在 1943 年心理學家 McCulloch 和數學家 Pitts 共同提出類神經網路的概念，然而在發展的過程中，1969 年 Minsky 和 Papert 提出此時的類神經網路連簡單的 XOR 問題都解決不了(葉怡成，2003)，因此類神經網路的研究便開始陷入低潮，直到爾後多層感知器的出現解決了 XOR 問題，以及在 1982 年 Hopfield 提出 HNN 網路，類神經網路的研究才慢慢被大眾所接受。時至今日類神經網路已被廣泛的應用在各個領域，舉凡電機、資工、土木等理工領域到財務管理、經濟等以及醫藥相關都有應用類神經網路方法的研究。

類神經網路一直被持續探討的其中原因之一是不需任何的數學假設，因此對於任何資料皆可以使用類神經網路來做為預測的工具。此外，類神經網路的優點還有能解決最佳化、非線性系統問題以及具有高容錯的能力。類神經的網路的基本概念是以大腦神經網路傳遞反應的想法；輸入向量經過一組權重 w_i 後將資料傳給作用函數，而權重 w_i 可以為正或為負，以大腦神經的例子來說便是控制刺激反應或是抑制反

應，作用函數是將加權後的資料做一加總，再將加總後的資料做非線性轉換得到輸出值。圖 3-1-1 為神經元運算過程。




圖 3-1-1 神經元運算過程

以數學的觀點神經元 k 的計算過程能用下列式子(3.1.1)、(3.1.2)表示：

$$\sum_{i=1}^n w_{ki} x_i + b_k = net_k \quad (3.1.1)$$

$$F(net_k) = y_k \quad (3.1.2)$$

輸入向量 x_i 與 w_{ki} 相乘加總後在與偏權值 b_k 相加後為 net_k ，而(3-1-1)式中的 net_k 經過非線性轉換後便可以得到輸出值 y_k 。使用非線性轉換的原因是為了防止輸入向量會有非線性的特性，因此經過轉換後會有較好的預測效果，經常使用的非線性轉換函數為雙彎曲函數(Sigmoid Function)與雙曲線正切函數(Hyperbolic Tangent Function)(劉翔瑜，2006)。函數式分別表示如下：

1. 雙彎曲函數

$$f(x) = \frac{1}{1 + e^{-x}} \quad \begin{matrix} x \in (-\infty, \infty) \\ y \in [0, 1] \end{matrix} \quad (3.1.3)$$

2.雙曲線正切函數

$$\begin{aligned} f(x) &= \tanh(x) & x &\in (-\infty, \infty) \\ y &\in [-1, 1] \end{aligned} \quad (3.1.4)$$

倒傳遞類神經網路

前面敘述為類神經網路的基本概念，然而類神經網路卻有許多種的架構模式，其中倒傳遞類神經網路（Back-Propagation Neural Network，BPN）因為學習精度高，回想速度快，輸出變數可為連續性數值，因此能處理較複雜的非線性函數或分類問題等，所以較被大眾所使用。本研究也將採用倒傳遞類神經網路預測股價指數的收盤價。倒傳遞類神經網路屬於多層前饋式網路並且以監督式學習法來處理網路學習的過程。而多層前饋式網路代表至少含有一層或多層的隱藏層，其功能為調節網路內部輸入值與網路整體輸出值，也因為隱藏層的加入才可以解決 XOR 或較複雜的非線性問題，以圖 3-1-2 表示：




圖 3-1-2 多層前饋式網路

監督式學習法是給定訓練樣本依照目標值與預測值的誤差調整權重的大小，使得目標值與預測值的誤差可以縮小到介定的範圍內，所以會是以目標值與預測值的誤差最小化為準則。解決最小化的問題可利用最陡坡降法解決，通常目標

值與預測值的誤差以均方誤差法來就做為誤差函數 E ，函數式表示如下(劉翔瑜，2006):

$$E = \frac{1}{2} \sum_k (T_k - Y_k)^2 \quad (3.1.5)$$

T_k 為第 k 個神經元的目標輸出值

Y_k 為輸出層第 k 個神經元的網路輸出值

當一訓練資料進入時，網路就會依照誤差函數重新調整權重大小，因此調整幅度會與誤差函數對權重值的導函數大小成正比，以下列式子表示：

$$\Delta w_{ji} = -\eta \frac{\partial E}{\partial w_{ji}} \quad (3.1.6)$$

(3.1.6)中的 η 為學習速率，控制了最陡坡降法修正誤差的步伐，因此學習速率的選擇變得格外重要。 η 太小時會使得誤差函數變小速度會很慢， η 太大容易造成過度配適(over fitting)的情況發生。新的權重將會以上一筆訓練資料的權重加上調整權重的幅度，可以下列式子(3.1.7)表示：

$$w_{ji}(Z) = w_{ji}(Z-1) + \Delta w_{ji} \quad (3.1.7)$$

類神經網路因此需要控制許多的參數，包括輸入變數的選擇、隱藏層數、各個隱藏層神經元的個數、權重值的大小、學習速率的決定以及容忍的誤差範圍等多項須要考慮的方面。關於隱藏層的層數選擇，以往學者的研究通常建議一層或兩層為主，多於兩層的隱藏層數其預測效果並沒有比較好(Davies，1994)，而對於一層或兩層的結果，往往通常需要去分別實驗做比較。而輸入變項以往都依靠過往的文獻研究、經驗法則或者是專家建議選取適當的輸入變數，利用試誤法檢測變數對於預測效果是否有顯著的關係。

第二節 支援向量機

原始的支援向量機(SVM)是為了將資料分成特性不同的兩種分類，其主要思維是在高維度之特徵空間中找尋一個擁有兩分割超平面距離最大化的最佳超平面 (Optimal Hyperplane)，使得兩種不同類型的資料可以有效的分割(謝弘一，2005)。

假設在處理二元分類的問題，有一資料集 $(x_1, y_1)(x_2, y_2) \cdots (x_n, y_n)$

$$x_i \in \mathbb{R} \quad y_i = \begin{cases} +1 \\ -1 \end{cases}$$

在有限維度 R^n 中可以有一個超平面(Hyperplane)將資料以線性分割的方式分隔出來，此超平面 H_{wb} 可以以下列所示：

$$\begin{aligned} w^T x + b &= 0 \\ w_i, x_i, b &\in \mathbb{R} \end{aligned} \quad (3.2.1)$$

w : 為權重向量， b : 為偏移量

此分割的超平面便可以判斷資料的分類是屬於 $y=+1$ 這一類別，或者是 $y=-1$ 這一類，因此利用訓練資料尋找適當的超平面，而創造一個決策函數(decision function)式子如下：

$$d_{wb}(x) = \sum_{i=1}^n w_i x_i + b = w^T x + b \quad (3.2.2)$$

$$w_i, x_i, b \in \mathbb{R}$$

上列(3.2.3)式決策函數做為資料的分類規則如下：

$$\begin{cases} d_{wb}(x) > 0 & \text{if } y_i = +1 \\ d_{wb}(x) < 0 & \text{if } y_i = -1 \end{cases} \Rightarrow \begin{cases} w^T x + b > 0 & \text{if } y_i = +1 \\ w^T x + b < 0 & \text{if } y_i = -1 \end{cases} \quad (3.2.3)$$

見圖 3-2-1 所示：




圖 3-2-1 決策函數分割圖

由於圖 3-2-1 是資料可線性分割，代表資料的散佈是不會在 H_{wb} 上，因此必定會有兩個平行的超平面且可以將資料分隔開來，而 SVM 所追求的便是此兩超平面 H_1 、 H_2 幾何距離最大化。見下圖 3-2-2




圖 3-2-2 尋找距離最大的兩分割超平面

如果資料可完全分割，必能有兩超平面將資料分隔開來，因此決策函數可以將(3.2.3)式寫為

$$(w^T x + b) \cdot y_i \geq 1 \quad \text{for } i = 1, \dots, n \quad y_i = 1 \text{ or } -1 \quad (3.2.4)$$

而此兩超平面 H_1 、 H_2 以下式表示：

$$\begin{aligned} H_1: w^T x + b &= 1 \\ H_2: w^T x + b &= -1 \end{aligned} \quad (3.2.5)$$

其中 H_1 、 H_2 為分割資料的超平面亦稱為支援超平面 (Support Hyperplane)，而落在 H_1 、 H_2 的點所形成的向量便為支援向量 (Support Vector) (Vapnic, 1998)。

對於尋找最佳超平面意即兩支援超平面 H_1 、 H_2 距離最大，因此兩支援超平面到最佳超平面距離各表示如下：

$$\Rightarrow \|H_1 - H_2\| = \|H_1 - H\| + \|H - H_2\| = \frac{1}{\|w\|^2} + \frac{1}{\|w\|^2} = \frac{2}{\|w\|^2} \quad (3.2.6)$$

所以 SVM 的原理是求 $\max \|H_1 - H_2\|$ 。相同求 $\max \frac{2}{\|w\|^2}$ ，等價於 $\min \frac{\|w\|^2}{2}$ ，因此目標式以下列式子表示：

$$\begin{aligned} \min \frac{\|w\|^2}{2} \\ \text{subject to: } (w^T x + b) \cdot y_i \geq 1 \quad \text{for } i = 1, \dots, n \end{aligned} \quad (3.2.7)$$

為求解(3.2.7)式可利用 Lagrange 法將具有限制式與目標式合併，式子將變成如下：

$$\min_{w, b} \max_{\alpha} L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i [y_i (w^T x + b) - 1] \quad (3.2.8)$$

α_i 為Lagrange 乘數, $\alpha_i \geq 0 \quad i = 1, 2, \dots, n$

鬆弛變數(slack variable)

以上所敘述的 SVM 是建立在假設資料可完全分割的情況，但是對於資料的散佈，有時候不一定可以完全分割，因此在原始的目標式 (3.2.11) 中給予鬆弛變數 ξ (Vapnik, 1995)。給定 ξ 的目的是為了在資料不能完全分割的情況下，容許些微的資料分類錯誤使得可以求得更好的預測效果，加入鬆弛變數的目標式與條件式表示如下：

$$\begin{aligned} \min \quad & \frac{\|w\|^2}{2} + C \sum_{i=1}^n \xi_i \\ \text{subject to: } & (w^T x + b) \cdot y_i \geq 1 - \xi_i, \quad \xi_i \geq 0 \\ & \text{for } i = 1, \dots, n \end{aligned} \quad (3.2.9)$$

式子 (3.2.18) 中的 C 為控制變數影響到 SVM 對容忍分類錯誤的程度。如果 C 越大則容許分類錯誤的程度較大，但是兩分割超平面的幾何距離就會變小，如果 C 越小容忍分類錯誤的程度較小，因此與當初所想求的分割超平面幾何距離就會比較大，而 C 的大小決定便是對容忍分類錯誤所重視的程度。

核心函數(kernel function)

在假設資料皆可完全被線性分割，又或者是加入了鬆弛變數容許分類錯誤的狀況之下，對於有些資料太過複雜或者很多變數的關係導致分類的效果還是不好時，Boser, Guyon and Vapnik (1992) 提出利用核心函數將資料映射至高維度特徵空間以後，資料將能在空間中，使用前述的方法做線性的切割，並且尋找最佳的分類超平面。因此在計算方面，需先給定一轉換函數 ϕ ，使得

$$\begin{aligned} x &= (x_1, x_2, \dots, x_n) \\ \Rightarrow \phi(x) &= (\phi(x_1), \phi(x_2), \dots, \phi(x_n)) \end{aligned} \quad (3.2.10)$$

由於 (3.2.16) 的 $\langle x_i, x_j \rangle$ 為內積形式，因此為了將資料轉換至特

徵空間，所以 $\langle x_i, x_j \rangle$ 將改變成 $\langle \phi(x_i), \phi(x_j) \rangle$ ，其中 $\langle \phi(x_i), \phi(x_j) \rangle$ 可寫成核心函數(kernel function)的形式 $k(x_i, x_j)$ ，所以目標式與條件式套用核心函數可改寫如下：

$$\begin{aligned} \min \quad & \frac{\|w\|^2}{2} \\ \text{subject to: } & (\langle w, \phi(x) \rangle + b) \cdot y_i \geq 1 \quad \text{for } i=1, \dots, n \end{aligned} \quad (3.2.11)$$

在特徵空間中，有些資料可能也不一定能完全的線性分割出來，因此可以加入鬆弛變數，容許些微的分類錯誤使得分類的效果更好，而數學式子可以表示如下：

$$\begin{aligned} \min \quad & \frac{\|w\|^2}{2} + C \sum_{i=1}^n \xi_i \\ \text{subject to: } & (\langle w, \phi(x) \rangle + b) \cdot y_i \geq 1 - \xi_i, \quad \xi_i \geq 0 \\ & \text{for } i=1, \dots, n \end{aligned} \quad (3.2.12)$$

利用核心函數將資料轉換至高維度特徵空間，資料散佈的情形更為分開，加上鬆弛變數可容許些微的錯誤分類，在非線性中的資料會有較好的預測效果。而至今常使用的核心函數為線性函數(linear function)、多項式函數(polynomial function)、徑向基底函數(radial basic function, RBF)與 S 型函數神經網路(sigmoid neural nets)，其中 RBF 函數只需控制兩個母體參數(c 與 γ)且可針對非線性複雜資料進行分類，因此被建議優先選擇做為核心函數(Hsu, Chang and Lin, 2003 ; 李忠達, 2007)數學式表示如下：

Linear : $k(x_i, x_j) = x_i^T x_j$

Polynomial : $k(x_i, x_j) = (\gamma x_i^T x_j + \gamma)^d, \gamma \geq 0$

Radial Basic Function: $k(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2), \gamma > 0$

Sigmoid Neural Nets : $k(x_i, x_j) = \tanh(\gamma x_i^T x_j + \gamma), \gamma \geq 0$

支援向量迴歸

支援向量機不只可以做為分類的用途，也在專家學者的研究下使得支援向量機能處理迴歸的問題。1996 年 Drucker 和 Burges 等人以支援向量機為基礎衍伸發展出支援向量迴歸 (support vector regression, SVR)。因此，預測值不再侷限為整數，也擴展可以預測到實數部分 (Drucker, Burges, Kaufman, Smola, & Vapnik, 1996)。支援向量迴歸概念是以損失函數為主軸，以線性迴歸模型來說，通常都以最小平方法 (least square Estimator, LSE) 或者是最大概似估計法 (Maximum Likelihood Estimator, MLE) 來估計母體參數，而支援向量迴歸則是建立在非線性迴歸資料中，其中訓練資料可能是離群值 (outlier) 或雜訊 (noise) 等都有可能成為建立模型的干擾因子而影響最後的預測結果，因此可利用損失函數解決此問題。損失函數大多使用 ε -Insensitive loss function， ε -Insensitive 是檢測迴歸方程式與訓練資料的距離，利用 ε -Insensitive band 來建構迴歸超平面，而 ε -Insensitive loss function 與圖形表示如下 (Vapnik et al, 1997)

$$|y - f(x, w)|_{\varepsilon} = \begin{cases} 0 & \text{if } |y - f(x, w)| \leq \varepsilon \\ |y - f(x, w)| - \varepsilon & \text{otherwise} \end{cases} \quad (3.2.13)$$




圖 3-2-3 ε -Insensitive loss function

支援向量迴歸利用損失函數的為當實際值與預測值小於 ε 時，損失函數的值等於 0，而實際值與預測值大於 ε ，則損失函數不等於 0，因此希望在結構風險誤差最小中求得 $\|w\|^2$ 最小

值，此外還運用到前述的鬆弛變數 ζ ，與核心函數 $k(x_i, x_j)$ ，鬆弛變數的目的是容忍些微錯誤的分類已達更好的預測效果，核心函數在面對非線性資料時可先將資料轉換至高維度的特徵空間，對於迴歸模型的建立可以有最小的損失風險。因此目標式與限制式可表示如下：

$$\begin{aligned} \min \quad & \frac{\|w\|^2}{2} + C \sum_{i=1}^n (\xi_i + \xi_i^*) \\ \text{subject to:} \quad & (\langle w, \phi(x) \rangle + b) - y_i - \xi_i \leq \varepsilon \\ & y_i - (\langle w, \phi(x) \rangle + b) - \xi_i^* \leq \varepsilon \\ & \xi_i, \xi_i^* \geq 0 \quad i = 1, \dots, n \end{aligned} \quad (3.2.14)$$

C 為控制變數意即鬆弛變數對於在建構迴歸模型時能夠給與容忍錯誤程度的大小。

第三節 技術分析

技術分析的建立，乃藉由市場的交易活動來了解市場供需情況而給予投資人決策的建議，因此重點在於研究買進與賣出股票的時機為何。技術分析大略分為兩種指標，通常以決策指標與參考指標兩大類，常用的決策指標有移動平均線 (Moving Average, MA)、KD 值 (Stochastic Line)、指數平滑異同移動平均線 (Moving Average Convergence and Divergence, MACD)、相對強弱指標 (Relative Strength Index, RSI) 等；參考指標常見的有周轉率和乖離率指標 (BIAS) 等。本研究欲以常用的技術分析指標與基本資料做為輸入變數，使用的技術指標說明如下 (陳勁帆，2005；黃敏菁，2005)

一、相對強弱指標(RSI)

相對強弱指標(relative strength index, RSI)的意義是比較一段時期內的平均收盤上漲幅度和平均收盤下跌幅度，藉以分析市場買賣盤的意向和實力而判斷未來市場的走勢。RSI的公式如下：

$$RSI = 100 \times \left(1 - \frac{1}{1 + RS} \right)$$

RS : 相對強度(Relative strength)

$$RS = \frac{\text{平均下跌幅度}}{\text{平均上漲幅度}} \quad (3.3.1)$$

$$\text{因此 } RSI = 100 \times \left(1 - \frac{1}{1 + RS} \right) = 100 \times \frac{n \text{ 日平均上漲幅度}}{n \text{ 日平均下跌幅度}}$$

由上式(3.3.1)可知 RSI 值介在 0 至 100 之間。RSI 由於是 n 日的平均上漲幅度除以 n 日下跌幅度，因此日數的選擇，有非常多種選擇，常用的日數有 5 日 RSI、6 日 RSI、10 日 RSI、12 日 RSI。

二、指數平滑異同移動平均線(MACD)

指數平滑異同移動平均線(moving average convergence divergence, MACD)是以指數移動平均線(EMA)容易掌握趨勢變動的方向之優點所發展出來，利用兩條不同速度(短期的移動平均線 12 日 EMA 以及移動速率較慢的長期移動平均線 26 日 EMA)的指數平滑移動平均線來計算二者之間的差離值(DIF)作為研判行情的基礎。計算過程如下：

(1)需求指數(Demand Index, DI)

$$DI_t = \frac{\text{當日最高價} + \text{當日最低價} + 2 \times \text{當日收盤價}}{4} \quad (3.3.2)$$

(2)指數移動平均數(Exponential Moving Average, EMA)

$$EMA_t = EMA_{t-1} + \alpha \times (D I_t - EMA_{t-1})$$

$$\alpha = \frac{2}{1 + \text{移動平均天數}} \quad (3.3.3)$$

(3) 差離值(DIF)=短期移動平均-長期移動平均

$$D I F(t) = EMA(12) - EMA(26) \quad (3.3.4)$$

(4) 差離值平均(DEM)即一般所稱 MACD

$$MA C D(t) = MA C D(t-1) + \alpha * (D I F(t) - MA C D(t-1))$$

$$\alpha = \left(\frac{2}{1 + \text{移動平均天數}} \right) \quad (3.3.5)$$

三、隨機指標(KD)

隨機指標(Stochastic) 又稱為 KD 指標，是美國 George Lane 在 1957 年所創造出來。由於期貨風險性波動大，根據觀察，當市場價格上漲時，當日收盤價總是朝向當日價格的最高價靠近；股價下跌時，收盤價會向當日價格的最低價接近，因此需要較短期、敏感的指標工具，對於中短期投資的技術分析也較為適用，KD 指標結合動量觀念、強弱指標與移動平均線的優點。在計算的過程中，將當日或最近數日的最高、最低價、收盤價等價格的漲幅，來反映價格走勢的強弱和超買超賣等現象。計算 KD 指標過程如下：

(1) 以 9 天週期為例，算出未成熟隨機值(R S V)

$$R S V = \frac{(\text{第 9 天收盤價} - \text{最近 9 天內最低價})}{(\text{最近 9 天內最高價} - \text{最近 9 天內最低價})} \times 100$$

(2) $K_t = \frac{1}{3} \times RSV_t + \frac{2}{3} \times K_{t-1}$

(3) $D_t = \frac{1}{3} \times K_t + \frac{2}{3} \times D_{t-1}$

$$(3.3.6)$$

因此 K_t 與 D_t 計算出的數值為 0 至 100 之間，KD 線將參考其間內的最高價與最低價納入考量，較能呈現真正的波幅，並且可以與兩線交叉點來做短期的買進賣出時機。

四、移動平均線(MA)

移動平均(Moving Average, MA)是運用股價趨勢判斷的方法，以移動平均的概念，計算某一段時間內的股價趨勢。移動平均線過去較常使用的有 5 日 MA(週線)、10 日 MA、20 日 MA(月線)、60 日 MA 等等。移動平均線的目的以某一段時間平均成本的移動曲線配合收盤價的線型變化做一期間多空的優劣形勢分析，預測股價可能的變化。移動平均的計算較為簡單，以下式表示：

$$\begin{aligned}\text{當日平均價格} &= \frac{\text{當日成交金額}}{\text{當日成交股數}} \\ 5 \text{ 日平均價} &= \frac{(\text{當日平均價} + \text{前 4 日平均價} \times 4)}{5} \\ 20 \text{ 日平均價} &= \frac{(\text{當日平均價} + \text{前 19 日平均價} \times 19)}{20}\end{aligned}\quad (3.3.7)$$

五、平均成交量(MV)

股市中常常成交量會影響股市的價格，價量配合股價持續上漲，而價量背離是變盤的徵兆之一，個股的成交量以成交張數表示，因此平均成交量(Mean Volume, MV)可分析現行成交量與價格的關係。而平均成交量的公式如下所示：

$$n \text{ 日 } MV = \frac{\text{前 } n \text{ 日的成交量總和}}{n} \quad (3.3.7)$$

六、趨向指標(DMI)

趨向指標(Directional Movement Index, DMI)是 Welles Wilder JR. 在 1978 年所提出。藉由創新高價或新低價的動量，以計量分析的方法，研判市場上多空雙方的力道，來決定波段操作或短線進出，並提供投資人在投資金額上加減碼的依據。對照其他技術指標都是以每一日的收盤價或漲跌幅變化來計算出不同的分析數據，其缺點在於忽略了每一日的高價與低價的波動幅度。而趨向指標 DMI 則是將每日的高低波動的幅度因素考量在內，分析預測未來的走勢。「趨向指標(DMI)」的

計算較為繁複，包含兩個重要的技術指標，包括「方向指標 (Directional Indicator, DI)」及「平均趨向指標 (Average Movement Index, ADX)」。計算過程如下所示：

(1) 計算趨向變動值趨向值 (Directional Movement, DM)

$$\begin{aligned} +DM &= \begin{cases} H_t - H_{t-1} & \text{if } H_t - H_{t-1} > 0 \\ 0 & \text{o.w.} \end{cases} \\ -DM &= \begin{cases} |L_t - L_{t-1}| & \text{if } L_t - L_{t-1} < 0 \\ 0 & \text{o.w.} \end{cases} \end{aligned} \quad (3.3.8)$$

H_t : 第 t 日最高價
 L_t : 第 t 日最低價

DM 表示股價波動的增減幅度，依照(3.3.8)式可求 14 日之趨向變動值：

$$\begin{aligned} +DM_{14} &= \frac{13}{14} \times (+DM_{13}) + \frac{1}{14} \times (\text{當日的} +DM) \\ -DM_{14} &= \frac{13}{14} \times (-DM_{13}) + \frac{1}{14} \times (\text{當日的} -DM) \end{aligned} \quad (3.3.9)$$

(2) 計算真正波動幅度 (True Range, TR):

$$TR = \max \{ (H_t - L_t), (H_t - C_t), (L_t - C_{t-1}) \}$$

C_t : 為第 t 日之收盤價

$$TR_{14} = \frac{13}{14} \times TR_{13} + \frac{1}{14} \times (\text{當日之} TR) \quad (3.3.10)$$

(3) 計算方向指標 (Directional Indicator, DI):

$$DI = \frac{\text{趨向變動值}}{\text{真正的波動幅度}}, \quad +DI_{14} = \frac{+DM_{14}}{TR}, \quad -DM_{14} = \frac{-DM_{14}}{TR} \quad (3.3.11)$$

(3) 計算平均趨向指標 (Average Directional Movement Index, ADX)

ADX)，首先要先計算趨向值(Directional Movement Index，DX)：

$$DX = \frac{|(+DI) - (-DI)|}{(+DI) + (-DI)} \times 100\% \quad (3.3.12)$$

利用(3.3.12)算出 ADX：

$$ADX_{14} = \frac{13}{14} ADX_{13} + \frac{1}{14} (\text{當日的} DX) \quad (3.3.13)$$

七、威廉指標(WMS%R)

威廉指標(Williams Oscillator，WMS%R)是應用擺動原理來量度股市的超買賣現象，尋找股市週期循環內的高點或是低點，提供投資的買賣訊號。計算方式為：

$$WMS\%R = 100 \times \frac{(H_n - C_t)}{(H_n - L_n)} \quad (3.3.14)$$

H_n ：n日內最高價； L_n ：n日內最低價
 C_t ：第n日的收盤價

八、動量指標 (MTM)

動量指標(Momentum，MTM)為一種分析股價波動的技術指標。在探討股價波動的過程中，股價移動的速度是相當重要的因素，因此由股價在波動中加速、減速情況便能從中分析買賣點的訊號。股價通常會往確定的漲勢或是跌勢的方向前進，也就是說當有一明確的趨勢時，股市的價格也會跟著趨勢的方向。一般來說，股價進行的速度會是趨勢方向的先行指標。MTM 計算過程如下所示：

$$MTM = C - C_n \quad (3.3.15)$$

C_n ：n日前的收盤價； C ：當日的收盤價

九、乖離率(BIAS)

乖離率(Bias)是從移動平均理論衍生的一項技術指標，理論基礎是如果股價離平均線太遠，短期內還是會因為技術性

反彈或回軟將股價拉回平均線附近，因此乖離率是計算股價在波動過程中與移動平均線出現偏離的程度。乖離率理論基礎以直觀的角度來看，可以視為投資人目前的平均報酬率，當平均報酬率比股價高時，投資人會想要獲利了結，而賣壓變重，而股價就會下跌。同理，平均報酬率比股價低時，投資人覺得可以逢低買進，買氣升高，而股價就會上漲。乖離率的計算方式如下：

$$n\text{日的乖離率} = \frac{(\text{當日收盤價} - n\text{日移動平均})}{n\text{日移動平均}} \times 100\% \quad (3.3.16)$$

十、心理線(PSY)

心理線(Psychological Line, PSY)是根據投資人的心理受到股價趨勢的影響，使得投資人改變投資決策。因此心理線便是投資者受到影響後傾向買方或傾向賣方的心理與事實轉換為數值。而計算方式如下所示：

$$n\text{日的PSY} = \frac{n\text{日內上漲天數}}{n} \times 100\% \quad (3.3.17)$$

第四節 主成份分析

主成份分析(Principal Component Analysis, PCA)是由 Pearson 於 1901 年提出，由 Hotelling 於 1933 再加以修正以後發展出來的統計方法。主成份分析能將資料簡化，將多個有相關的變數簡化成少數且互相獨立的主成份，而且經由線性組合所得的主成份會有最大的變異數。另外，在建立模型中，會希望所取的變數不需要過多，所以主成份分析除了用來概述變數間的關係外，亦可消減模型中所承載的大量變數。因此主成份分析就是尋找一組線性組合，使得此組線性組合能以少數幾個主成份代替原來較多的變數，幾個主成份之間也互相獨立，且線性組合能不失原來的資訊具有代表

性，而組成的方式為對重要的變數給予較大的權重，不重要的變數給予較小的權重。所以，主成份分析能達成精簡、獨立、具代表性等三項重要的目標（陳順宇，2002）。

主成份分析是以所有變數做線性組合，假設變數為 x_1, x_2, \dots, x_n ，因此會得到主成份 y_1, y_2, \dots, y_n ，樣本共異變數矩陣 S ，第 k 個主成份為

$$\begin{aligned} y_k &= a_{k1}x_1 + \dots + a_{kn}x_n = a'_k x \\ a_k &= S \text{ 的第 } k \text{ 個特徵值 } \lambda_k \text{ 對應之特徵向量} \end{aligned} \quad (3.4.1)$$

主成份分析有下列特性：

1. 第一主成份的係數向量 a_1 與第二主成份的係數向量 a_2 是互相直交。以數學式表示為 $a_1'a_2=0$ ，同理，而各個主成份的係數也會互相直交。
2. 第一主成份 y_1 與第二主成份 y_2 也會互相直交， $y_1'y_2=0$ 。因此各個主成份也會互相獨立。
3. 各個主成份的變異數是其對應的特徵值， $Var(y_i)=\lambda_i$ 。
4. 所有主成份變異數的和與所有變數的變異數的和相等。

$$\sum_{i=1}^n Var(y_i) = \sum_{i=1}^n Var(x_i)$$

5. 主成份 y_k 解釋全體原變數變異數的比例為：

$$\frac{Var(y_k)}{\sum_{i=1}^n Var(y_i)} = \frac{\lambda_k}{\sum_{i=1}^n \lambda_i}$$

而第一個主成份至第 k 個主成份共解釋變異數的比例為：

$$\frac{\sum_{i=1}^k Var(y_i)}{\sum_{i=1}^n Var(y_i)} = \frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^n \lambda_i}$$

第 j 個主成分 y_j 與第 k 個變數 x_k 的相關係數為：

$$r_{y_j x_k} = \frac{a_{jk} \sqrt{\lambda_j}}{s_k}$$

λ_j = 第j個主成份的特徵值

s_i = 第i個變數的標準差

如果變數的單位相同，可以利用共變異數矩陣 S 做主成份得點，但是如果變數的單位不同，必須先將資料標準化後在做主成份分析會有比較好的效果。利用相關矩陣 R 取代共變異數矩陣 S，在求出特徵值、特徵向量。

主成份個數的選擇：

對於許多變數 x_i ，選取多少個主成份是難解的問題，如果選取過多主成份，解釋原變數能力雖然會很大，但是沒有達到縮減的目的，選取的主成分太少，可能解釋原變數能力會太小，代表性不足。下列表示常用選取主成份個數的原則：

a. 解釋變異數比例 R^2 大於某一水準，通常水準由經驗法則訂定(0.9 或 0.8)。

b. 取到第 k 個主成份的特徵值大於全體特徵值的平均。即

$$\lambda_k \geq \frac{\sum_{i=1}^n \lambda_i}{n}。$$

c. 利用特徵值畫出陡坡圖藉以判斷到第幾個主成份為開始平坦的點。

d. 相對於利用陡坡圖，可利用統計方法 Bartlett 檢定與 Anderson 檢定找出最後 q 個特徵值相等的方法。因此可判斷最後第 q 個是否為陡坡圖開始平坦的點。

第肆章 實證研究

本研究以台灣期貨交易所(TAIFEX)推出的台股期貨與金融期貨以及電子期貨為研究對象，研究範圍以 2004 年 11 月 10 日至 2008 年 11 月 18 日止，共計有 998 筆資料，資料來自「台灣經濟新報(TEJ)」資料庫中之每日交易資料。本研究提出兩種投資決策預測模型，分別是以類神經網路與支援向量迴歸對上述三筆資料做股價指數預測的研究，並且比較經過主成份後的預測模型與未主成份的預測模型兩者預測能力與投資績效。

第一節為資料分析將基本資料及技術指標利用主成份分析法轉換為互相獨立的主成份變數，使得變數之間互相獨立，因此變數之間便不會有共線性的問題；第二節為類神經網路模型參數的探討，藉以比較三種資料在類神經網路預測的效果；第三節為支援向量迴歸參數的探討，同時也比較三種資料在支援向量迴歸的效果；第四節以預測的收盤價做綜合比較，探討以主成份變數與技術指標變數為輸入變數及兩種預測模型交叉比對之下的預測能力。以下分四節詳細說明之。



第一節 資料分析

本研究以台股指數、金融指數、電子指數做為研究對象，選擇常用的十項技術指標包含：相對強弱指標(RSI)、指數平滑異同移動平均線(MACD)、隨機指標(KD)、移動平均線(MA)、平均成交量(MV)、趨向指標(DMI)、威廉指標(WMS%R)、動量指標(MTM)、乖離率(BIAS)、心理線(PSY)，搭配基本資料開盤價、最高價、最低價、成交量等做一開始的變數選擇，對於每項的技術指標所採取的時間參數不同並且考慮多種時間參數，所以最後選擇的變數總計為 36 項，見下「表 4-1-1」所示：

表 4-1-1 所選取的技術指標變數

中文名稱	英文簡稱	採用天數
相對強弱指標	RSI	5 日、6 日、10 日、12 日
指數平滑異同移動平均線	MACD	12 日、26 日
隨機指標	KD	
移動平均線	MA	5 日、5 日、5 日、5 日
平均成交量	MV	5 日、10 日、20 日、60 日
趨向指標	DMI	10 日、12 日、14 日
威廉指標	WMS%R	3 日、6 日、12 日、14 日
動量指標	MTM	3 日、6 日、10 日、12 日
乖離率	BIAS	5 日、10 日、20 日
心理線	PSY	3 日、6 日、12 日

因為懷疑技術指標之間是否有線性相關，因此本研究先對台股指數、金融指數、電子指數三筆資料中所計算出的技術指標利用統計方法中的相關分析了解是否變數之間具有高度相關。

從下「表 4-1-2」台股指數的相關係數矩陣可以看出大部份的技術指標變數具有高度相關，相關係數為正代表變數之間為正相關；相關係數為負代表變數為負相關，其值越大，相關程度也越大。利用相關係數下方的顯著性檢定也可判斷兩兩變數之間是否有線性相關，若 p 值小於 0.05 代表兩變數之間具有顯著的相關，因為技術指標為基本資料分析計算而來，使得變數之間有線性相關，因此台股指數適合用主成份分析法將輸入變數轉換為互相獨立的主成份變數。

表 4-1-2 台股指數相關係數

	RSI	MACD	Kt	Dt	MA	MV	ADX	WMSR	MTM	BIAS	PSY
RSI	1.000	0.336	0.872	0.606	-0.033	0.251	-0.186	-0.614	0.701	0.735	0.617
顯著性		0.000	0.000	0.000	0.301	0.000	0.000	0.000	0.000	0.000	0.000
MACD		1.000	0.399	0.572	0.189	0.350	-0.269	-0.069	0.117	0.121	0.077
顯著性			0.000	0.000	0.000	0.000	0.000	0.029	0.000	0.000	0.014
Kt			1.000	0.828	-0.017	0.257	-0.208	-0.354	0.483	0.487	0.399
顯著性				0.000	0.601	0.000	0.000	0.000	0.000	0.000	0.000
Dt				1.000	0.032	0.254	-0.296	-0.072	0.146	0.148	0.101
顯著性					0.312	0.000	0.000	0.023	0.000	0.000	0.001
MA					1.000	0.160	0.228	0.060	-0.068	-0.095	-0.126
顯著性						0.000	0.000	0.060	0.031	0.003	0.000
MV						1.000	-0.138	-0.119	0.204	0.220	0.136
顯著性							0.000	0.000	0.000	0.000	0.000
ADX							1.000	0.018	-0.051	-0.062	0.002
顯著性								0.565	0.110	0.051	0.952
WMSR								1.000	-0.574	-0.668	-0.530
顯著性									0.000	0.000	0.000
MTM									1.000	0.921	0.660
顯著性										0.000	0.000
BIAS										1.000	0.609
顯著性											0.000
PSY											1.000
顯著性											

相同地，金融指數的相關係數矩陣由下「表 4-1-3」得知技術指標之間還是有高度的相關，因此也可以利用主成份分析將變數轉換為獨立成份變數，使得在預測模型中變數之間互相獨立。

表 4-1-3 金融指數相關係數

	RSI	MACD	Kt	Dt	MA	MV	ADX	WMSR	MTM	BIAS	PSY
RSI	1.000	0.268	0.856	0.581	-0.045	0.057	-0.118	-0.591	0.692	0.707	0.635
顯著性		0.000	0.000	0.000	0.152	0.071	0.000	0.000	0.000	0.000	0.000
MACD		1.000	0.304	0.487	0.212	0.290	-0.224	0.001	0.081	0.082	0.030
顯著性			0.000	0.000	0.000	0.000	0.000	0.969	0.010	0.010	0.345
Kt			1.000	0.813	-0.015	0.114	-0.101	-0.319	0.460	0.450	0.428
顯著性				0.000	0.642	0.000	0.001	0.000	0.000	0.000	0.000
Dt				1.000	0.056	0.169	-0.198	-0.021	0.103	0.104	0.124
顯著性					0.076	0.000	0.000	0.516	0.001	0.001	0.000
MA					1.000	0.340	-0.082	0.090	-0.127	-0.181	-0.114
顯著性						0.000	0.010	0.004	0.000	0.000	0.000
MV						1.000	0.031	0.019	-0.010	-0.010	-0.058
顯著性							0.334	0.556	0.744	0.747	0.069
ADX							1.000	-0.030	0.007	0.005	0.010
顯著性								0.347	0.823	0.870	0.743
WMSR								1.000	-0.586	-0.649	-0.525
顯著性									0.000	0.000	0.000
MTM									1.000	0.917	0.666
顯著性										0.000	0.000
BIAS										1.000	0.607
顯著性											0.000
PSY											1.000
顯著性											

同上，「表 4-1-4」相關係數矩陣得知電子指數技術指標的相關係數與顯著性檢定變數之間具有高度相關，因此嘗試利用主成份分析得到新的輸入變數。

表 4-1-4 電子指數相關係數

	RSI	MACD	Kt	Dt	MA	MV	ADX	WMSR	MTM	BIAS	PSY
RSI	1.000	0.332	0.867	0.598	-0.030	0.106	-0.120	-0.603	0.732	0.767	0.641
顯著性		0.000	0.000	0.000	0.349	0.001	0.000	0.000	0.000	0.000	0.000
MACD		1.000	0.388	0.570	0.199	0.001	-0.269	-0.073	0.108	0.114	0.046
顯著性			0.000	0.000	0.000	0.982	0.000	0.021	0.001	0.000	0.147
Kt			1.000	0.826	-0.006	0.069	-0.123	-0.337	0.493	0.505	0.428
顯著性				0.000	0.858	0.028	0.000	0.000	0.000	0.000	0.000
Dt				1.000	0.045	0.039	-0.192	-0.058	0.154	0.164	0.132
顯著性					0.157	0.221	0.000	0.067	0.000	0.000	0.000
MA					1.000	-0.136	0.341	0.053	-0.068	-0.102	-0.120
顯著性						0.000	0.000	0.095	0.032	0.001	0.000
MV						1.000	-0.224	-0.022	0.112	0.094	0.032
顯著性							0.000	0.496	0.000	0.003	0.318
ADX							1.000	0.040	-0.048	-0.061	-0.042
顯著性								0.204	0.133	0.054	0.185
WMSR								1.000	-0.579	-0.675	-0.529
顯著性									0.000	0.000	0.000
MTM									1.000	0.920	0.708
顯著性										0.000	0.000
BIAS										1.000	0.661
顯著性											0.000
PSY											1.000
顯著性											

為解決變數之間具有相關的問題，因此對樣本資料做主成份分析。主成份分析萃取的標準是利用特徵值相關矩陣及特徵向量相關矩陣找出特徵值大於 1 之主成份，並且利用陡坡圖加以印證所選取的主成份點是否達到和緩的坡度。

主成份分析

台股指數運用 SPSS 12.0 中的主成份分析法，可將原始的 36 個輸入變數轉換成 36 個主成份點，每個主成份點互相獨立，並且為了縮減變項的數目，利用上述的萃取標準可以得到「表 4-1-5」台股指數相關係數特徵值中特徵值大於 1 或趨近於 1 的有六個主成份點，而六個主成份點的累積解釋變異百分比為 88.78%，經由陡坡圖「圖 4-1-1」的描繪也能證明在第六個成份點以後，坡度開始趨近平緩，表示前六項有較大的解釋變異能力，因此選擇主成份一至主成份六做為模型預測的輸入變數。

表 4-1-5 台股指數相關係數矩陣特徵值

主成份變數	特徵值	總和	變異數的百分比	累積百分比
1	14.51	14.51	39.23	39.23
2	8.43	22.94	22.78	62.00
3	4.04	26.98	10.92	72.92
4	2.55	29.53	6.88	79.80
5	2.06	31.59	5.57	85.37
6	1.26	32.85	3.42	88.79
7	0.99	33.84	2.68	91.46
8	0.67	34.51	1.81	93.27
9	0.57	35.08	1.54	94.81
10	0.41	35.49	1.12	95.93
11	0.25	35.75	0.68	96.61
12	0.23	35.98	0.63	97.24
13	0.21	36.19	0.56	97.80
14	0.14	36.33	0.38	98.18
15	0.12	36.45	0.32	98.51
16	0.11	36.56	0.29	98.79
17	0.09	36.64	0.24	99.03
18	0.08	36.73	0.22	99.25
19	0.07	36.80	0.20	99.45
20	0.06	36.86	0.16	99.61
21	0.04	36.90	0.12	99.73
22	0.03	36.93	0.08	99.80
23	0.02	36.95	0.07	99.87
24	0.01	36.97	0.04	99.90
25	0.01	36.98	0.03	99.93
26	0.01	36.99	0.03	99.96
27	0.01	37.00	0.02	99.98
28	0.00	37.00	0.01	100.00
29	0.00	37.00	0.00	100.00
30	0.00	37.00	0.00	100.00
31	0.00	37.00	0.00	100.00
32	0.00	37.00	0.00	100.00
33	0.00	37.00	0.00	100.00
34	0.00	37.00	0.00	100.00
35	0.00	37.00	0.00	100.00
36	0.00	37.00	0.00	100.00

因素陡坡圖




圖 4-1-1 台股指數主成份分析陡坡圖

金融指數運用 SPSS 12.0 中的主成份分析法，可將原始的 36 個輸入變數轉換成 36 個主成份點，每個主成份點互相獨立，並且為了縮減變項的數目，利用上述的萃取標準可以得到「表 4-1-6」台股指數相關係數特徵值中特徵值大於 1 或趨近於 1 的有六個主成份點，而六個主成份點的累積解釋變異百分比為 87.20%，經由陡坡圖「圖 4-1-2」的描繪也能證明在第六個成份點以後，坡度開始趨近平緩，表示前六項有較大的解釋變異能力，因此選擇主成份一至主成份六做為模型預測的輸入變數。

表 4-1-6 金融指數相關係數矩陣特徵值

主成份變數	特徵值	總和	變異數的百分	累積百分比
1	13.77	13.77	37.23	37.23
2	8.27	22.05	22.36	59.58
3	3.39	25.43	9.16	68.74
4	3.13	28.57	8.47	77.21
5	2.32	30.88	6.26	83.47
6	1.38	32.27	3.74	87.20
7	0.98	33.24	2.64	89.85
8	0.73	33.97	1.98	91.82
9	0.67	34.64	1.80	93.62
10	0.44	35.08	1.18	94.81
11	0.40	35.48	1.08	95.88
12	0.28	35.75	0.75	96.63
13	0.24	35.99	0.64	97.27
14	0.16	36.15	0.43	97.70
15	0.14	36.29	0.39	98.09
16	0.13	36.42	0.35	98.44
17	0.10	36.52	0.27	98.70
18	0.09	36.61	0.25	98.95
19	0.09	36.70	0.24	99.19
20	0.08	36.78	0.22	99.40
21	0.07	36.85	0.18	99.58
22	0.04	36.88	0.10	99.68
23	0.03	36.92	0.09	99.77
24	0.03	36.94	0.08	99.85
25	0.01	36.96	0.04	99.89
26	0.01	36.97	0.04	99.92
27	0.01	36.98	0.03	99.95
28	0.01	36.99	0.03	99.98
29	0.00	37.00	0.01	99.99
30	0.00	37.00	0.00	99.99
31	0.00	37.00	0.00	100.00
32	0.00	37.00	0.00	100.00
33	0.00	37.00	0.00	100.00
34	0.00	37.00	0.00	100.00
35	0.00	37.00	0.00	100.00
36	0.00	37.00	0.00	100.00

因素陡坡圖




圖 4-1-2 金融指數主成份分析陡坡圖

電子指數以 SPSS 12.0 中的主成份分析法，可將原始的 36 個輸入變數轉換成 36 個主成份點，每個主成份點互相獨立，並且為了縮減變項的數目，利用上述的萃取標準可以得到「表 4-1-7」台股指數相關係數特徵值中特徵值大於 1 或趨近於 1 的有六個主成份點，而六個主成份點的累積解釋變異百分比為 88.47%，經由陡坡圖「圖 4-1-3」的描繪也能證明在第六個成份點以後，坡度開始趨於平緩，表示前六項有較大的解釋變異能力，因此選擇主成份一至主成份六做為模型預測的輸入變數。

表 4-1-7 電子指數相關係數矩陣特徵值

主成份變數	特徵值	總和	變異數的百分	累積百分比
1	14.38	14.38	38.87	38.87
2	8.47	22.85	22.88	61.75
3	3.62	26.47	9.79	71.53
4	2.97	29.44	8.02	79.55
5	2.02	31.46	5.47	85.03
6	1.28	32.74	3.45	88.47
7	0.83	33.56	2.24	90.71
8	0.66	34.23	1.80	92.51
9	0.55	34.78	1.49	94.00
10	0.49	35.27	1.32	95.32
11	0.41	35.68	1.10	96.43
12	0.23	35.91	0.62	97.05
13	0.20	36.10	0.53	97.58
14	0.15	36.26	0.41	97.99
15	0.12	36.38	0.32	98.32
16	0.11	36.49	0.30	98.61
17	0.10	36.58	0.26	98.87
18	0.08	36.66	0.22	99.09
19	0.08	36.74	0.20	99.29
20	0.07	36.81	0.19	99.49
21	0.06	36.86	0.15	99.63
22	0.04	36.90	0.11	99.74
23	0.03	36.94	0.09	99.83
24	0.03	36.96	0.07	99.89
25	0.01	36.97	0.03	99.92
26	0.01	36.98	0.03	99.95
27	0.01	36.99	0.03	99.98
28	0.01	37.00	0.01	99.99
29	0.00	37.00	0.00	100.00
30	0.00	37.00	0.00	100.00
31	0.00	37.00	0.00	100.00
32	0.00	37.00	0.00	100.00
33	0.00	37.00	0.00	100.00
34	0.00	37.00	0.00	100.00
35	0.00	37.00	0.00	100.00
36	0.00	37.00	0.00	100.00

因素陡坡圖




圖 4-1-3 電子指數主成份分析陡坡圖

本節將三筆資料的輸入變數經由相關分析後，發現都具有高度相關，因此利用主成份分析法將三筆資料都萃取新的六個主成份變數，所以將作為倒傳遞類神經網路(BPN)與支援向量迴歸(SVR)的輸入變數。實證期間 998 筆資料中之 800 筆(2004 年 11 月 10 日至 2008 年 1 月至 29 日，約 80%)作為訓練資料，而剩下之 198 筆(2008 年 1 月 30 日至 2008 年 11 月至 18 日，約 20%)資料則保留作為測試資料。

第二節 倒傳遞類神經網路

本研究欲以倒傳遞類神經網路作為預測的模型，使用 Vesta 公司所出版的類神經網路軟體(Qnet)進行分析。類神經網路架構包含了輸入層、隱藏層、轉換函數、輸出層。葉怡成(2003)指出隱藏層數通常為一層便能解釋複雜的非線性系統，轉換函數使用雙彎曲函數，隱藏層節點數依照建議，對一個具有 k 個輸入節點的類神經網路，隱藏層節點數為 $2k-2$ 、 $2k-1$ 、 $2k$ 、 $2k+1$ 、 $2k+2$ 、 $2k+3$ 。而其他的參數如學習速率考慮到其值不能太大或太小，學習速率太大容易造成過度學習，太小會使得學習過程的時間過於緩慢，因此建議在 0.01 至 0.05 之間，本研究選擇學習速率為 0.01、0.015、0.02、0.05，訓練次數為 7000 次與 10000 次，慣性因子設定為 Qnet 軟體內設值 0.08。利用試誤法(try and error)從中選取最佳的參數組合，判斷的方法為利用均方根誤差(root mean squared error, RMSE)與最陡坡降法 (The Steepest Descent Method)來加以驗證預測的效果。最後比較在類神經網路以主成份分析作為輸入變數與技術指標作為輸入變數的預測效果。

(一) 台股指數類神經網路預測結果

a. 以主成份為輸入變數的類神經網路模型

經過試誤法所找出的最佳組合在隱藏層節點數為 10，學習速率為 0.015 及訓練次數 7000 次時 RMSE 值為最小值，「圖 4-2-1」為結合主成份分析與倒傳遞類神經網路模型測試之 RMSE 趨勢圖，由圖中可知，此 BPN 模式之收斂情況良好，亦無過度學習的情況存在。




圖 4-2-1 以主成份為輸入變數測試樣本之 RMSE 趨勢圖

b. 以技術指標為輸入變數的類神經網路模型

以技術指標為輸入變數時，由於輸入變數的數目高達 36 個，類神經網路模型在訓練時容易有發散的情形產生，導致預測結果不好，可能需要測試更多組的參數，在台股指數所找尋最佳參數在隱藏層節點數為 71，學習速率為 0.005 及訓練次數 10000 次時 RMSE 值有最小值。「圖 4-2-2」為以技術分析為輸入變數之測試之 RMSE 趨勢圖。




圖 4-2-2 以技術指標為輸入變數之測試樣本之 RMSE 趨勢圖

由「圖 4-2-1」、「圖 4-2-2」得知訓練的模型效果良好。計算兩種模型預測值與實際值之 RMSE 得知:以技術指標為輸入變數之類神經網路模型之 RMSE 值為 125.79，以主成份變數為輸入變數之類神經網路模型之 RMSE 值為 234.40。顯示未經過主成份之技術指標為輸入變數之預測效果會比以主成份變數為輸入變數還要好。對於台股指數便適合在類神經網路利用「技術指標」為輸入變數。

(二) 金融指數類神經網路預測結果

a. 以主成份為輸入變數的類神經網路模型

經過試誤法所找出的最佳組合在隱藏層節點數為 10，學習速率為 0.02 及訓練次數 10000 次時 RMSE 值為最小值，「圖 4-2-3」為結合主成份分析與倒傳遞類神經網路模型測試之 RMSE 趨勢圖，由圖中可知，此 BPN 模式之收斂情況良好，亦無過度學習的情況存在。




圖 4-2-3 以主成份為輸入變數測試樣本之 RMSE 趨勢圖

b. 以技術指標為輸入變數的類神經網路模型

與台股指數的情形相同，以技術指標為輸入變數時，由於輸入變數的數目高達 36 個，類神經網路模型在訓練時容易有發

散的情形產生，導致預測結果不好，可能需要測試更多組的參數，在金融指數所找尋最佳參數在隱藏層節點數為 74，學習速率為 0.005 及訓練次數 10000 次時 RMSE 值有最小值。「圖 4-2-4」為以技術分析為輸入變數之測試之 RMSE 趨勢圖。




圖 4-2-4 以技術指標為輸入變數之測試樣本之 RMSE 趨勢圖由「圖 4-2-3」、「圖 4-2-4」得知所選取的訓練過程效果良好。計算兩種模型預測值與實際值之 RMSE 得知:以技術指標為輸入變數之類神經網路模型之 RMSE 值為 16.36，以主成份變數為輸入變數之類神經網路模型之 RMSE 值為 24.23。顯示未經過主成份之技術指標為輸入變數之預測效果會比以主成份變數為輸入變數還要好。對於金融指數便適合在類神經網路利用「技術指標」作為輸入變數。

(三) 電子指數類神經網路預測結果

a. 以主成份為輸入變數的類神經網路模型

經過試誤法所找出的最佳組合在隱藏層節點數為 10，學習速率為 0.02 及訓練次數 10000 次時 RMSE 值為最小值，「圖 4-2-5」為結合主成份分析與倒傳遞類神經網路模型測試之 RMSE 趨勢圖，由圖中可知，此 BPN 模式之收斂情況良好，亦無過度學習的情況存在。




圖 4-2-5 以主成份為輸入變數測試樣本之 RMSE 趨勢圖

b. 以技術指標為輸入變數的類神經網路模型

與台股指數的情形相同，以技術指標為輸入變數時，由於輸入變數的數目高達 36 個，類神經網路模型在訓練時容易有發散的情形產生，導致預測結果不好，可能需要測試更多組的參數，在電子指數所找尋最佳參數在隱藏層節點數為 71，學習速率為 0.005 及訓練次數 10000 次時 RMSE 值有最小值。

「圖 4-2-6」為以技術分析為輸入變數之測試之 RMSE 趨勢圖。




圖 4-2-6 以技術指標為輸入變數測試樣本之 RMSE 趨勢圖

由「圖 4-2-5」、「圖 4-2-6」得知所選取的訓練過程效果良好。計算兩種模型預測值與實際值之 RMSE 得知:以技術指標為輸入變數之類神經網路模型之 RMSE 值為 6.04，以主成分變數為輸入變數之類神經網路模型之 RMSE 值為 5.52。顯示經過主成份之技術指標為輸入變數之預測效果會比以技術指標變數為輸入變數還要好。對於電子指數便適合在類神經網路利用「主成份變數」作為輸入變數。

最後整理三筆資料「表 4-2-1」所得出的最佳參數組合與 RMSE，並在第四節中做一綜合衡量績效的比較。

表 4-2-1 整合主成份與類神經網路最佳參數整理表

	隱藏層節點數	學習率	訓練次數	RMSE
台股指數: 主成分變數	10	0.015	7000	234.40
台股指數: 技術指標	71	0.005	10000	125.79
金融指數: 主成分變數	10	0.02	10000	24.23
金融指數: 技術指標	74	0.005	10000	16.36
電子指數: 主成分變數	10	0.02	10000	5.52
電子指數: 技術指標	71	0.005	10000	6.04

第三節 支援向量迴歸

支援向量迴歸採用 Chang and Lin(2001)所設計的 SVM 軟體 LIBSVM 作為分析的工具，為了數值計算的穩定，必須先將輸入變數做正規化(normalization)的轉換，經過轉換的資料會在-1 至 1 之間，LIBSVM 可以利用 svm-scale 指令將資料做正規化的轉換，資料轉後，svm-train 為資料的訓練，其中在訓練的過程，需要設定兩個參數， c 及 g ； c 為第三章研究方法中所敘述的給定懲罰變數中的係數， g 為管狀區域的寬度，因此與類神經網路一樣，需要以試誤法找出最佳的參數解，但 Hsu *et al.*(2003)建議參數可以往指數成長的序列搜尋(如 2^{-3} 、 2^{-2} 、 2^{-1} 、 2^0 、 2^1 、 2^2 、 2^3 等)尋找的參數解的時間也會縮短。最後預測出的結果以 RMSE 最小值作為最佳參數解的選取。

(一) 台股指數支援向量迴歸預測結果

由「表 4-3-1」得知經過試誤法所找出的最佳組合：

a.以技術指標為輸入變數時， $c=2^{11}$ 、 $g=2^{-9}$ 有 RMSE=110.55 為最小值。

b.以主成份變數為輸入變數時， $c=2^{13}$ 、 $g=2^{-7}$ 有 RMSE=107.72 為最小值。

由以上得知經過主成份之技術指標為輸入變數之預測效果會比以技術指標變數為輸入變數還要好。對於台股指數在支援向量迴歸適合利用「主成份變數」作為輸入變數。

表 4-3-1 台股指數支援向量模型

組別	技術指標		測試 RMSE
參數	c	g	
1	2^9	2^{-7}	283.31
2		2^{-8}	188.33
3		2^{-9}	176.91
4	2^{10}	2^{-7}	263.28
5		2^{-8}	170.94
6		2^{-9}	130.47
7	2^{11}	2^{-7}	241.40
8		2^{-8}	154..35
9		2^{-9}	110.55
組別	主成分		測試 RMSE
參數	c	g	
1	2^{11}	2^{-7}	144.49
2		2^{-8}	165.89
3		2^{-9}	268.14
4	2^{12}	2^{-7}	116.62
5		2^{-8}	126.48
6		2^{-9}	158.01
7	2^{13}	2^{-7}	107.72
8		2^{-8}	110.15
9		2^{-9}	116.66

(二) 金融指數支援向量迴歸預測結果

由「表 4-3-2」得知經過試誤法所找出的最佳組合：

a.以技術指標為輸入變數時， $c=2^{12}$ 、 $g=2^{-9}$ 有 $RMSE=23.06$ 為最小值。

b.以主成份變數為輸入變數時， $c=2^{10}$ 、 $g=2^{-8}$ 有 $RMSE=14.39$ 為最小值。
由以上得知經過主成份之技術指標為輸入變數之預測效果會比以技術指標變數為輸入變數還要好。對於金融指數在支援向量迴歸適合利用「主成份變數」作為輸入變數。

表 4-3-2 金融指數支援向量模型

組別	技術指標		測試 RMSE
參數	C	g	
1	2^{10}	2^{-7}	59.21
2		2^{-8}	40.92
3		2^{-9}	26.82
4	2^{11}	2^{-7}	51.38
5		2^{-8}	37.17
6		2^{-9}	24.80
7	2^{12}	2^{-7}	45.50
8		2^{-8}	33.15
9		2^{-9}	23.06
組別	主成分		測試 RMSE
參數	C	g	
1	2^8	2^{-7}	18.97
2		2^{-8}	22.29
3		2^{-9}	58.61
4	2^9	2^{-7}	17.04
5		2^{-8}	15.95
6		2^{-9}	20.56
7	2^{10}	2^{-7}	16.56
8		2^{-8}	14.39
9		2^{-9}	14.50

(三) 電子指數支援向量迴歸預測結果

由「表 4-3-2」得知經過試誤法所找出的最佳組合：

a.以技術指標為輸入變數時， $c=2^8$ 、 $g=2^{-8}$ 有 $RMSE=3.64$ 為最小值。

b.以主成份變數為輸入變數時， $c=2^6$ 、 $g=2^{-6}$ 有 $RMSE=2.46$ 為最小值。

由以上得知經過主成份之技術指標為輸入變數之預測效果會比以技術指標變數為輸入變數還要好。對於電子指數在支援向量迴歸適合利用「主成份變數」作為輸入變數。

表 4-3-2 電子指數支援向量模型

組別	技術指標		測試 RMSE
參數	C	g	
1	2^6	2^{-6}	6.93
2		2^{-7}	5.42
3		2^{-8}	3.83
4	2^7	2^{-6}	5.62
5		2^{-7}	4.83
6		2^{-8}	3.85
7	2^8	2^{-6}	4.34
8		2^{-7}	3.93
9		2^{-8}	3.64
組別	主成分		測試 RMSE
參數	C	g	
1	2^4	2^{-4}	4.30
2		2^{-5}	3.25
3		2^{-6}	3.86
4	2^5	2^{-4}	4.06
5		2^{-5}	2.96
6		2^{-6}	2.66
7	2^6	2^{-4}	3.94
8		2^{-5}	2.81
9		2^{-6}	2.46

第四節 預測能力評比

本節針對第四章二、三節所尋找出的最佳參數組合做一衡量績效的評比，衡量績效的指標種類相當多元，常用的指標為均方根誤差(root mean squared error, RMSE)以外，另有以計算預測值與實際值誤差的正規化均方誤差(normalized mean squared error, NMSE)與平均絕對誤差(mean absolute error, MAE)。以上述三種衡量指標作為本節模型預測效果的評比。下列式子為各指標計算之過程：

1.均方根誤差：

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (O_i - P_i)^2}{n}}, \quad O_i: \text{實際值} \quad P_i: \text{預測值} \quad (4.4.1)$$

2.正規化均方誤差：

$$NMSE = \frac{\sum_{i=1}^n (O_i - P_i)^2}{n\delta^2}, \quad \delta^2 = \frac{1}{n-1} \sum_{i=1}^n (O_i - \bar{O})^2 \quad (4.4.2)$$

3.平均絕對誤差：

$$MAE = \frac{1}{n} \sum_{i=1}^n |O_i - P_i| \quad (4.4.3)$$

台股指數預測績效衡量評比

「表 4-4-1」是以台股指數探討兩種輸入變數在類神經網路與支援向量迴歸上的預測能力。在 RMSE、NMSE、MAE 指標下皆是以「主成份變數」為輸入變數的支援向量迴歸預測效果最好，其次是以「技術指標」為輸入變數的支援向量迴歸，而最差的是以「主成份變數」為輸入變數的類神經網路模型，由此得知在類神經網路模型上利用主成份作為輸入變數並不是適合的方法，而支援向量迴歸的模型上，利用「主成份變數」是可以得到好的預測效果。整體而言預測效果的能力支援向量迴歸會比類神經網路模型來得好。

表 4-4-1 台股指數預測績效衡量指標

	技術指標 SVR	主成分分析 SVR	技術指標 BPN	主成分分析 BPN
RMSE	110.55	107.72	125.79	234.40
績效排名	2	1	3	4
NMSE	0.005	0.005	0.007	0.026
績效排名	2	1	3	4
MAE	76.92	75.34	107.47	145.34
績效排名	2	1	3	4

金融指數預測績效衡量評比

「表 4-4-2」是以金融指數探討兩種輸入變數在類神經網路與支援向量迴歸上的預測能力。在 RMSE、NMSE、MAE 指標下皆是以「主成份變數」為輸入變數的支援向量迴歸預測效果最好，其次是以「技術指標」為輸入變數的類神經網路模型，而最差的是以主成份為輸入變數的類神經網路模型。由此得知金融指數在類神經網路模型上利用主成份作為輸入變數並不是適合的方法，而支援向量迴歸的模型上，利用「主成份變數」是可以得到好的預測效果。

表 4-4-2 金融指數預測績效衡量指標

	技術指標 SVR	主成分分析 SVR	技術指標 BPN	主成分分析 BPN
RMSE	23.064	14.391	16.369	24.235
績效排名	3	1	2	4
NMSE	0.010	0.004	0.005	0.011
績效排名	3	1	2	4
MAE	12.850	10.388	11.711	15.427
績效排名	3	1	2	4

電子指數預測績效衡量評比

「表 4-4-3」是以電子指數探討兩種輸入變數在類神經網路與支援向量迴歸上的預測能力。在 RMSE、NMSE、MAE 指標下皆是以「主成份變數」為輸入變數的支援向量迴歸預測效果最好，其次是以「技術指標」為輸入變數的支援向量迴歸，而最差的是以「技術指標」為輸入變數的類神經網路模型。以兩種預測模型比較，支援向量迴歸較優於類神經網路。由此得知在類神經網路模型上利用主成份作為輸入變數是不錯的方法，而支援向量迴歸的模型上，利用「主成份變數」則是可以得到好的預測效果。

表 4-4-3 電子指數預測績效衡量指標

	技術指標 SVR	主成分分析 SVR	技術指標 BPN	主成分分析 BPN
RMSE	3.640	2.466	6.048	5.525
績效排名	2	1	4	3
NMSE	0.005	0.002	0.014	0.012
績效排名	2	1	4	3
MAE	2.268	1.855	5.264	3.586
績效排名	2	1	4	3

第五節 投資績效分析

本研究以類神經網路與支援向量機作為預測模型，預測的目標為隔日的收盤價，依照第四章實證分析所選出的最佳參數組合，經過 RMSE、NMSE、MAE 的比較之後，以所預測的收盤價判斷漲跌方向並設計投資交易策略，進行投資績效的分析，且與買入持有策略與過往文獻做一比較。

以預測的收盤價判斷明日的漲跌幅後進行買進或賣出的策略，因此先計算各種模型的預測正確率。預測正確率的計算以下列式子表示：

首先定義上漲與下跌

$$\begin{cases} \text{上漲: 收盤價}_i - \text{收盤價}_{i-1} > 0 \\ \text{下跌: 收盤價}_i - \text{收盤價}_{i-1} \leq 0 \end{cases}$$

$$\text{預測正確率} = \frac{1}{n} \sum_{i=1}^n P_i, i = 1, 2, \dots, n \quad (4.5.1)$$

$$P_i = \begin{cases} 1, & \text{預測漲跌方向與實際漲跌方向相同} \\ 0, & \text{預測漲跌方向與實際漲跌方向不同} \end{cases}$$

「表 4-5-1」為三筆資料在各種模型之下的預測正確率，研究結果發現在三筆資料中以「主成份變數」為輸入變數的支援向量迴歸的預測正確率皆為最高，此結果與第四章所做的預測績效衡量指標結果一致相同，因此主成份變數作為支援向量迴歸的輸入變數是有幫助的。而利用主成份變數作為類神經網路的輸入變數卻是在預測正確率的效果最差，也與上章節所做出的結果相同。因此得出以主成份變數作為類神經網路的輸入變數是不合適的。

表 4-5-1 預測漲跌方向正確率

	技術指標 SVR	主成分分析 SVR	技術指標 BPN	主成分分析 BPN
台股指數	84.26%	91.37%	84.77%	84.26%
績效排名	3	1	2	3
金融指數	86.29%	97.46%	93.91%	85.28%
績效排名	3	1	2	4
電子指數	90.86%	96.95%	91.37%	90.86%
績效排名	3	1	2	3

比較預測漲跌方向正確率之後，可知以主成份為輸入變數的支援向量迴歸與以技術指標為輸入變數的類神經網路模型是有較好的預測效果，本研究以漲跌方向作為買賣訊號，做一模擬投資的交易策略，並且比較四種預測模型之投資績效，在此之前，以「表 4-5-2」介紹目前期貨投資必須的費用：

表 4-5-2 台指期貨交易費用

	保證金	每一點價值	手續費
台股指數期貨	77000	200	每口 77 元
金融指數期貨	64000	1000	
電子指數期貨	63000	4000	

假設持有本金為 20 萬元，以四種預測模型所預測出的收盤價進行模擬投資，計算累積報酬率，交易策略如下：

買進時機：預測明日股價上漲時，於尾盤買進一口，若第二天仍是預測上漲，持續買進一口，一天限定買進一口，最多可連續五天買進。

賣出時機:預測明日股價下跌時，於隔天開盤賣出所有持有的口數賺取價差，若隔天仍是預測下跌，等待買進的訊號。

每當完成一筆買進與賣出交易時，計算一次所獲取的報酬率，交易報酬率與累積報酬率為以下式子表示：

交易報酬率

$$= \frac{(\text{漲幅點數}) * \text{每點計算價值} - \text{單邊手續費} * 2}{\text{本金}} \quad (4.5.2)$$

$$= \frac{(\text{賣出} + \text{買進指數}) * \text{每點計算價值} * 0.025\%}{\text{本金}}$$

$$\text{累積報酬率} = (1 + \text{交易報酬率}_1) \times (1 + \text{交易報酬率}_2) \times \dots \times (1 + \text{交易報酬率}_n) - 1 \quad (4.5.3)$$

利用預測的收盤價判斷漲跌方向，並做每日當沖交易，得出單日的報酬率，測試樣本期間為至 2008 年 1 月 30 日至 2008 年 11 月 18 日，計有 198 筆，研究結果發現金融指數在支援向量迴歸且輸入變數為主成份變數時有最高的累積報酬率為 6784.98%，另外也得知支援向量迴歸的累積報酬率皆優類神經網路模型於。以三種類股期貨指數的報酬率為金融指數期貨最高，其次為電子指數期貨，最低報酬率為台股指數期貨報酬率。

綜合比較交易策略方面，本研究除了以「買入持有(buy and hold)」策略為操作的對照組之一以外，也將王基瑩(2004)以主成分分析結果做為類神經網路輸入因子的交易模型做為比較的部份。買入持有為一開始交易日買進，最後一交易日賣出，結果指出台股指數報酬率為 101.59%，金融指數報酬率為 113.19%，電子指數報酬率為 111.64%，探討台股期貨買入持有報酬率小於金融期貨與電子期貨報酬率之原因為台股指數期貨平倉損益漲幅點數中，1 點為 200 元計算，金融期貨 1 大點為 1000 元計算，電子期貨 1 大點為 4000 元計算。王基瑩(2004)以主成份分析作為類神經網路的輸入變數，預測隔日

的開盤價與收盤價，並藉預測的股價指數判斷明日上漲或下跌且作為模擬投資交易的訊號，當預測上漲時開盤買進，尾盤賣出；預測下跌時開盤賣出，尾盤買進，作者以單日沖銷為交易策略，其報酬率為下列(4.5.4)、(4.5.5)所示：

$$\text{單日報酬率} = \text{指數漲跌比率} - \text{交易成本率} \quad (4.5.4)$$

$$\begin{aligned} \text{累積報酬率} = & (1 + \text{單日報酬率}_1) \times (1 + \text{單日報酬率}_2) \times \cdots \\ & \times (1 + \text{單日報酬率}_n) - 1 \end{aligned} \quad (4.5.5)$$

因此本研究欲利用上述的交易模型分別模擬兩個對照組，將其投資效率與本研究進行比較。

對照組一：以本研究的基本資料計算出的 36 種技術指標輸入變數做主成份分析得到 6 個主成份輸入變數，最後做一報酬率的計算，研究結果發現台指期貨報酬率為 321.93%，金融指數期貨 519.94%，電子指數期貨報酬率 245.04%。

對照組二：以本研究的研究範圍使用與作者相同研究上的 11 種技術指標輸入變數做主成份分析得到 3 個主成份輸入變數，最後做一報酬率的計算，研究結果發現台指期貨報酬率為 263.41%，金融指數期貨 379.83%，電子指數期貨報酬率 280.55%。依照王基瑩的交易模型比較對照組一與對照組二的模擬投資報酬，得知以本研究的 36 個技術指標所組成的主成份變數在台指期貨與金融指數期貨是有較高的報酬，電子指數期貨則是以作者的 11 個技術指標所組成的主成份變數投資報酬率較高。另外比較作者與本研究的交易模型，不同策略之下，所獲得的報酬率也不盡相同，其原因有二：一、投資時間不同，本研究以 198 筆測試資料為投資交易時間，而作者以 95 筆測試資料為模擬投資交易的時間，因此時間長度不同，報酬率也會不一樣。二、交易策略不同，本研究交易策略為連

續預測上漲時，可持續買進，最多買進五口，因此所得出的累積報酬率會高於作者的單日沖銷的累積報酬率。「表 4-5-3」為整理四種預測模式、三筆資料與兩種對照組類神經預測模型上及買入持有的累積報酬率：

表 4-5-3 投資績效報酬率

	台股指數	金融指數	電子指數
技術指標 SVR	631.44%	3563.76%	2155.05%
主成分分析 SVR	1544.77%	6784.98%	2890.03%
技術指標 BPN	1455.90%	5790.98%	3759.21%
主成分分析 BPN	555.67%	2683.88%	2615.70%
對照組一	321.93%	519.94%	245.04%
對照組二	263.41%	379.83%	280.55%
買入持有	101.59%	113.19%	111.64%

整體而言，以類神經網路與支援向量迴歸所預測出的結果，在模擬投資的交易策略之下，支援向量迴歸皆比類神經網路投資績效好，也比買入持有的投資報酬率高，而在過往的文獻中，以本研究範圍套入王基瑩(2004)的預測模型及交易策略，其投資報酬率仍小於本研究預測模型與交易策略下的投資報酬，顯示以主成份分析作為支援向量迴歸的輸入變數確實是有助於增加投資的績效，因此可供投資人進行策略分析的參考。

第五章 結論與建議

第一節 結論

技術分析的出現能夠幫助判斷目前市場的趨勢為何種情況，但是技術分析的指標種類太多，究竟該如何選擇適當的技術指標及時間參數的選取，變成眾人探討的議題。因此本研究選擇技術指標作為原始輸入變數，考慮技術指標彼此之間會具有相關問題存在，所以使用主成份分析做為新的輸入變數，並且以類神經網路與支援向量機作為預測模型的工具，預測目標為隔日收盤價，最後擬一交易策略模擬投資績效，期望能給予投資人決策時的參考。

本研究以資料分析獲得結論如下：

- 壹、選取的技術指標變數，經過統計方法中的相關分析，發現大部分的變數具有高度相關。因此適合利用主成份分析轉換成主成份變數，使得變數之間互相獨立。
- 貳、探討模型預測能力，發現在台股指數、金融指數、電子指數中皆是以主成份變數作為支援向量迴歸的輸入變數，預測效果最好，其預測值與實際值最為接近，預測漲跌方向正確率也是以主成份變數作為支援向量迴歸的輸入變數最高。
- 參、模擬投資績效方面，台股指數期貨與金融指數期貨皆是以主成份變數為支援向量迴歸的輸入變數投資績效最好，而電子指數期貨是以技術指標為類神經網路模型的輸入變數最好。對於股市指數期貨種類來說，以金融指數期貨報酬率高於電子指數期貨報酬率，最低為台股指數期貨報酬率，此原因為每種股市指數期貨契約不同，漲幅點數金額計算不同所致。
- 肆、比較模擬投資交易策略，累積買進口數的交易策略會高於單日沖銷的交易策略，而買入持有的策略下報酬率則是最低。

第二節 研究限制

實證方面，尚有許多未考量的因素，本研究的研究限制有以下幾點：

壹、期貨商品交易時需繳交保證金，若交易人帳戶淨值低於「維持保證金」且不補足至原始保證金的數額，將被期貨公司予以斷頭出場。本研究假設保證金在充裕的狀況下，並不會有被斷頭出場的風險。

貳、市場趨勢影響的因素有包含總體經濟、政治、天然災害、或是經濟犯罪等多種情況，上述情況有可能會導致股價大起大落，本研究因為不確性風險太高並未加入考量。

參、股市指數期貨中，每個月都有到期日，本研究假設期貨之契約是連續的，並無考慮到期日的情況發生。

肆、在交易行為中，每一家期貨公司為了吸引顧客的手續費截然不同，因此在投資報酬中手續費的計算並未與市場的手續費相同。

第三節 後續研究建議

本研究後續研究建議可以分為下列幾點：

壹、本研究預測目標為隔日收盤價，後續研究者可針對開盤價與成交量進行預測，並且以不同交易策略進行模擬投資。

貳、國際情勢往往會牽動台灣股市，因此可以考慮加入美國、日本、大陸、歐洲市場等財務指標，對於股價的變化，相信對預測會更有幫助。

參、本研究交易策略並未考慮五指數期貨有漲跌幅 7% 的限制，後續研究者可利用非當日沖銷，以漲跌幅度判斷買進賣出的時機，做投資報酬的探討。

肆、期貨的功能除了有套利的功能以及價格發現之功能，也可以進行避險。因此可搭配現貨做一買一賣的交易策略，進行損失的控管。

伍、預測模型上，輸入變數的選取以及參數的選擇可能都會改變預測的結果，因此可以使用不同變數組合進行模擬預測。

陸、期貨有高報酬高風險的特性，可以考量加入停損策略，減少預測錯誤的損失。



參考文獻

中文部份

- 王基瑩 (2004)。台灣股市上市公司股票交易策略績效之研究。輔仁大學應用統計所未出版碩士論文。台北縣。
- 江天佑 (2003)。台股指數期貨對投資組合避險效果之研究。銘傳大學經濟學系未出版碩士班論文。台北市。
- 何宣儀 (2000)。股價指數期或套利機會分析並驗證國內期貨市場之有效性-以台股、電子、金融期貨為例。國立政治大學財務管理研究所未出版碩士論文。台北市。
- 李宗祥 (1989)。股價指數期貨之探索性研究。國立中興大學企業管理研究所未出版碩士論文。台中市。
- 李忠達 (2007)。應用資料包絡分析及支援向量機建構信用評分模式於顧客貢獻度之評估與改善。輔仁大學管理學研究所未出版碩士論文。台北縣。
- 林船全 (2008)。獨立成分分析法與支援向量迴歸於台指選擇權分析與預測之研究。國立彰化師範大學商業教育學系未出版碩士論文。彰化市。
- 陳雅雯 (2003)。支援向量機於預測台灣股市股價漲跌之實證研究。南華大學資訊管理學系未出版碩士論文。嘉義縣。
- 陳順宇 (2002)。多變量分析。(4版) 臺北市: 華泰。
- 陳勁帆 (2005)。EWMA 管制圖應用在股票市場成交量的分析—以台灣五十指數之電子股為例。台灣科技大學工業工程與管理研究所未出版碩士論文。台北市。
- 黃敏菁 (2005)。支援向量機在財務時間序列預測之應用。輔仁大學金融研究所未出版碩士論文。台北縣。

葉怡成 (2003)。類神經網路模式應用與實作。台北市:儒林圖書有限公司。

楊琪倫 (2002)。台灣指數期貨開盤價預測之研究。輔仁大學管理學研究所未出版碩士論文。台北縣。

劉翔瑜 (2006)。倒傳遞類神經網路、支援向量迴歸於日經 225 現貨指數之預測及交易策略之研究。輔仁大學金融研究所未出版碩士論文。台北縣。



英文部份

- Boser, B. E., Guyon, I. M., & Vapnik, V. N. (1992). *A training algorithm for optimal margin classifiers.*, Pittsburgh, Pennsylvania, United States, 144-152.
- Brock, W., Lakonishok, J., & LeBaron, B. (1992). Simple Technical Trading Rule and the Stochastic Properties of Stock Return, *Journal of Finance*, 41, 1731-1764.
- Cristianini, N., & Shawe-Taylor, J. (2000). *An Introduction to Support Vector Machines and other kernel-based learning methods*. New York :Cambridge.
- Davies, P. C. (1994). Design issues in neural network development. *NEUROVEST Journal*, 5, 21-25.
- Drucker, H. C., Burges, J. C., Kaufman, L., Smola, A., & Vapnik, N. (1996). Support vector regression machines. *Advances in Neural Information Processing Systems*, 9(1), 155-161
- Fama, E. F. (1970). Efficient Capital Markets: A Review of Theory and Empirical Work. *Journal of Finance*, 25, 383-417.
- Hsu, C.W., Cheng C.C., & Lin, C.C.(2003). A Practical Guide to Support Vector Classification. From <http://www.csie.ntu.edu.tw/~cjlin/papers/guide/guide.pdf>
- Kim, K. J., & Han, I.(2000). Genetic algorithms approach to feature discretization in artificial neural networks for the prediction of stock price index, *Expert Systems with Application*, 19, 125-132.
- Komo, D., Chang, C.I., & Ko, H. (1994). Neural Network Technology for Stock Market Index Prediction, *International Symposium on Speed, Image Processing and Neural Network*, 2, 543-546.

- Levich, R. M., & Thomas, L. R. (1993). The Significance of Technical Trading Rules Profits in the Foreign Exchange Market : A Bootstrap Approach, *Journal of International Money and Finance* 12, 451-474.
- Pai, P. F., Chang, P. T., Lin, K. P., & Hong, W. C. (2005). Hybrid learning fuzzy neural models in stock price forecasting. *Journal of Information and Optimization Sciences*, 26(3), 495-508,
- Poser, S. W. (2003). Applying Elliott Wave Theory profitably. Wiley.
- Pruitt, S. W., & White, R. E. (1988). The CRISMA trading system: Who says technical analysis can't beat the market?, *Journal of Portfolio Management*, 14, 55-58.
- Tay, F.E.H., & Cao L.J. (2001). Application of support vector machines in financial time series forecasting. *Omega*, 29, 309-317
- Vapnik, V. N. (1995). *The nature of statistical learning theory*. New York : Springer.